

Eine Validierung KI-gestützter Videoanalysen zur Erfassung von Unterrichtsqualität im Wirtschaftsunterricht


Masterarbeit

vorgelegt von

Quentin Weber

an der

Universität
Konstanz



Sektion Politik-Recht-Wirtschaft

Fachbereich Wirtschaftswissenschaften

1. Gutachterin: Dr. rer. pol. Liane Platz
2. Gutachterin: Prof. Dr. Sabine Hochholdinger

Konstanz, 2026

Abstract

Die empirische Unterrichtsforschung zeigt, dass insbesondere die Tiefenstrukturen des Unterrichts qualitätsrelevant sind, da sie die unmittelbaren Lehr-Lern-Prozesse adressieren und Lernzuwächse vergleichsweise stark erklären. Aufgrund des hohen Aufwands videobasierter und multimodaler Beobachtungsverfahren zur Erfassung dieser Tiefenstrukturen rücken KI-gestützte Ansätze als potenziell effiziente Analyseinstrumente in den Fokus. Ziel dieser Arbeit ist die Entwicklung und quantitative Prüfung eines automatisierten Workflows zur KI-gestützten Erfassung von Unterrichtsqualität im bislang wenig untersuchten Fachkontext des Wirtschaftsunterrichts. Methodisch ist die Untersuchung als quantitative Validierungsstudie konzipiert, in der die KI-Beurteilungen systematisch mit videobasierten menschlichen Ratings als Referenzmaß abgeglichen werden. Analysiert wurden 18 Unterrichtssegmente aus vier videografierten Unterrichtsstunden im Fach Volkswirtschaftslehre. Die Audiodaten der Unterrichtsaufzeichnungen wurden mithilfe des Whisper-Modells transkribiert und anschließend durch ein Large Language Model (GPT-5.1) auf Basis des „Unterrichtsfeedbackbogens Tiefenstrukturen (UFB)“ in den Dimensionen Kognitive Aktivierung (KA), Konstruktive Unterstützung (KU) und Strukturierte Klassenführung (SK) bewertet. Aggregiert weist SK die höchste Übereinstimmung auf, jedoch mit deutlicher Heterogenität auf Itemebene. KA zeigt eine mittlere Übereinstimmung mit relativ homogenem Muster. Die geringste Passung ergibt sich für KU. Systematische Modalitätsgrenzen zeigen sich vor allem bei nonverbal konzeptualisierten Merkmalen wie dem Monitoring (SK2) sowie in einer Tendenz zur Überbewertung, wenn das Instrument einen hohen Anteil positiv formulierter Indikatoren aufweist. Insgesamt zeigt der Workflow substantielle Validierungspotenziale, insbesondere für sprachlich explizite Qualitätsmerkmale.

Inhaltsverzeichnis

1. Einleitung	1
2. Theoretische Grundlagen	4
2.1. Genese und theoretische Fundierung des Basismodells.....	4
2.2. Kognitive Aktivierung.....	7
2.2.1. Theoretische Verankerung.....	7
2.2.2. Operationalisierung.....	9
2.2.3. Empirische Evidenz und fachliche Differenzierung	10
2.3. Strukturierte Klassenführung	11
2.3.1. Theoretische Verankerung.....	12
2.3.2. Operationalisierung.....	13
2.3.3. Empirische Evidenz und fachliche Differenzierung	15
2.4. Konstruktive Unterstützung	16
2.4.1. Theoretische Verankerung.....	17
2.4.2. Operationalisierung.....	18
2.4.3. Empirische Evidenz und fachliche Differenzierung	19
2.5. Fachspezifische Qualitätsmerkmale des Wirtschaftsunterrichts	20
2.5.1. Aktualität und Lebensweltbezug.....	23
2.5.2. Handlungsorientierung.....	24
2.5.3. Urteilsbildung und Entscheidungsfindung.....	25
2.6. Erfassung von Unterrichtsqualität.....	26
2.6.1. Unterrichtsbeobachtungen	27
2.6.2. Unterrichtstranskripte.....	30
2.7. KI in der Unterrichtsforschung	32
2.7.1. Anwendungen und Potenziale.....	32
2.7.2. Herausforderungen.....	34
3. Forschungsfragen	36
4. Methoden	37
4.1. Forschungsdesign.....	37
4.2. Workflow	38
4.2.1. Transkription	38
4.2.2. KI-gestützte Beurteilung.....	39

4.2.3.	Durchführung	40
4.2.4.	Auswertung	41
5.	Ergebnisse	43
5.1.	Transkriptbasierte Indikatoreignung	43
5.1.1.	Kognitive Aktivierung	44
5.1.2.	Konstruktive Unterstützung	45
5.1.3.	Strukturierte Klassenführung	46
5.2.	Vergleich von menschlichen Bewertungen und KI-Bewertungen	47
5.2.1.	Kognitive Aktivierung	47
5.2.2.	Konstruktive Unterstützung	49
5.2.3.	Strukturierte Klassenführung	50
5.3.	Aggregierter Vergleich auf Ebene der Basisdimensionen	51
6.	Diskussion	54
6.1.	Interpretation der Ergebnisse	54
6.1.1.	Kognitive Aktivierung	54
6.1.2.	Konstruktive Unterstützung	57
6.1.3.	Strukturierte Klassenführung	60
6.2.	Methodologische Limitationen	63
6.2.1.	Transkriptbasierte Limitationen	63
6.2.2.	Limitation durch das Beobachtungsinstrument	65
6.2.3.	KI-spezifische Limitationen	66
6.2.4.	Limitationen durch den Referenzstandard	67
6.3.	Ausblick und Implikationen	68
6.3.1.	Multimodale Erweiterung und Instrumentenpassung	68
6.3.2.	Einsatz in Praxis und Lehrkräfte(aus)bildung	70
7.	Fazit	72
	Literatur	75
	Verzeichnisse	87
	Abkürzungsverzeichnis	87
	Abbildungsverzeichnis	88
	Tabellenverzeichnis	89
	Anhang	90

1. Einleitung

Erkennen wir eine erfolgreiche Lehrkraft, wenn wir sie sehen? Strong et al. (2011) gehen dieser Frage nach, indem sie erfahrene Lehrkräfte und Schulleitungen kurze Videosequenzen von Unterricht bewerten lassen, in denen sie die Effektivität der jeweils beobachteten Lehrperson einschätzen sollen. Die Effektivität der Lehrkräfte war dabei unabhängig über die Lernzuwächse ihrer Schülerinnen und Schüler (SuS) bestimmt worden, sodass ein objektiver Bezugspunkt für die Urteile der Beobachter*innen vorlag. Trotz ihrer Expertise gelang es den Beobachter*innen jedoch nicht, die tatsächlich lernwirksamen Lehrkräfte zuverlässiger als durch Zufall zu identifizieren, was die Grenzen intuitiver Urteile über Unterrichtsprozesse eindrücklich aufzeigt (Strong et al., 2011). Die Ergebnisse der Studie machen damit deutlich, dass selbst erfahrene Beobachter*innen Unterricht nicht heuristisch anhand offensichtlicher Merkmale zuverlässig bewerten können, sondern dass es einer systematischen Erfassung tieferliegender, lernwirksamer Qualitätsmerkmale bedarf.

In der deutschsprachigen Unterrichtsforschung deuten zahlreiche Befunde darauf hin, dass gerade die Tiefenstrukturen des Unterrichts qualitätsrelevant sind, da sie die unmittelbaren Lehr-Lern-Prozesse adressieren und eine besonders hohe Erklärungskraft für Lernzuwächse aufweisen (Begrich et al., 2023; Hattie, 2013; Kunter & Voss, 2011; Seidel & Shavelson, 2007). Zur systematischen Erfassung dieser Tiefenstrukturen hat sich das Modell der drei generischen Basisdimensionen etabliert. Entsprechend werden Kognitive Aktivierung (KA), Konstruktive Unterstützung (KU) und Strukturierte Klassenführung (SK) als Basisdimensionen der Unterrichtsqualität bezeichnet (Fauth et al., 2024; Klieme, 2006; Klieme & Rakoczy, 2008; Praetorius et al., 2018). Der Ansatz ist in der Forschung zum Mathematikunterricht entstanden und wurde empirisch vor allem im Mathematik- und Naturwissenschaftsunterricht untersucht (Praetorius et al., 2020b). Dennoch beansprucht das Modell eine generische Gültigkeit (Begrich et al., 2023). In Verbindung mit dem Angebots-Nutzungs-Modell (Fend, 1981; Helmke & Weinert, 1997) folgt daraus, dass beobachtbare Merkmale des Unterrichts zunächst Lerngelegenheiten bereitstellen, deren Wirksamkeit jedoch wesentlich von der Nutzung durch die Lernenden abhängt (Helmke & Klieme, 2008). Unterrichtsqualität lässt sich daher nicht direkt beobachten, sondern nur über verschiedene Zugänge und Instrumente erschließen (Fauth et al., 2024; Kunter & Voss, 2011). Beobachtungsbasierte Qualitätsmerkmale zeigen stärkere Zusammenhänge mit Lernleistungen als über Fragebögen erhobene Merkmale

(Seidel & Shavelson, 2007). Als direkter Zugang zu Lehr-Lern-Prozessen hat sich daher insbesondere der Einsatz von Videodaten etabliert, da dieser mehrere Vorteile bietet (Gabriel, 2014; Reusser & Pauli, 2021). Ein zentrales Potenzial videobasierter Unterrichtsbeobachtung liegt in der wiederholbaren Sichtung und Re-Analyse derselben Sequenzen (Pauli & Reusser, 2006) sowie im gleichzeitigen Zugang zu verschiedenen Äußerungsmodalitäten und dem parallelen Handeln mehrerer Personen (Herrle & Breitenbach, 2016). Gleichzeitig ist die Erhebung, Kodierung und Auswertung videografierter Unterrichtssequenzen mit erheblichem zeitlichen und finanziellen Aufwand verbunden (Begrich et al., 2023; Gabriel, 2014). Zusätzlich setzen hoch inferente Ratings umfangreiche Trainingsprozesse voraus (Gold et al., 2013; Klieme, 2006). Mit dem Aufkommen Künstlicher Intelligenz (KI), insbesondere großer Sprachmodelle wie ChatGPT, wird in der Bildungsforschung zunehmend diskutiert, inwiefern solche Modelle zur Analyse und Bewertung von Lehr-Lern-Prozessen eingesetzt werden können (Köller et al., 2024; Scheiter et al., 2025). Dabei sollen etablierte Zugänge wie videobasierte Erhebungen nicht ersetzt, sondern unterstützt und erweitert werden (Eberle et al., 2024). Vor diesem Hintergrund erscheinen KI-gestützte Verfahren als potenziell ressourcenschonende Ergänzung, um große Bestände bereits erhobener Videodaten systematisch auswerten zu können (Begrich et al., 2023).

Die zentrale Motivation dieser Arbeit besteht darin, einen weitgehend automatisierten und ressourcenschonenden Workflow zu entwickeln, der die Schritte der videobasierten Transkripterstellung, der KI-gestützten Bewertung und der programmgesteuerten Auswertung integriert. Auf diese Weise soll ein praktikabler Beitrag zur Entlastung und Skalierung der Unterrichtsqualitätsforschung geleistet werden. Damit dieser Anspruch tragfähig ist, muss geprüft werden, ob eine automatisierte Auswertung durch ChatGPT zu vergleichbaren Ergebnissen führt wie videobasierte Analysen geschulter menschlicher Rater*innen. Ziel dieser Arbeit ist es daher, die Übereinstimmungsvalidität einer KI-gestützten, transkriptbasierten Bewertung von Unterrichtsqualität im Vergleich zu videobasierten menschlichen Ratings systematisch zu prüfen. Ein zusätzlicher Beitrag der Arbeit liegt darin, den bislang wenig untersuchten Fachkontext des Wirtschaftsunterrichts in den Blick zu nehmen. Als Bezugsrahmen dient der „Unterrichtsfeedbackbogen Tiefenstrukturen (UFB)“ des Instituts für Bildungsanalysen Baden-Württemberg (IBBW) einschließlich des zugehörigen Beobachtungsmanuals (Fauth et al., 2024). Das Beobachtungsinstrument operationalisiert Unterrichtsqualität in den drei Basisdimensionen KA, KU und SK über insgesamt elf Items sowie positiv und negativ formulierte

Indikatoren. Im Zentrum steht die Frage, in welchem Maße ChatGPT auf Basis von Unterrichtstranskripten als Instrument zur Beobachtung und Bewertung von Tiefenstrukturen eingesetzt werden kann und an welchen Stellen sich systematische Grenzen der Transkriptmodalität abzeichnen. Daraus ergeben sich zwei Forschungsfragen:

(F1) Für welche Basisdimensionen, Items und Indikatoren des UFB ist eine transkriptbasierte KI-Bewertung grundsätzlich geeignet und wo zeigen sich systematische Grenzen?

(F2) In welchem Maße stimmen KI-gestützte, rein transkriptbasierte Bewertungen der Unterrichtsqualität mit videobasierten Ratings geschulter menschlicher Rater*innen in den drei Basisdimensionen KA, KU und SK überein?

Methodisch ist die Arbeit als quantitative Validierungsstudie angelegt. Als Datengrundlage dienen Videoaufzeichnungen von vier Unterrichtsstunden im Fach Volkswirtschaftslehre an einem beruflichen Gymnasium in Baden-Württemberg. Die Videodaten werden mit dem Whisper-Modell von OpenAI automatisiert transkribiert und in insgesamt 18 Transkriptsegmente unterteilt. Diese Segmente werden anschließend mit ChatGPT (GPT-5.1) anhand des UFB bewertet. Die KI-Bewertungen stützen sich ausschließlich auf die finalen Transkripte. Als Referenz für den Vergleich werden die aggregierten videobasierten Ratings geschulter Rater*innen herangezogen.

Die Arbeit gliedert sich in sieben Kapitel. Kapitel 2 behandelt die theoretischen Grundlagen und folgt dabei demselben roten Faden wie die Hinführung in der Einleitung. Es führt vom Basismodell und den Basisdimensionen über deren Kritik und fachspezifische Ausdifferenzierungen hin zu Verfahren der Erfassung von Unterrichtsqualität sowie zu Potenzialen und Herausforderungen KI-gestützter Analysen in der Unterrichtsforschung. Kapitel 3 expliziert die Forschungsfragen. Kapitel 4 beschreibt das Forschungsdesign, das Datenmaterial und das methodische Vorgehen einschließlich der Umsetzung der KI-gestützten Beurteilung. Kapitel 5 präsentiert die Ergebnisse der KI-Analyse, insbesondere die Indikatoreignung für transkriptbasierte Ratings sowie den Vergleich zwischen KI-Bewertungen und menschlichen Ratings. Kapitel 6 interpretiert und diskutiert die Befunde theoriegeleitet, reflektiert methodische Limitationen und leitet Implikationen sowie Forschungsdesiderate ab. Kapitel 7 schließt die Arbeit mit einem Fazit und der Beantwortung der eröffneten Forschungsfragen ab.

2. Theoretische Grundlagen

2.1. Genese und theoretische Fundierung des Basismodells

Die systematische Erforschung von Lehr-Lern-Prozessen im schulischen Unterricht hat in Deutschland eine lange Tradition (Klieme, 2006). In der Nachkriegszeit wurde der pädagogische Zugang zu Unterrichtsprozessen zunächst stark von allgemein- und fachdidaktischen Diskursen geprägt. Zu dieser Zeit beschäftigten sich Forschende bereits mit dem Verhältnis von Methodik und Didaktik und didaktischen Prinzipien wie beispielsweise Situations- und Handlungsorientierung. Potenziale eines systematischen empirischen Blicks auf das Handlungsfeld Unterricht wurden dabei allerdings kaum genutzt (Klieme, 2006). In den 1960er- und 1970er-Jahren waren die erziehungswissenschaftlichen Debatten in Deutschland von übersteigerten Erwartungen an die technokratische Realisierbarkeit qualitativen Unterrichts sowie von amerikanisch geprägten behavioristischen und reformpädagogischen Ansätzen bestimmt, die stärker auf normative Ideale als auf empirische Evidenz bauten (Klieme, 2006). Die durch das Prozess-Produkt-Paradigma geprägte Unterrichtsforschung ging davon aus, dass bestimmte Unterrichtshandlungen, Bedingungen und Merkmale die Leistungen von Lernenden beeinflussen. Entsprechend untersuchte sie direkt beobachtbare Prozessmerkmale des Lehrerhandelns, die den Lernfortschritt als Produkt möglichst zuverlässig vorhersagen sollten (Praetorius et al., 2020b; Seidel & Shavelson, 2007). Nahezu alle frühen Meta-Analysen zu Lehrer- und Unterrichtseffektivität aus dem amerikanischen Raum (z. B. Brophy & Good, 1986) basieren auf dem Prozess-Produkt-Paradigma und hatten das Ziel, Lernfortschritt von SuS durch beobachtbare Lehrerhandlungen vorherzusagen (Rothland, 2024; Seidel & Shavelson, 2007). Die daraus resultierende Menge an fächerübergreifenden Einzelbefunden wurde in den 1980er-Jahren in generische Merkmalslisten qualitativ hochwertigen Unterrichts überführt und zusammengefasst (Praetorius et al., 2020b). Beispielsweise gilt im deutschsprachigen Raum Meyers Konzept der „Zehn Merkmale guten Unterrichts“ (2003) als Referenzrahmen.

Die empirische Wende der Unterrichtsforschung in den 1970er-Jahren führte zu einer grundlegenden Neuausrichtung des Forschungsparadigmas in Deutschland und rückte kognitive sowie ko-konstruktive Lernprozesse der SuS stärker in den Mittelpunkt. Zugleich wurde die wechselseitige Verknüpfung motivationaler und fachlicher Aspekte des Lernens zunehmend berücksichtigt (Klieme, 2006). Mit der Veröffentlichung von Jacob S. Kounins Arbeit „Tech-

niken der Klassenführung“ (1976) verlor der behavioristisch geprägte Fokus auf sichtbare Unterrichtsmerkmale und methodisch-technische Steuerung an Bedeutung (Klieme, 2006; Klieme & Rakoczy, 2008). Die Forschung wandte sich zunehmend den tieferliegenden Prozessen und Interaktionsstrukturen zu, die später als zentrale Grundlage für die Entwicklung des Modells der Basisdimensionen von Unterrichtsqualität galten (Klieme, 2006). Im neuen Verständnis wird Lernen als ein aktiver, kumulativer und sozialer Konstruktionsprozess verstanden, bei dem Lehrerhandeln das Lernen nicht direkt verursacht, sondern eine Lernumgebung als Gelegenheitsstruktur erschafft, deren Angebote von den Beteiligten gemeinsam geformt und genutzt werden müssen (Baumert & Kunter, 2006; Klieme, 2006; Klieme & Rakoczy, 2008; Kunter & Voss, 2011). Als zentrales Rahmenkonzept der neuen Unterrichtsforschung hat sich daraufhin das Angebots-Nutzungs-Modell etabliert, das auf Fend (1981) zurückgeht und von Helmke und Weinert (1997) ausgearbeitet wurde (Baumert & Kunter, 2006; Brühwiler et al., 2025; Helmke & Klieme, 2008). Es nimmt an, dass der Unterricht ein Lernangebot darstellt, das nur in dem Maße lernwirksam wird, wie es von den Lernenden durch eigene Lernaktivität genutzt wird (Helmke & Klieme, 2008). Dem folgt, dass unter ungünstigen Bedingungen auf der Seite der Lernenden Unterrichtsangebote suboptimal genutzt werden (Brühwiler et al., 2025). Im Gegensatz zur Annahme des Prozess-Produkt-Paradigmas haben beobachtbare Unterrichtsmerkmale und Lehrerhandlungen keinen direkten Effekt auf schulische Leistungen. Sie initiieren lediglich kognitive und metakognitive Aktivitäten, welche die Lernenden selbstständig und aktiv einsetzen und nutzen können (Brühwiler et al., 2025). Demnach lassen sich interindividuelle Unterschiede im Niveau und der Entwicklung schulischer Leistungen durch eine Vielzahl verschiedener Einflussfaktoren und Kontexte erklären, die das Lernpotenzial des Einzelnen definieren (Brühwiler et al., 2025; Helmke & Klieme, 2008).

Angestoßen durch Kounins Untersuchungen zur Klassenführung verlagerte sich der Fokus der Unterrichtsforschung zunehmend von der Analyse äußerlich beobachtbarer Unterrichtsmerkmale hin zu den tieferliegenden Interaktions- und Prozessstrukturen des Unterrichts (Klieme, 2006). Mit der Unterscheidung zwischen Sichtstrukturen und Tiefenstrukturen etablierte sich in der deutschsprachigen Unterrichtsforschung ein weiterer theoretischer Konsens (Begrich et al., 2023; Oser & Baeriswyl, 2002; Seidel, 2003). Sichtstrukturen beziehen sich dabei auf leicht beobachtbare, äußere methodische und organisatorische Gestaltungsmerkmale sowie strukturelle Rahmenbedingungen des Unterrichts. Tiefenstrukturen hingegen beziehen sich

auf die eigentlichen Prinzipien der Lernwirksamkeit, die in aller Regel nicht direkt beobachtbar, sondern lediglich erschließbar sind (Brühwiler et al., 2025; Kunter & Voss, 2011).

Vor diesem Hintergrund entwickelte die Forschung ein Modell, das Tiefenstrukturen empirisch handhabbar macht und Befunde über Fächer und Studien hinweg vergleichbar bündelt. Um die Vielzahl empirischer Befunde zu systematisieren und Unterrichtsqualität sparsam zu konzeptualisieren, wurde daher das Modell der drei Basisdimensionen entwickelt. Das Modell entstand im Rahmen der deutschen Erweiterung der TIMSS-Videostudie (Third International Mathematics and Science Study) (1995), um die Komplexität des Unterrichts als Forschungsgegenstand zu reduzieren (Klieme & Rakoczy, 2008; Praetorius et al., 2020b; Rothland, 2024). Ziel war die Identifikation eines wissenschaftstheoretisch sparsamen Modells (Praetorius et al., 2020b). Eine faktoranalytische Auswertung von Beobachter*innen-Urteilen brachte drei Dimensionen qualitativen Mathematikunterrichts hervor. Die Faktoren Unterrichts- und Klassenführung, Schülerorientierung sowie KA wurden dann erstmals von Klieme (2001) als Grunddimensionen der Unterrichtsqualität präsentiert (Klieme & Rakoczy, 2008; Klieme et al., 2001; Rothland, 2024). Obwohl diese Kerndimensionen ursprünglich aus der Analyse des Mathematikunterrichts hervorgegangen sind, wird ihnen eine generische, also fachübergreifende sowie schulform- und stufenunabhängige Gültigkeit zugeschrieben (Begrich et al., 2023; Rothland, 2024). Im deutschsprachigen Raum gilt das Modell der drei generischen Basisdimensionen KA, KU und SK seit den 2010er-Jahren als etabliert (Praetorius et al., 2020b; Rothland, 2024). Obwohl das Modell der drei Basisdimensionen in der quantitativen Unterrichtsforschung fest etabliert ist, wird zunehmend auf die Notwendigkeit der Weiterentwicklung hingewiesen. Die empirische Befundlage zeigt, dass die prädiktive Validität nicht durchgehend überzeugend ist und dass Teile der bisherigen Unterrichtsforschung auf vereinfachenden und teilweise unzutreffenden theoretischen Annahmen beruhen (Praetorius et al., 2025; Praetorius et al., 2020b; Rothland, 2024). Dem Modell liegen zudem überwiegend Studien aus dem Mathematik- und Naturwissenschaftsunterricht zugrunde (Brühwiler et al., 2025). Insbesondere Aspekte der fachlichen und fachdidaktischen Qualität sowie der Konsolidierung und Übung sind bislang nicht hinreichend berücksichtigt und stellen somit zentrale Desiderate für die Weiterentwicklung des Modells dar (Brühwiler et al., 2025; Praetorius & Charalambous, 2018; Praetorius et al., 2020b).

2.2. Kognitive Aktivierung

Die KA wird als eine zentrale Basisdimension der Unterrichtsqualität verstanden (Praetorius et al., 2024). Theoretisch und konzeptuell bezieht sich KA auf konstruktivistische Lerntheorien und zielt darauf ab, die Lernenden zum vertieften Nachdenken und zu einer elaborierten Auseinandersetzung mit dem Unterrichtsgegenstand anzuregen (Lipowsky et al., 2009; Praetorius et al., 2020b; Praetorius et al., 2024). Diese Form der Auseinandersetzung kann beispielsweise durch herausfordernde, problemorientierte Aufgabenstellungen oder das Einfordern von Begründungen angeregt werden (Praetorius et al., 2020b). Ziel ist dabei der Aufbau langfristiger, vernetzter und transferfähiger Wissensstrukturen (Kunter & Trautwein, 2013). Das Konzept der KA ist eng in das Angebots-Nutzungs-Modell der Unterrichtsforschung eingebettet (Fend, 2006; Kunter & Voss, 2011). Aus dieser Perspektive wird Unterricht als eine Lerngelegenheit betrachtet, deren Qualität in der Bereitstellung von Lernangeboten liegt. Die KA wird dabei als Angebot der Lehrkraft konzeptualisiert, während die resultierende mentale Auseinandersetzung der Lernenden mit dem Lerngegenstand als kognitive Aktiviertheit die Nutzung des Angebots darstellt (Fauth & Leuders, 2022; Kunter & Voss, 2011; Praetorius et al., 2024). KA auf der Angebotsseite bezeichnet demnach pädagogische Praktiken, Unterrichtsstrategien, Aufgabenstellungen und Interaktionsmuster, die darauf abzielen, ko-konstruktive Auseinandersetzungen mit den Lerninhalten zu ermöglichen (Kunter & Voss, 2011; Rothland, 2024). Unterricht kann demnach immer nur das Potenzial zur KA bieten, da die tatsächliche mentale Aktivität und der erfolgreiche Wissenserwerb von den Lernenden selbst vollzogen werden müssen und von individuellen Voraussetzungen wie Motivation, Interesse und Vorwissen abhängen (Fauth & Leuders, 2022; Klieme, 2020; Kunter & Voss, 2011; Praetorius et al., 2024). Ziel der Lehrkraft ist es, den Unterricht so zu gestalten, dass das Potenzial für KA auf der Angebotsseite maximiert wird (Rothland, 2024). Die empirische Forschung zur KA hat sich bislang vorrangig auf die Angebotsseite konzentriert, während die Nutzungsseite oft vernachlässigt wurde (Praetorius et al., 2024).

2.2.1. Theoretische Verankerung

Die KA ist theoretisch in kognitionspsychologischen und (sozial-)konstruktivistischen Lerntheorien verankert (Klieme & Rakoczy, 2008; Kunter & Voss, 2011; Praetorius et al., 2020b). Eine grundlegende Annahme konstruktivistischer Lerntheorien ist, dass Lernende Wissen nicht direkt vermittelt bekommen, sondern es aktiv und kumulativ auf Basis ihres Vorwissens konstruieren (Kunter & Voss, 2011; Lauterbach et al., 2013). Aus lernpsychologischer Sicht

bedeutet dies, dass bestehende Wissensstrukturen modifiziert, erweitert, vernetzt, umstrukturiert oder neu gebildet werden müssen, um ein tiefgehendes Verständnis zu fördern (Kunter & Voss, 2011). Dies erfordert eine aktive, vertiefte kognitive Auseinandersetzung mit den Inhalten, welche über die bloße Aneignung von deskriptivem Wissen hinausgeht (Lauterbach et al., 2013).

Im Fokus der kognitionspsychologischen Perspektive steht die aktive Informationsverarbeitung im Arbeitsgedächtnis, die die eigentlichen Lernprozesse (Interpretation, Selektion, Organisation, Elaboration, Stärkung, Generierung sowie metakognitives Planen, Überwachen und Regulieren) umfasst (Renkl, 2009). Entscheidend ist hierbei die KA im Sinne von Mayer, welche Prozesse wie das Auswählen, Organisieren und Integrieren von Wissen beinhaltet (Klieme & Rakoczy, 2008; Mayer, 2004). Eng verbunden ist die Idee der fokussierten Informationsverarbeitung (Renkl, 2009). Diese Perspektive differenziert die aktive Verarbeitung, indem sie betont, dass erfolgreiches Lernen nicht nur durch mentale Aktivität an sich erreicht wird, sondern dann, wenn die mentale Aktivität auf die zentralen Konzepte und Prinzipien des Lernbereichs ausgerichtet und fokussiert ist. Eine ungerichtete oder zu breite Aktivität kann hingegen ineffektiv sein (Renkl, 2009). Ein zentraler Mechanismus der KA aus kognitionspsychologischer Sicht ist die Initiierung kognitiver Konflikte (Kunter & Voss, 2011; Rothland, 2024). Diese Konflikte, beispielsweise wenn neue Informationen im Widerspruch zu vorhandenen Vorstellungen (Fehlkonzeptionen) stehen, sind die Voraussetzungen für einen „Conceptual Change“, also die Reorganisation bestehender Wissensstrukturen und somit für kognitive Weiterentwicklung (Kunter & Voss, 2011; Rothland, 2024).

KA ist keine klar definierte oder technokratisch umsetzbare Methode. Vielmehr handelt es sich um einen breiten Fundus an didaktischen Möglichkeiten, mit denen Lernende zum vertieften Nachdenken angeregt und kognitive Prozesse gezielt katalysiert werden können (Fauth & Leuders, 2022). Im Unterricht kann KA hauptsächlich durch die Gestaltung der Lernumgebung, insbesondere durch Aufgabenstellungen und Gesprächsführung, realisiert werden, wenn sie auf das Verstehen und schlussfolgernde Denken der SuS ausgerichtet ist (Klieme, 2020). Aufgaben gelten dann als kognitiv aktivierend, wenn sie Lernende zum vertieften Nachdenken anregen und sie dazu herausfordern, vorhandenes Wissen zu erweitern oder neu zu verknüpfen (Fauth & Leuders, 2022; Lipowsky, 2020; Rothland, 2024). Entscheidend ist, dass sie an das Vorwissen und das Verständnisniveau der SuS anknüpfen, nicht bloß durch die An-

wendung eingeübter Routinen lösbar sind und die Übertragung bekannten Wissens auf neue Situationen erfordern (Fauth & Leuders, 2022; Lauterbach et al., 2013; Lipowsky, 2020). Kognitiv aktivierende Aufgaben lösen idealerweise kognitive Konflikte aus, eröffnen mehrere mögliche Lösungswege oder Lösungen und fördern Problemlöse-, Modellierungs- und Argumentationsprozesse (Fauth & Leuders, 2022; Klieme, 2020; Lipowsky, 2020; Praetorius et al., 2020b; Rothland, 2024). Die empirische Unterrichtsforschung betont dabei, dass nicht allein die Auswahl solcher Aufgaben, sondern insbesondere ihre Umsetzung im Unterricht entscheidend ist. Komplexe Aufgaben verlieren häufig ihr kognitiv aktivierendes Potenzial, wenn sie zu stark gelenkt oder in kleinen, vorgegebenen Schritten abgearbeitet werden (Fauth & Leuders, 2022; Kunter & Voss, 2011).

Zur Förderung von KA tragen darüber hinaus verschiedene pädagogisch-didaktische Strategien bei. Dazu gehört zunächst die Exploration des Vorwissens, bei der Lehrkräfte die vorhandenen Kenntnisse, Erfahrungen und Vorstellungen der Lernenden ermitteln, um darauf aufbauend passende Lernangebote zu gestalten (Baumert et al., 2010; Fauth & Leuders, 2022; Renkl, 2009). Ebenso bedeutsam ist der bewusste und evolutionäre Umgang mit Schülervorstellungen (Rakoczy & Pauli, 2006). Bestehende, möglicherweise fehlerhafte Konzepte sollten im Unterrichtsgespräch aufgegriffen und in produktive Lernprozesse überführt werden, indem die Lehrkraft sie evolutionär zu einem fachlich korrekten Verständnis weiterentwickelt (Fauth & Leuders, 2022; Rakoczy & Pauli, 2006). Auch die Förderung von Selbsterklärungen und Begründungen durch gezielte Fragen und Rückmeldungen erweist sich als wirkungsvoll, da sie Lernende dazu anregt, ihre Gedankengänge auszudrücken, zu reflektieren und zu rechtfertigen, was wiederum tiefere Verarbeitungsprozesse auslöst (Renkl, 2009; Rittle-Johnson et al., 2017). Dies kann durch gezielte diagnostische Fragen und entsprechende Rückmeldungen im Sinne eines formativen Assessments (Black & Wiliam, 1998) erreicht werden (Fauth & Leuders, 2022; Hattie, 2013). Schließlich kann eine dialogisch angelegte Gesprächsführung zur KA beitragen, wenn Lehrkräfte unterschiedliche Perspektiven und Argumente gezielt gegenüberstellen und Widersprüche als Lernanlässe nutzen (Fauth & Leuders, 2022; Kunter & Voss, 2011).

2.2.2. Operationalisierung

Die quantitative Erforschung der beschriebenen Merkmale von KA erfolgt über verschiedene Perspektiven und Datenquellen. Eine Möglichkeit ist die Nutzung externer Beobachter*innen-

Ratings, bei denen entweder eine globale Einschätzung des Anspruchsniveaus oder die Kodierung spezifischer Interaktionsmuster und Äußerungen von SuS auf der Grundlage von Videoanalysen erfolgt (Praetorius et al., 2024). Weitere Methoden umfassen Fragebögen zur Befragung von Lehrkräften und SuS sowie die Analyse von Unterrichtsartefakten wie Hausaufgaben oder Klassenarbeiten zur Bewertung des kognitiven Potenzials (Praetorius et al., 2024). Die Erfassung der tatsächlichen kognitiven Aktiviertheit ist methodisch herausfordernd, da sie interne mentale Prozesse betrifft (Fauth & Leuders, 2022). Mögliche Zugänge sind Selbstberichte der SuS, die die Verarbeitungstiefe und gedankliche Auseinandersetzung abbilden, sowie qualitative Ansätze, bei denen Merkmale wie Meldeaktivität, Körperspannung und Mimik als Indikatoren für kognitive Beteiligung identifiziert werden (Praetorius et al., 2024).

2.2.3. Empirische Evidenz und fachliche Differenzierung

Die Dimension der KA hat sich in der empirischen Unterrichtsforschung als ein robuster und wirkungsmächtiger Prädiktor für den Lernerfolg von SuS erwiesen (Baumert et al., 2010; Klieme et al., 2001; Kunter et al., 2006; Lipowsky et al., 2009). Bereits in der TIMSS-Video studie wurde deutlich, dass KA der einzige Faktor ist, der in einem deutlichen Zusammenhang mit den Unterschieden in den Lernzuwächsen zwischen den Klassen stand (Fauth & Leuders, 2022; Klieme et al., 2001). Auch die Ergebnisse der COACTIV-Studie (Cognitive Activation in the Classroom) zeigen, dass das Potenzial zur KA eng mit der Entwicklung mathematischer Kompetenzen verbunden ist (Baumert et al., 2010; Kunter & Voss, 2011). Dabei zeigte sich, dass nicht nur die Qualität und Komplexität der Aufgaben entscheidend für die Anregung tiefergehender Denkprozesse ist, sondern auch die Art und Weise, wie diese im Unterricht eingesetzt werden (Fauth et al., 2014; Fauth & Leuders, 2022). Bei gleichzeitiger Betrachtung kognitiver und motivational-emotionaler Zielkriterien zeigte sich, dass die KA (neben der SK) als entscheidend für die kognitive Leistungsentwicklung (Mathematikleistung) galt (Helmke & Klieme, 2008). Die motivationale und emotionale Entwicklung der Lernenden hingegen wird stärker von der KU beeinflusst (Kunter & Voss, 2011).

Obwohl das Modell der drei Basisdimensionen ursprünglich als generisch gültiger Rahmen entwickelt wurde, betonen neuere Untersuchungen die Notwendigkeit einer genaueren fachlichen Differenzierung (Klieme & Rakoczy, 2008; Praetorius et al., 2018; Praetorius et al., 2020b; Rothland, 2024). Viele empirische Befunde stammen aus dem Mathematik- und Naturwissenschaftsunterricht, wodurch das Konzept der KA stark von diesen Fächern geprägt ist

(Klieme, 2006; Praetorius et al., 2020b). Die Übertragung dieses Verständnisses auf sprachliche, ästhetische oder sozialwissenschaftliche Lernbereiche erfordert jedoch Anpassungen (Helmke & Klieme, 2008; Klieme & Rakoczy, 2008). Während im Mathematikunterricht logisches Denken und strukturierte Problemlösung im Vordergrund stehen, liegt der Schwerpunkt in Fächern wie Deutsch oder Englisch stärker auf interpretativem und kommunikativem Verstehen (Helmke & Klieme, 2008). Je nach Fach muss also unterschiedlich definiert werden, was KA bedeutet (Klieme & Rakoczy, 2008). Im Sportunterricht wird beispielsweise von einer kognitiv-motorischen oder ästhetischen Aktivierung gesprochen, im Literaturunterricht eher von einer kognitiv-emotionalen Aktivierung (Begrich et al., 2023). Diese Unterschiede verdeutlichen, dass die KA immer im Zusammenhang mit den fachlichen Zielen und Inhalten betrachtet werden muss. Das Konzept der drei Basisdimensionen weist trotz theoretischer Verankerung und empirischer Fundierung blinde Flecken auf (Praetorius et al., 2020b). Obwohl das Modell die KA in ihren Kernaspekten abdeckt, fehlt eine systematische Berücksichtigung anderer relevanter Aspekte wie die Unterstützung des Übens und Konsolidierens als Teil des Angebots zur KA (Begrich et al., 2023; Praetorius et al., 2020b). Zukünftige Forschungsbemühungen müssen daher die theoretische und methodische Ausdifferenzierung der KA vorantreiben und das Zusammenspiel mit fachspezifischen Theorien und Lernzielen präzisieren (Begrich et al., 2023; Klieme & Rakoczy, 2008; Praetorius et al., 2020b).

2.3. Strukturierte Klassenführung

Die SK stellt eine zentrale Dimension der Unterrichtsqualität dar und gilt im Rahmen der empirischen Unterrichtsforschung als einer der einflussreichsten Faktoren für den Lernerfolg von SuS (Gold et al., 2013; Hattie, 2013; Kunter & Voss, 2011; Ophardt et al., 2017; Ophardt & Thiel, 2008; Seidel, 2009). SK ist, im Rahmen der theoretischen Annahmen, dass Unterricht ein Angebots-Nutzungs-Modell darstellt, eine zentrale Komponente der Angebotsseite (Begrich et al., 2023; Kunter & Voss, 2011). Die aktive und gestalterische Rolle der Lernenden bei der Nutzung des Angebots spiegelt dabei konstruktivistische Vorstellungen wider (Klieme & Rakoczy, 2008). SK wird ebenfalls als notwendige Voraussetzung oder Stützfunktion für die Wirksamkeit anderer Dimensionen eines lernwirksamen Unterrichts betrachtet (Gold et al., 2013; Ophardt & Thiel, 2008). Die zentrale Funktion der SK besteht in der Herstellung und Aufrechterhaltung von Lerngelegenheiten und einer angemessenen Lernumgebung für SuS (Emmer & Stough, 2001; Gold et al., 2013). Sie dient zur Herbeiführung von positivem und

erwünschtem Verhalten und der Maximierung der bereitgestellten aktiven Lernzeit (Seidel, 2009). Konkret zielt SK darauf ab, den Unterricht so zu steuern, dass möglichst wenige Störungen auftreten, alle SuS am Lernprozess und Unterrichtsgeschehen beteiligt sind und die Unterrichtszeit effektiv genutzt werden kann (Rothland, 2024; Seidel, 2009).

2.3.1. Theoretische Verankerung

Die theoretische Fundierung der SK beruht auf unterschiedlichen wissenschaftlichen Traditionen, vor allem auf der empirischen Unterrichtsforschung und der pädagogischen Psychologie. Einen zentralen Ausgangspunkt bildet der ökologisch-psychologische Ansatz von Jacob Kounin, der in den 1970er-Jahren die systematische Erforschung effektiver Klassenführung begründete (Ophardt et al., 2017). Kounin verlagerte den Blick von reaktiven Disziplinierungsmaßnahmen hin zu einem proaktiven und präventiven Verständnis von Unterrichtssteuerung (Klieme & Rakoczy, 2008; Kunter & Voss, 2011; Ophardt & Thiel, 2008). Seine Arbeit zeigte, dass die Qualität der Klassenführung weniger von Reaktionen oder Sanktionen auf Störungen, sondern vielmehr von der störungspräventiven Organisation des Unterrichts abhängt (Klieme & Rakoczy, 2008). Zu den Schlüsselmerkmalen zählen die Allgegenwärtigkeit (Withitness) der Lehrkraft und die Überlappung (Overlapping), also die Fähigkeit, den SuS zu vermitteln, jederzeit über ihr Verhalten informiert zu sein, und die gleichzeitige Überwachung mehrerer Abläufe im Klassenzimmer (Kounin, 1976; Kunter & Voss, 2011). Weitere wichtige Konzepte effektiver SK sind die Reibungslosigkeit (Smoothness), der Schwung (Momentum) und das Management von Übergängen (Managing Transitions), also die Vermeidung unnötiger Unterbrechungen und Leerlauf sowie der Erhalt eines flüssigen Unterrichtsablaufs (Seidel, 2009). Auch die Fähigkeit zur Gruppenmobilisierung (Group Focus), also die Konzentration der Aufmerksamkeit auf die gesamte Klasse und die Einbindung aller Lernenden, gilt als zentrales Merkmal effektiver SK (Seidel, 2009). Schließlich betont Kounin die Bedeutung von Abwechslung (Variety) und kognitiver Herausforderung (Challenge) in Lernaktivitäten, um das Interesse der SuS aufrechtzuerhalten und Störungen vorzubeugen (Kounin, 1976; Seidel, 2009).

Ein weiterer theoretischer Zugang ergibt sich aus dem ökologischen beziehungsweise kontextualistischen Ansatz von Walter Doyle (1986). Doyle beschrieb Unterricht als komplexe soziale Situation, die durch Strukturmerkmale wie Multidimensionalität, Simultaneität, Unvorhersagbarkeit, Öffentlichkeit und Historizität gekennzeichnet ist (Baumert & Kunter, 2006;

Doyle, 1986; Kunter & Voss, 2011). In diesem Verständnis wird SK als die Steuerung von Aktivitätsstrukturen und als Herstellung sozialer Ordnung gesehen (Ophardt et al., 2017). Lehrkräfte müssen hier die Vielzahl paralleler Ereignisse im Klassenzimmer koordinieren, Routinen etablieren und eine Balance zwischen Kontrolle und Flexibilität finden, um stabile Interaktionsmuster, soziale Ordnung und Kooperation zu schaffen (Doyle, 1986; Ophardt & Thiel, 2008).

Der handlungstheoretische Ansatz, der vor allem durch die Arbeiten von Carolyn Evertson und Edmund Emmer geprägt wurde, betrachtet die Lehrkraft als zentrale Gestalterin sozialer Verhaltenserwartungen (Ophardt & Thiel, 2008). Klassenmanagement umfasst in diesem Zusammenhang die Planung und Einführung von Regeln und Routinen, die klare Strukturen für wiederkehrende Unterrichtssituationen schaffen und Störungen vorbeugen (Kunter & Voss, 2011; Ophardt & Thiel, 2008). Dadurch wird die Komplexität des Unterrichtsgeschehens reduziert und das Handeln aller Beteiligten vorhersehbarer (Ophardt & Thiel, 2008). Erfolgreiche Lehrkräfte formulieren ihre Erwartungen frühzeitig (zu Beginn des Schuljahres), kommunizieren sie klar und üben gewünschte Verhaltensweisen gemeinsam mit den Lernenden ein (Ophardt & Thiel, 2008; Seidel, 2009).

Einflussreich für die SK ist außerdem die Arbeit „Classroom management that works: Research-based strategies for every teacher“ von Robert und Jayna Marzano aus dem Jahr 2003. In ihrer Metaanalyse bestätigten sie im Wesentlichen die Ergebnisse von Kounin, zeigten jedoch zusätzlich, dass auch Sanktionen wirksam sein können, wenn sie angemessen eingesetzt werden. Den wichtigsten Einflussfaktor sehen Marzano und Marzano im Mental Set der Lehrkraft, also in einer Haltung, die durch situatives Bewusstsein, Selbstkontrolle und emotionale Ausgeglichenheit geprägt ist. Lehrkräfte sollten demnach auf Fehlverhalten ruhig und sachlich reagieren, ohne es „persönlich“ zu nehmen (Marzano & Marzano, 2003).

2.3.2. Operationalisierung

In der quantitativen Unterrichtsforschung wird SK in der Regel auf mehreren Ebenen erfasst, um der Komplexität des Konstrukts gerecht zu werden. Die Datenerhebung erfolgt meist multimodal und multikriterial, das heißt, sie bezieht verschiedene Perspektiven und Informationsquellen ein (Kunter & Voss, 2011; Seidel, 2009). Ein zentraler Zugang sind die Einschätzungen der SuS, die mithilfe standardisierter Fragebögen Auskunft über ihre Wahrnehmung der SK geben. Diese Schülerberichte werden häufig auf Klassenebene aggregiert, um ein Ge-

samtbild des wahrgenommenen Unterrichtsklimas zu erhalten (Seidel, 2009). Ergänzend dazu werden Berichte von Lehrkräften eingesetzt, in denen sie die intendierte Anlage ihres Unterrichts sowie die Qualität ihrer SK selbst einschätzen (Kunter & Voss, 2011). Eine weitere, besonders aufschlussreiche Methode sind externe Beobachtungen und Videoanalysen, bei denen geschulte Beobachter*innen das Unterrichtsgeschehen anhand festgelegter Kriterien auswerten (Kunter & Voss, 2011; Seidel, 2009). Dabei werden sowohl niedrig inferente als auch hoch inferente Beobachtungssysteme verwendet, um die prozessbezogenen Aspekte der SK wie Allgegenwärtigkeit, Strukturierung und Gruppenfokus möglichst zuverlässig zu erfassen (Gold et al., 2013; Ophardt & Thiel, 2008). Die empirische Forschung fasst SK als ein vielschichtiges Konstrukt (Syndrom) auf, das verschiedene Aspekte umfasst (Seidel, 2009). Dazu gehört das Verhaltensmanagement, das auf die Prävention und den gezielten Umgang mit Störungen abzielt (Rothland, 2024). Die Messung erfolgt oft über Skalen zur Häufigkeit von Störungen (negativ gepolt) und die effektive Behandlung von Störungen (Rothland, 2024; Seidel, 2009). Eine weitere Dimension betrifft das Zeitmanagement und die Strukturierung des Unterrichts. Im Mittelpunkt steht die Frage, wie die verfügbare Lernzeit optimal genutzt werden kann, um Leerlauf zu vermeiden und die aktive Lernzeit (Time on Task) zu maximieren (Lipowsky et al., 2009; Rothland, 2024). Eine klare Strukturierung des Unterrichtsablaufs und der Inhalte sowie das Etablieren klar definierter Regeln tragen entscheidend dazu bei, dass die Lernenden wissen, was von ihnen erwartet wird und wie sie ihren Lernprozess gestalten können (Lipowsky et al., 2009; Seidel, 2009).

Ein systematischer Bezugsrahmen zur Beschreibung dieser Kompetenzen findet sich im Modell KODEK (Kompetenz des Klassenmanagements), das drei verschiedene Bereiche des Klassenmanagements unterscheidet. Es umfasst das Management des Schülerverhaltens (Regeln, Interventionen), das Management der Instruktion (Prozesse, Zeitnutzung) sowie das Management der Lehrer-Schüler-Beziehung (Arbeitsbündnis, Konfliktlösung) (Ophardt et al., 2017). Die empirische Erfassung von SK bleibt jedoch herausfordernd, da erfolgreiche Klassenführung häufig implizit geschieht (Ophardt & Thiel, 2008) und das Nichtauftreten unerwünschter Ereignisse (Störungen oder Unterbrechungen) selbst als Indikator für die Wirksamkeit eines guten Klassenmanagements verstanden wird (Kunter & Voss, 2011).

2.3.3. Empirische Evidenz und fachliche Differenzierung

Ergebnisse aus der empirischen Forschung heben immer wieder die zentrale Bedeutung der SK für die Qualität von Unterricht und Lernerfolgen hervor. Sie gilt als ein robuster und wirkungsvoller Prädiktor für den Lernfortschritt und die Effizienz des Unterrichtsgeschehens (Doyle, 1986; Emmer & Stough, 2001; Hattie, 2013; Helmke & Weinert, 1997; Marzano & Marzano, 2003; Seidel & Shavelson, 2007). Die TIMSS-Studie hebt beispielsweise SK als eine notwendige Bedingung für eine gelingende KA hervor (Klieme et al., 2001). Die COACTIV-Studie zeigte außerdem, dass die Effizienz der SK nach dem Potenzial zur KA den größten Einfluss auf die Mathematikleistung der SuS hatte (Brunner et al., 2006; Gold et al., 2013). Darüber hinaus zeigte sich, dass eine gut strukturierte und störungsarme Unterrichtsorganisation nicht nur die fachliche Entwicklung der Lernenden unterstützt, sondern auch deren Motivation und Freude am Lernen fördert (Kunter et al., 2007; Kunter & Voss, 2011). Dabei spielt die Maximierung der effektiven Lernzeit (Time on Task) eine entscheidende Rolle für die Leistungsentwicklung von Lernenden. In Klassen, die durch eine klare Struktur, transparente Abläufe und ein hohes Maß an Verlässlichkeit gekennzeichnet waren, erzielten die SuS höhere Leistungsniveaus und entwickelten gleichzeitig ein positiveres Verhältnis zum Lernen (Kunter & Voss, 2011).

Metaanalytische Befunde weisen zudem darauf hin, dass die Wirksamkeit einzelner Unterrichtsmerkmale von ihrer Proximalität zu den tatsächlichen Lernaktivitäten der SuS abhängt (Seidel, 2009; Seidel & Shavelson, 2007). Wird SK in diesem Zusammenhang als eher distales Merkmal verstanden, das zwar indirekt mit den Lernprozessen verbunden ist, diese jedoch maßgeblich beeinflusst, indem es die Rahmenbedingungen für konzentriertes und kontinuierliches Arbeiten schafft, entstehen relativ geringe messbare Effekte auf das Lernen der SuS (Seidel, 2009). SK im Sinne des Managements von Lernzeit und Begleitung in Lernprozessen wird hingegen als mittelbar unterstützend angesehen und erzielt moderate Effekte auf das Lernen der SuS (Seidel, 2009).

Obwohl SK als generische Dimension konzipiert ist, die unabhängig von Fach, Schulform oder Jahrgangsstufe relevant ist, wird zunehmend diskutiert, inwiefern sie fachlich differenziert betrachtet werden sollte (Begrich et al., 2023). Studien zeigen, dass SK über verschiedene Fächer (Deutsch, Englisch und Mathematik) korreliert, eine hohe Stabilität und vergleichbare Bedeutung aufweist (Klieme et al., 2008; Seidel et al., 2006). Dennoch deuten Untersu-

chungen darauf hin, dass sich die konkrete Ausprägung und Relevanz der SK in Abhängigkeit vom jeweiligen Fach unterscheiden kann (Begrich et al., 2023; Klieme & Rakoczy, 2008). So spielt im Fach Sport beispielsweise die Gewährleistung von Sicherheit und Aufmerksamkeit eine besondere Rolle, während im Sprachunterricht kommunikative Prozesse und der Umgang mit unterschiedlichen Sozialformen stärker im Vordergrund stehen (Begrich et al., 2023). Die Analyse fachspezifischer Aktivitätsstrukturen ist daher notwendig, um die Wechselwirkungen zwischen fachlicher Instruktion und SK besser zu verstehen (Ophardt & Thiel, 2008).

Zudem stellen der Wandel moderner Unterrichtsstrukturen und gesellschaftliche Veränderungsprozesse eine Herausforderung für die Erforschung und Umsetzung von SK dar (Begrich et al., 2023). In offenen Lernumgebungen mit flexiblen Gruppenkonstellationen, individualisierten Lernwegen und kooperativen Lernformen verändert sich die Rolle der Lehrkraft und damit auch die Bedeutung der SK (Ophardt & Thiel, 2008). In solchen Kontexten steht weniger die Kontrolle des Unterrichtsablaufs im Vordergrund, sondern vielmehr die Fähigkeit der Lehrkraft, flexibel auf das Geschehen im Klassenzimmer zu reagieren, Lernprozesse adaptiv zu begleiten und situativ zu steuern (Begrich et al., 2023; Seidel, 2009).

2.4. Konstruktive Unterstützung

Die KU, auch bekannt unter früheren Bezeichnungen wie Schülerorientierung, unterstützendes Unterrichtsklima oder unterstützendes Sozialklima, bildet eine der drei generischen Basisdimensionen der Unterrichtsqualität (Klieme, 2006; Praetorius et al., 2020b). Die KU umfasst konzeptionell zwei Subfacetten (Klieme, 2020). Zum einen bezieht sie sich auf die emotionale und motivationale Unterstützung, die die Qualität der Beziehung zwischen Lehrkraft und SuS in den Mittelpunkt stellt (Rothland, 2024). Sie zeigt sich in einem respektvollen, geduldigen und wertschätzenden Verhalten, insbesondere im Umgang mit Fehlern oder Verständnisproblemen. Auch die Reaktionen und Verhaltensweisen der Lehrkraft bei persönlichen oder sozialen Schwierigkeiten der Lernenden spielen eine zentrale Rolle, da sie das Wohlbefinden und die Motivation der SuS nachhaltig fördern (Kunter & Voss, 2011).

Zum anderen umfasst die KU methodisch-didaktische Aspekte, die auf den Lernprozess selbst bezogen sind. Dazu zählen Hilfestellungen (Scaffolding) beim Wissenserwerb, die Anpassung an individuelle Lernvoraussetzungen, formatives Assessment, Feedback und positive Fehlerkultur (Hattie & Timperley, 2007; Rothland, 2024; Sliwka et al., 2022). Diese Merkmale sol-

len dazu beitragen, dass Unterricht adaptiv gestaltet wird und die individuellen Lernprozesse der SuS bestmöglich unterstützt werden (Sliwka et al., 2022).

Im Rahmen des Angebots-Nutzungs-Modells lässt sich die KU der Angebotsseite zuordnen. In diesem Zusammenhang übernimmt die KU eine zentrale Rolle für die Motivationsförderung (Klieme & Rakoczy, 2008; Praetorius et al., 2020b). Die KU beeinflusst demnach die affektiven und motivationalen Prozesse der Lernenden, insbesondere durch die Erfüllung psychologischer Grundbedürfnisse (Deci & Ryan, 1993), was wiederum zu Leistungs- und Motivationssteigerung führt (Klieme & Rakoczy, 2008).

2.4.1. Theoretische Verankerung

Die KU stützt sich auf zentrale psychologische und lerntheoretische Ansätze, insbesondere auf die Selbstbestimmungstheorie (SBT) sowie auf konstruktivistische Prinzipien des Lehrens und Lernens. Die SBT von Deci und Ryan gilt als eine der bedeutendsten psychologischen Grundlagen für die KU (Deci & Ryan, 1993; Praetorius et al., 2020b). Die SBT geht davon aus, dass Lernen dann besonders erfolgreich ist, wenn drei grundlegende psychologische Bedürfnisse erfüllt werden. Dazu gehören das Erleben von Kompetenz, die Wahrnehmung von Autonomie und das Gefühl sozialer Eingebundenheit (Deci & Ryan, 1993). Kompetenz entsteht durch konstruktives und inhaltsbezogenes Feedback, das den Lernenden ihren Fortschritt sichtbar macht und ihnen ermöglicht, Vertrauen in die eigene Leistungsfähigkeit zu entwickeln (Deci & Ryan, 1993; Praetorius et al., 2020b). Autonomie wird gefördert, wenn Lehrkräfte Wahlmöglichkeiten eröffnen, individuelle Hilfestellungen bieten, Eigeninitiative zulassen und die Lernenden aktiv in Entscheidungsprozesse einbinden (Deci & Ryan, 1993; Praetorius et al., 2024; Sliwka et al., 2022). Soziale Eingebundenheit entsteht durch ein wertschätzendes Unterrichtsklima und durch positive, verlässliche Beziehungen zwischen Lehrenden und Lernenden (Praetorius et al., 2020b).

Die methodisch-didaktische Komponente der KU steht in engem Zusammenhang mit konstruktivistischen und sozial-konstruktivistischen Lerntheorien. Ein zentrales Konzept in diesem Zusammenhang ist Scaffolding, also die adaptiv-prozessuale Bereitstellung temporärer Unterstützung, die über den Lernprozess hinweg sukzessive reduziert wird, sobald die Lernenden zunehmend selbstständig agieren können (Sliwka et al., 2022). Ziel dieser Form der Unterstützung ist es, Lernanforderungen so zu gestalten, dass sie für die SuS bewältigbar bleiben, ohne ihnen dabei zu viel Autonomie zu entziehen (Praetorius et al., 2024; Sliwka et

al., 2022). Dies kann etwa durch die Strukturierung komplexer Aufgaben oder durch gezieltes Eingreifen bei Verständnisproblemen erfolgen (Kunter & Voss, 2011). Das Maß der Unterstützung muss feinfühlig und individuell gemäß dem Prinzip „so viel wie nötig, so wenig wie möglich“ gewählt werden, damit die Lernenden genau jene Hilfe erhalten, die sie benötigen, um den Lernprozess selbstständig fortsetzen zu können (Praetorius et al., 2024; van de Pol et al., 2015). Dieses Konzept ist eng mit der Idee der „Zone der nächsten Entwicklung“ nach Wygotski verbunden, die beschreibt, dass Lernende an der Grenze zwischen dem, was sie selbstständig leisten können, und dem, was sie mit Unterstützung bewältigen können, gefördert werden. Scaffolding soll genau diesen Bereich adressieren (Sliwka et al., 2022). In diesem Zusammenhang wird auch die enge Verbindung zur KA deutlich. Effektive Unterstützung erfordert stets, dass Lernprozesse denkaktivierend gestaltet werden. In diesem Bereich verschwimmen die Grenzen zwischen KU und KA, da sich beide Dimensionen in der Qualität adaptiven Unterrichtshandelns überschneiden. Deshalb wird argumentiert, dass die Qualität der KU daran gemessen werden sollte, in welchem Maß sie zur KA beiträgt (Praetorius et al., 2024).

Die Wirksamkeit der KU hängt außerdem in erheblichem Maße von den motivationalen Orientierungen und der Selbstregulationsfähigkeit der Lehrkraft ab. Lehrkräfte, die ihre Arbeit als sinnerfüllt und bedeutungsvoll erleben und die Freude am Unterrichten zeigen, schaffen häufiger eine unterstützende und anregende Lernatmosphäre (Baumert & Kunter, 2006). So konnte beispielsweise gezeigt werden, dass der Enthusiasmus von Mathematiklehrkräften für das Unterrichten selbst in positivem Zusammenhang mit der Qualität der SK und der durch SuS wahrgenommenen KU steht (Baumert & Kunter, 2006).

2.4.2. Operationalisierung

Die empirische Erfassung des Konstrukts KU erfolgt primär über Einschätzungen von Lehrkräften, SuS oder externen Beobachtenden (Begrich et al., 2023). Lehrkräfte schätzen beispielsweise ihre eigene Unterrichtsgestaltung und ihre motivationale Orientierung ein. SuS schätzen die wahrgenommene Unterstützung und das Unterrichtsklima mittels Fragebögen ein (Kunter & Voss, 2011). Wie bei den anderen Basisdimensionen hängt auch die Beurteilung der KU stark von der jeweiligen Perspektive ab. Sie ist daher häufig durch deutliche Abweichungen und Variationen gekennzeichnet, da die Operationalisierung nicht immer einheitlich erfolgt und sich die unterschiedlichen Einschätzungen nicht notwendigerweise auf dasselbe

Konstrukt beziehen (Begrich et al., 2023). Dennoch wird versucht, die KU durch die Differenzierung in konkrete Subfacetten empirisch fassbar zu machen. Diese Facetten beziehen sich beispielsweise auf die Qualität des von der Lehrkraft gegebenen Feedbacks, die individuelle Unterstützung während des Lernprozesses, den wertschätzenden und respektvollen Umgang sowie auf das allgemeine Klassenklima (Fauth et al., 2024).

2.4.3. Empirische Evidenz und fachliche Differenzierung

Das Modell der drei Basisdimensionen verfolgt das Ziel, zentrale Qualitätsmerkmale lernwirksamen Unterrichts systematisch zu bündeln (Rothland, 2024). Die empirische Forschung bestätigt, dass die KU insbesondere im Hinblick auf nicht-kognitive Lernergebnisse eine herausgehobene Bedeutung besitzt. Untersuchungen, wie etwa die COACTIV-Studie, zeigten, dass die persönliche und individuelle Unterstützung der Lernprozesse durch die Lehrkraft einen deutlichen Einfluss auf die emotional-motivationale Entwicklung der SuS hat (Kunter & Voss, 2011). Lernende, die den Unterricht als unterstützend und wertschätzend erleben, entwickeln häufiger ein stärkeres Selbstvertrauen, ein stabileres Interesse an schulischen Inhalten und eine insgesamt positivere Einstellung zum Lernen (Fauth et al., 2024; Kunter & Voss, 2011). Die KU wirkt somit vor allem auf motivationaler und emotionaler Ebene und trägt wesentlich zu einem positiven Unterrichtsklima bei, in dem Lernfreude und Engagement gefördert werden. Im Zusammenhang mit der kognitiven Leistungsentwicklung zeigt sich ein differenziertes Bild. Ergebnisse der COACTIV-Studie deuten darauf hin, dass insbesondere die SK und die KA entscheidende Prädiktoren für Leistungszuwächse darstellen. Die KU stand zwar bei bivariater Betrachtung signifikant mit der Mathematikleistung in Verbindung, erklärte jedoch bei gleichzeitiger Betrachtung aller drei Basisdimensionen keine zusätzliche Varianz (Kunter & Voss, 2011). Dieser Befund verdeutlicht, dass die Dimensionen differentielle Muster in Bezug auf kognitive und emotional-motivationale Merkmale aufweisen.

Obwohl das Modell der Basisdimensionen als generisch konzipiert wurde, wird die Frage der Fachspezifität weiterhin intensiv diskutiert. Besonders für die KA wird betont, dass fachliche Inhalte und Aufgabenkulturen ihre Ausprägung maßgeblich beeinflussen (Fauth & Leuders, 2022; Klieme & Rakoczy, 2008). Im Vergleich dazu gilt die KU konzeptionell als weniger stark fachlich gebunden (Praetorius & Charalambous, 2018). Im Abgleich mit dem Syntheseframework (SF) zeigt sich, dass Teile der KU als generisch einzuordnen sind, insbesondere die sozio-emotionale Unterstützung (z. B. Respekt, Wertschätzung). Andere Aspekte der KU

wie Feedback und Scaffolding überschneiden sich dagegen mit der Dimension des formativen Assessments und weisen damit stärkere fach- und kontextbezogene Anteile auf (Praetorius & Charalambous, 2018; Praetorius et al., 2020b). Im Vergleich zur konzeptionell generischen SK stimmt die Ausprägung der KU bei derselben Lehrkraft zwischen den Fächern Deutsch und Englisch deutlich weniger stark überein als die Ausprägung der SK (Praetorius et al., 2015).

2.5. Fachspezifische Qualitätsmerkmale des Wirtschaftsunterrichts

Wie in den vorangegangenen Kapiteln gezeigt wurde, hat sich das Modell der drei Basisdimensionen als sparsamer, theoretisch fundierter, generischer und empirisch gut belegter Rahmen für die Beschreibung von Unterrichtsqualität etabliert. Zugleich wurde jedoch mehrfach auf seine Grenzen hingewiesen, insbesondere im Hinblick auf die fehlende Berücksichtigung fachspezifischer Besonderheiten (Praetorius & Charalambous, 2018; Praetorius et al., 2018; Praetorius et al., 2020b). Die bereits diskutierte Kritik an der generischen Gültigkeit des Modells verdeutlicht, dass die drei Basisdimensionen zwar notwendige, jedoch keine hinreichenden Bedingungen für qualitativ hochwertigen Unterricht darstellen. Eine valide Analyse von Unterrichtsqualität erfordert daher eine fachspezifische Differenzierung, die es ermöglicht, auch die inhaltlich-methodischen und normativen Besonderheiten einzelner Fächer abzubilden. Als Reaktion auf die Diskussion um die Fachspezifität entwickelten Praetorius und Charalambous (2018) ein erweitertes SF mit dem Ziel, eine integrative Systematisierung generischer und fachspezifischer Dimensionen von Unterrichtsqualität zu ermöglichen. Zu diesem Zweck analysierten und verglichen sie zwölf international etablierte Beobachtungsframeworks und synthetisierten daraus insgesamt sieben Dimensionen von Unterrichtsqualität (Platz et al., 2025; Praetorius & Gräsel, 2021; Praetorius et al., 2020b).

- (1) Die „Auswahl und Thematisierung von Inhalten und Fachmethoden“ zielen darauf ab, Lernende mit inhaltlich relevanten und fachlich angemessenen Gegenständen in Kontakt zu bringen.
- (2) Die „Kognitive Aktivierung“ regt Prozesse für vertiefte Auseinandersetzungen mit den Lerninhalten an.
- (3) Die „Unterstützung des Übens“ dient der Festigung und Konsolidierung erworbener Kenntnisse.

- (4) Das „Formative Assessment“ ermöglicht die fortlaufende Rückmeldung über Lernfortschritte und bildet die Grundlage zur gezielten Anpassung von Lehr-Lern-Prozessen.
- (5) Die „Unterstützung des Lernens aller Schüler*innen“ umfasst Aspekte wie Differenzierung und adaptive Lernbegleitung.
- (6) Die „Sozio-emotionale Unterstützung“ betrifft das Schaffen eines wertschätzenden und sicheren Lernklimas.
- (7) Die „Klassenführung“ bildet die organisatorische und prozessuale Grundlage, um störungsfreie Lerngelegenheiten zu gewährleisten.

Während die ersten vier Dimensionen sowohl generische als auch fachspezifische Elemente enthalten, sind die übrigen drei Dimensionen überwiegend generischer Natur (Praetorius et al., 2020a). Damit verbindet das SF in systematischer Weise fachübergreifende und fachgebundene Aspekte von Unterrichtsqualität (Praetorius & Gräsel, 2021; Praetorius et al., 2020a). Das in Abb. 1 dargestellte MAIN-TEACH-Modell (multi-layered and integrated in conceptualizing the quality of teaching) nach Charalambous und Praetorius (2020) stellt eine konzeptuelle Weiterentwicklung des erweiterten SF dar (Praetorius & Gräsel, 2021).




Abb. 1: Das MAIN-TEACH-Modell (Praetorius & Gräsel 2021, p. 182)

Durch die theoretisch und empirisch engere Verknüpfung von Unterrichtsdimensionen mit den Lernprozessen (learning processes) der SuS sowie den angestrebten Ergebnissen (outcomes) bildet dieses Modell eine zentrale Grundlage für den fachübergreifenden Diskurs in der

Unterrichtsforschung (Platz et al., 2025; Praetorius & Gräsel, 2021). Es ordnet die Dimensionen der Unterrichtsqualität aus dem SF hierarchisch in drei Funktionsebenen, um ihre wechselseitige Beziehung sichtbar zu machen (Praetorius & Gräsel, 2021):

- I. Die innerste Schicht umfasst sinngemäß die Dimensionen (1) - (4) des SF und beschreibt die Aspekte, die unmittelbar auf die Förderung und Steuerung der Lernprozesse abzielen und damit den Kern unterrichtlicher Wirksamkeit bilden.
- II. Die mittlere Schicht integriert die Dimensionen (6) und (7) des SF sowie die „Unterstützung der Eigenverantwortung für das Lernen“ und umfasst dadurch Merkmale, die nicht auf den Lernprozess selbst gerichtet sind, jedoch die notwendigen Rahmenbedingungen für gelingendes Lernen schaffen.
- III. Die äußerste Schicht leitet sich aus der Dimension (5) des SF ab und fungiert als dimensionsübergreifendes Qualitätsmerkmal.

Das MAIN-TEACH-Modell postuliert durch seine Einbettung in das Angebots-Nutzungs-Modell eine direkte Verbindung zwischen der innersten Schicht (Kernebene) der Unterrichtsdimensionen und den dadurch angestoßenen Lernprozessen der SuS (Praetorius & Gräsel, 2021). Die Integration des SF im MAIN-TEACH-Modell erlaubt somit eine differenzierte Analyse, indem es sowohl generische als auch fachspezifische Aspekte der Unterrichtsqualität explizit berücksichtigt und deren vermuteten Wirkmechanismen auf die vielschichtigen Lernergebnisse strukturiert darstellt (Platz et al., 2025; Praetorius & Gräsel, 2021).

Trotz der zunehmenden Bedeutung des Wirtschaftsunterrichts im allgemeinbildenden Schulsystem und seiner traditionellen Verankerung im berufsbildenden Bereich fehlte in der Wirtschaftsdidaktik lange Zeit eine eigenständige, fachspezifische Forschung zur Unterrichtsqualität (Platz et al., 2025). Bisherige Arbeiten haben sich bislang überwiegend implizit mit diesem Thema befasst, etwa durch die Untersuchung des Professionswissens von Lehrkräften oder die Analyse von Sichtstrukturen. Andere Untersuchungen richteten ihren Fokus lediglich auf den fachbezogenen Bezug generischer Teilaspekte des SF oder auf die fachspezifische Ausdifferenzierung einzelner Dimensionen (für eine detaillierte Übersicht der empirischen Beiträge zur Unterrichtsqualität im Wirtschaftsunterricht siehe Platz et al., 2025, p. 220). Platz et al. (2025) greifen diese konzeptionelle Lücke auf und definieren auf Grundlage etablierter fachdidaktischer Konzepte und Prinzipien der Wirtschaftsdidaktik sowie der Zielsetzung des Wirtschaftsunterrichts an allgemeinbildenden Schulen, die unter anderem in der Förderung von

Mündigkeit und Handlungsfähigkeit der Lernenden in ökonomisch geprägten Lebenssituationen besteht (Loerwald, 2020), die drei spezifischen Qualitätsmerkmale „Aktualität und Lebensweltbezug“, „Handlungsorientierung“ sowie „Urteilsbildung und Entscheidungsfindung“.

2.5.1. Aktualität und Lebensweltbezug

Das Merkmal „Aktualität und Lebensweltbezug“ beschreibt die Auswahl exemplarischer Unterrichtsthemen, die ihren Ausgangspunkt sowohl in ihrer Aktualität als auch in Bezügen zur Lebenswelt der Lernenden nehmen. Im SF ist sie daher als fachspezifische Ausdifferenzierung der Dimension (1) „Auswahl und Thematisierung von Inhalten und Fachmethoden“ einzuordnen (Platz et al., 2025). Da der Wirtschaftsunterricht wesentlich auf sozialwissenschaftlichen Theorien und empirischen Erkenntnissen beruht, die sich in wirtschaftspolitischen und ökonomischen Alltagssituationen unmittelbar wiederfinden, bietet er besonders günstige Voraussetzungen für Aktualität und Lebensweltbezüge. SuS agieren als wirtschaftlich handelnde Bürger*innen selbst im Wirtschaftssystem. Dadurch sind gegenwartsbezogene und lebensweltnahe Anknüpfungspunkte nicht nur leichter herzustellen, sondern zugleich von höherer Relevanz als in anderen Fachdidaktiken (Böhner & Dolzanski, 2016; Platz et al., 2025). Zum einen liegt die Zielsetzung dieses Ansatzes, der konzeptionell auf dem Lebenssituationsansatz von Steinmann (1997) basiert, in der Befähigung der Lernenden zur mündigen Bewältigung ökonomisch geprägter Lebenssituationen. Zum anderen dient die Aufnahme realer wirtschaftlicher Ereignisse und ihre Verknüpfung mit gesellschaftlich oder medial diskutierten Problemstellungen dazu, die wahrgenommene Relevanz des Faches auf Seiten der Lernenden zu steigern (Platz et al., 2025). Wenn Lernende den Unterrichtsinhalten einen höheren persönlichen Wert beimessen, steigt nach der Erwartungs-Wert-Theorie von Eccles und Wigfield (2002) auch ihre Lernmotivation. Diese gesteigerte Motivation kann sich wiederum positiv auf ihre Leistungsentwicklung auswirken (Eccles & Wigfield, 2002; Trautwein et al., 2012). Dennoch besteht bei einer zu starken Ausrichtung auf Aktualität und Lebensweltbezug die Gefahr, dass die Auswahl fachlicher Inhalte subjektiv verengt oder beliebig wird (Hedtke, 2011; Platz et al., 2025). Eine zu starke Orientierung an der Lebenswelt der Lernenden in Kombination mit der notwendigen didaktischen Reduktion kann im Sinne der Sachantinomie nach Helsper (2023) die innere Sachlogik des Faches gefährden. In der Folge könnte der Unterricht zu einer bloßen „Aktualitätensschau“ (Dubs, 2018, p. 40) werden, statt eine fachlich fundierte Auseinandersetzung zu ermöglichen (Platz et al., 2025). Deshalb ist es wichtig, den Fokus konsequent auf die zugrunde liegenden ökonomischen Theorien und Modelle zu richten, um diese

anschließend flexibel auf spezifische aktuelle Situationen anwenden zu können. Ziel ist es, eine ökonomische Denkweise zu entwickeln, die Lernende befähigt, subjektive Erfahrungen mit formal-objektiven Dimensionen ökonomischer Sachverhalte zu verbinden (Sender, 2017) und darauf aufbauend situationsabhängig, rational, selbstbestimmt und verantwortungsvoll zu handeln (Platz et al., 2025).

2.5.2. Handlungsorientierung

Der Begriff Handlungsorientierung wird im pädagogischen Diskurs in unterschiedlichen Kontexten verwendet. In diesem Zusammenhang wird die Handlungsorientierung primär der Dimension (2) „Kognitive Aktivierung“ des SF zugeordnet, da sie eine Form der aktiven mentalen Auseinandersetzung mit den Lerninhalten und die Entwicklung von Problemlösestrategien darstellt (Platz et al., 2025). Aufgaben der Kategorie „Komplexe Probleme“, bei denen ein unzulänglicher Ausgangszustand durch den Prozess der Problemlösung behoben werden soll, haben dabei ein besonders hohes Potenzial für KA (Riebenbauer et al., 2025; Tulodziecki et al., 2017). Darüber hinaus ist die Dimension (5) des SF „Unterstützung des Lernens aller Schüler*innen“ bedeutsam, da handlungsorientiertes Lernen häufig mit Autonomie und offenen Unterrichtsstrukturen einhergeht (Platz et al., 2025). Daher sind die strukturierte Unterstützung und ein angemessener Grad an instruktionaler Steuerung durch die Lehrkraft, insbesondere für lernschwächere Lernende, von zentraler Bedeutung (Kirschner et al., 2006; Platz et al., 2025). Handlungsorientierung wird domänenübergreifend als eine „selbstständige und interaktive Auseinandersetzung mit Fachinhalten“ (Platz et al., 2025, p. 224) verstanden, die durch ein hohes Maß an lernbezogenen Aktivitäten der Lernenden gekennzeichnet ist. Typischerweise erfolgen Lernhandlungen ausgehend von einer zu bewältigenden Problem- oder Fragestellung. Das zentrale didaktische Leitmodell ist dabei häufig das auf der Handlungsregulationstheorie nach Volpert und Hacker basierende Modell der vollständigen Handlung aus den 1970er-Jahren (Platz et al., 2025). Dieses Modell wird häufig im Kontext der Berufsbildung genutzt und besteht aus sechs zyklisch angeordneten Schritten: (1) Informieren, (2) Planen, (3) Entscheiden, (4) Ausführen, (5) Kontrollieren und (6) Bewerten (Böhner & Dolzanski, 2016; Platz et al., 2025). Die Anwendung dieses Modells dient der Befähigung, spezifische ökonomisch geprägte Berufs- und Alltagssituationen reflektiert zu bewältigen und ist für verschiedene Bildungskontexte geeignet (Platz et al., 2025). Handlungsorientierung wird im Wirtschaftsunterricht vor allem durch komplexe Methoden umgesetzt, die eine selbstständige Auseinandersetzung mit Fachinhalten ermöglichen. Da Lernende reale wirtschaftliche Hand-

lungsfelder nur begrenzt betreten können (z. B. aufgrund fehlender Geschäftsfähigkeit, eingeschränkter Ressourcen oder möglicher finanzieller Risiken), kommen häufig modellhafte und simulierte Lernumgebungen zum Einsatz (z. B. Fallstudien, Serious Games & Simulationen, Lernspiele, Modelle und Übungsfirmen) (Platz et al., 2025). Aktuelle Entwicklungen zeigen zudem, dass digitale Technologien wie Virtual Reality neue Möglichkeiten eröffnen, um fachliches Wissen sowohl auf deklarativer als auch auf prozeduraler Ebene zu fördern (Conrad et al., 2024; Platz et al., 2025).

2.5.3. Urteilsbildung und Entscheidungsfindung

Das Merkmal „Urteilsbildung und Entscheidungsfindung“ lässt sich vorrangig der Dimension (2) „Kognitive Aktivierung“ des SF zuordnen, da Lernende auf Basis fachwissenschaftlicher Erkenntnisse und Kriterien Urteile fällen und Entscheidungen treffen sollen und dabei anspruchsvolle kognitive Prozesse ausgelöst werden (Platz et al., 2025). Solche komplexen Entscheidungsfälle und komplexen Beurteilungsfälle zählen zu den Aufgaben mit dem höchsten Grad an Potenzial für KA (Riebenbauer et al., 2025; Tulodziecki et al., 2017). Darüber hinaus ist die Dimension (6) des SF „Sozio-emotionale Unterstützung“ bedeutsam, da sie den notwendigen Rahmen für eine ergebnisoffene und multiperspektivische Auseinandersetzung mit kontroversen sozioökonomischen Fragestellungen schafft (Platz et al., 2025). Urteilsbildung und Entscheidungsfindung bezieht sich auf die Fähigkeit der Lernenden, komplexe sozioökonomische Fragestellungen argumentativ zu beurteilen und daraus verantwortungsvolle Entscheidungen abzuleiten (Platz et al., 2025). Die Urteilsbildung rückt dabei die kriteriengeleitete Abwägung und Einordnung von Informationen in den Vordergrund, die in einen argumentativ begründbaren Standpunkt münden. Die Entscheidungsfindung schließt an die Urteilsbildung an, indem sie konkrete Handlungsalternativen einbezieht und auf dieser Grundlage eine begründete Entscheidung über konkrete Handlungen ermöglicht (Platz et al., 2025). Für eine fundierte domänenspezifische Urteilsbildung ist die Berücksichtigung von Multiperspektivität zentral. Die Betrachtung eines Gegenstandes aus unterschiedlichen, zunächst nicht definierten Perspektiven ermöglicht es den Lernenden, einen Sachverhalt aus verschiedenen Blickwinkeln zu analysieren und bestehende Sichtweisen kritisch zu hinterfragen (Loerwald, 2008; Platz et al., 2025). Durch die Integration wertbezogener Kriterien wie Legitimität und Nachhaltigkeit entwickeln die Lernenden zudem ein Bewusstsein dafür, dass ökonomische Entscheidungen stets in gesellschaftliche Moralsysteme eingebettet sind und an gesellschaftlich anerkannte Werte gebunden werden müssen (Heid, 2006; Platz et al., 2025; Schramm, 2025).

Inhaltlich erstreckt sich das Merkmal „Urteilsbildung und Entscheidungsfindung“ auf zwei Bereiche. Zum einen auf die Auseinandersetzung mit inhaltsbezogenen Fragestellungen, zum anderen auf die Reflexion ökonomischer Theorien und Modelle (Platz et al., 2025). Im Verständnis der reflexiven Wirtschaftsdidaktik sind die Lernenden darüber hinaus gefordert, auch die Bezugswissenschaften selbst kritisch zu prüfen und die Vielfalt fachwissenschaftlicher Positionen einzubeziehen, um reflektierte Urteile zu bilden (Brahm et al., 2020; Goldschmidt et al., 2018; Platz et al., 2025). Dies fördert wichtige Schritte hin zu einem wissenschaftlich-erkenntniskritischen Habitus (Helsper, 2023) und legt den Grundstein für eine metareflexive Haltung gegenüber Handlungsalternativen (Cramer, 2020). Empirische Arbeiten zur Urteilsbildung und Entscheidungsfindung zeigen, dass in vielen Schulbuchaufgaben keine klare Trennung zwischen persönlichen Meinungsäußerungen und kriterienorientierter Urteilsbildung vorgenommen wird (Weyland & Gross, 2022). Gleichzeitig fällt es Lernenden häufig schwer, multiperspektivische Urteile zu entwickeln (Birke et al., 2022; Platz et al., 2025). Anstatt mit wirtschaftswissenschaftlichem Fachwissen zu argumentieren, greifen sie oftmals auf subjektive Alltagserfahrungen zurück, um Positionen zu begründen oder Entscheidungen abzuleiten (Ackermann & Kavadarli, 2022). Diese Befunde verdeutlichen, wie anspruchsvoll die Ausbildung einer reflektierten ökonomischen Urteilskompetenz ist und wie notwendig eine gezielte Förderung dieser Fähigkeiten im Wirtschaftsunterricht bleibt (Platz et al., 2025).

Während das Modell der Basisdimensionen und seine fachspezifischen Erweiterungen einen theoretisch fundierten Bezugsrahmen für Unterrichtsqualität bereitstellen, stellt sich für die empirische Unterrichtsforschung die zentrale Frage, wie diese Merkmale methodisch angemessen erfasst werden können. Dafür werden im folgenden insbesondere die Video- und transkriptbasierte Erforschung von Unterrichtsqualität thematisiert.

2.6. Erfassung von Unterrichtsqualität

Die Unterrichtsqualitätsforschung zielt darauf ab, das hochkomplexe und dynamische Geschehen (Doyle, 1986) im Unterricht durch die Reduzierung und Separierung auf eine überschaubare Anzahl relevanter Merkmale handhabbar zu machen (Praetorius et al., 2020b; Rothland, 2024). Die Auswahl dieser Merkmale orientiert sich dabei an deren nachweisbarer Relevanz für die Leistungs- oder Motivationsentwicklung der Lernenden (Kleickmann et al., 2019; Praetorius et al., 2020b). Die Tiefenstrukturen des Unterrichts sind dabei die qualitätsrelevanten Merkmale, da sie die direkten Lehr-Lern-Prozesse adressieren und in der Regel

eine größere Erklärungsmacht für Lernzuwächse bieten als die Sichtstrukturen (Hattie, 2013; Kunter & Voss, 2011; Seidel & Shavelson, 2007). Entsprechend werden zentrale Merkmale der Tiefenstruktur häufig als „Dimensionen der Unterrichtsqualität“ gefasst (Helmke, 2009; Kunter & Voss, 2011). Aufgrund der Komplexität des Forschungsfelds und der Tatsache, dass Tiefenstrukturen nicht direkt an einzelnen Verhaltensweisen abzulesen sind, hat die empirische Unterrichtsforschung verschiedene methodische Zugänge zur Datenerhebung und zur Erfassung von Unterrichtsqualität hervorgebracht (Kunter & Voss, 2011). Da es den „Königsweg der Erfassung“ (Kunter & Voss, 2011, p. 91) nicht gibt, wählt die empirische Unterrichtsforschung häufig einen multimethodischen Ansatz, der verschiedene Erhebungsverfahren und Datenquellen kombiniert (Kunter & Voss, 2011). Subjektive Berichte durch Lehrkräfte oder SuS sowie Materialanalyse ermöglichen einen ressourceneffizienten Zugang für die Unterrichtsqualitätsforschung. SuS-Berichte gelten als besonders aussagekräftige Informationsquelle zur Erfassung von Unterstützung und Unterrichtsklima. Sie bilden zudem zentrale Facetten der SK sowie das unmittelbare Erleben der Lernenden differenziert ab (Kunter & Voss, 2011). Dennoch sind die Aussagen von SuS unzureichend, um Abweichungen vom geplanten Inhalt oder das Potenzial zur KA zu beurteilen (Kunter & Voss, 2011). Außerdem haben vor allem jüngere SuS Schwierigkeiten, das konkret Erlebte auf eine generalisierende Einschätzung zu abstrahieren (Gabriel, 2014). Selbstberichte von Lehrkräften sind gut geeignet, um die intendierte Anlage des Unterrichts, die verwendeten Methoden sowie die zentralen Aspekte der SK zu erfassen. Trotzdem sind diese Selbstauskünfte von Lehrkräften nur begrenzt aussagekräftig für die tatsächliche KA (Kunter & Voss, 2011) und anfällig für Verzerrungen, insbesondere durch soziale Erwünschtheit (Gabriel, 2014). Die Analyse von Unterrichtsmaterialien wird hauptsächlich für die Erfassung des Potenzials zur KA herangezogen und kann Rückschlüsse auf die Unterrichtsplanung zulassen, die im Unterrichtsgeschehen selbst kaum sichtbar sind (Gruenkorn, 2020; Kunter & Voss, 2011). Im Gegensatz zu Videoaufzeichnungen oder Live-Beobachtungen bildet die Analyse von Unterrichtsmaterialien jedoch nicht die interaktiven Elemente des Unterrichtsgeschehens ab (Gruenkorn, 2020).

2.6.1. Unterrichtsbeobachtungen

Ein zentraler Zugang der Unterrichtsqualitätsforschung besteht in der Beobachtung von Unterricht durch externe Beobachter*innen, entweder in Form von Live-Beobachtungen oder auf der Grundlage videografiertter Unterrichtssequenzen. Dieses Verfahren gilt als der direkteste

Weg zur Erfassung von Unterrichtsqualität, da es unmittelbare Daten über das tatsächlich stattfindende Unterrichtsgeschehen liefert (Gabriel, 2014).

Innerhalb der quantitativen Unterrichtsforschung wird methodisch zwischen niedrig und hoch inferenten Beobachtungsverfahren differenziert, wobei der Inferenzgrad das Ausmaß interpretativer Schlussfolgerungen beschreibt, die zwischen dem beobachteten Verhalten und seiner kategorialen Zuordnung liegen (Gabriel, 2014; Pauli, 2012). Niedrig inferente Verfahren erfassen dabei die Häufigkeit oder Dauer klar definierter, direkt beobachtbarer Verhaltensweisen, wie etwa Sozialformen oder Zeitnutzung, um objektive Muster der Sichtstrukturen zu quantifizieren. Im Gegensatz dazu zielen hoch inferente Verfahren auf die Einschätzung komplexer Qualitätsdimensionen auf skalierten Instrumenten ab, um die psychologisch-didaktische Tiefenstruktur des Unterrichts kriteriengeleitet zu bewerten (Clausen et al., 2003; Gabriel, 2014; Pauli, 2012). Während hoch inferente Urteile eine höhere Erklärungsmacht für den Lernerfolg besitzen, erfordern sie eine stärkere kognitive Integrationsleistung der Beobachter*innen und sind daher anfälliger für subjektive Beurteilungsfehler als niedrig inferente Kodierungen (Clausen et al., 2003; Gabriel, 2014). Im Hinblick auf die Validität wird hoch inferenten Ratings allerdings ein Vorteil gegenüber niedrig inferenten Beobachtungen zugeschrieben, weil sie stärker theoriegeleitet sind und damit näher an den intendierten Konstrukten ansetzen (Clausen et al., 2003; Gabriel, 2014). Deshalb können hoch inferente Ratings die Basisdimensionen der Unterrichtsqualität unmittelbar operationalisieren (Gabriel, 2014).

Live-Beobachtungen ermöglichen es, Unterrichtsprozesse in Echtzeit zu erfassen und dabei Merkmale sichtbar zu machen, die durch andere Datentypen kaum zugänglich sind. Ihre Stärke liegt vor allem darin, dass die aufgezeichneten Merkmale weitgehend frei von den subjektiven Wahrnehmungen und Interpretationen der beteiligten Akteure (SuS, Lehrkräfte) sind (Clausen, 2002; Gabriel, 2014). Zudem zeigen Studien, dass beobachtungsbasierte Qualitätsmerkmale stärker mit den Lernleistungen der SuS zusammenhängen als Merkmale, die über Fragebögen erhoben werden (Seidel & Shavelson, 2007). Dennoch sind die beobachteten Ereignisse flüchtig und die Möglichkeit zur wiederholten Analyse ist begrenzt. Diese methodische Limitation wird durch den Einsatz videobasierter Beobachtungen aufgehoben, deren größtes Potenzial in der wiederholbaren Betrachtung und Re-Analyse der aufgezeichneten Unterrichtssequenzen liegt (Pauli & Reusser, 2006). Dies ermöglicht es, einen Unterrichtspro-

zess aus unterschiedlichen Perspektiven und unter verschiedenen Fragestellungen zu analysieren (Gabriel, 2014). Ein weiterer zentraler Vorteil liegt im Zugang zu einer Pluralität von gleichzeitig auftretenden Äußerungsmodalitäten und dem simultanen Agieren verschiedener Personen (Herrle & Breitenbach, 2016). Dabei bietet die Videografie nicht nur für die Unterrichtsforschung große Potenziale, sondern auch für die (Aus-)Bildung von Lehrkräften (Kramer et al., 2020). Die Analyse videografiertter Unterrichtssequenzen erleichtert die kritisch-reflexive Auseinandersetzung mit der Lehrpraxis (Seidel, 2022) und ermöglicht es den Studierenden, eine theoriegeleitete Analyse von Unterrichtsprozessen vorzunehmen, ohne dabei dem akuten Handlungsdruck des Klassenzimmers ausgesetzt zu sein (Böhnke et al., 2020; Piwowar et al., 2018). Außerdem können Studierende durch die Betrachtung von Fremdvideos für zentrale Unterrichtsqualitätsmerkmale sensibilisiert werden (Holodynski & Meschede, 2020). Videostudien bieten demnach einige Vorteile, sind aber im Vergleich zu Live-Beobachtungen mit großem zeitlichem, technischem, organisatorischem und kostenintensivem Aufwand verbunden (Gabriel, 2014; Herrle & Breitenbach, 2016). Dabei hängt die Qualität der daraus resultierenden Ergebnisse stark von der Qualität der Produktion der Unterrichtsvideos ab (z. B. Tonqualität, Bildqualität) (Zucker et al., 2020). Außerdem stellen Unterrichtsvideos immer nur einen Teil der Unterrichtsrealität dar. Aufzeichnungen sind abhängig von der Kameraführung, der Positionierung der Mikrofone und dem Bewusstsein der Akteure, dass ihre Handlungen aufgezeichnet werden (Gabriel, 2014). Die Reaktivität auf den Kameraeffekt kann sowohl das Verhalten der Lernenden als auch der Lehrkraft beeinflussen und dadurch der Repräsentativität der Unterrichtssequenz schaden (Gabriel, 2014; Petko et al., 2003). Außerdem sind keine Interaktionen mit den Protagonisten der Videos möglich. Demnach beschränkt sich die Arbeit mit Videos auf das Beobachten und Interpretieren der gezeigten Sequenz im Situationskontext der zusätzlich erhobenen und zur Verfügung stehenden Informationen (Krammer & Reusser, 2005). Die qualitative Unterrichtsforschung unterscheidet idealtypisch drei Arten des methodischen Videoeinsatzes (Reh, 2012). Erstens können Videoaufzeichnungen zur Unterstützung anderer Aufzeichnungsweisen eingesetzt werden. Hierbei dienen Videodaten primär zur Vervollständigung und Verbesserung der Transkription verbaler Interaktionen. Dadurch können Redebeiträge besser einzelnen Sprecher*innen zugeordnet werden oder auffällige Mimik und Gestik im Transkript vermerkt werden (Reh, 2012). Zweitens können Videoaufzeichnungen genutzt werden, um technische Protokolle multimodaler Interaktionsstrukturen zu erstellen. Hier wird ein sehr aufwendiges Transkriptionsverfahren entwickelt, das Ver-

bal- und Gesten-/Mimik-Transkripte, Protokolle sowie Skizzen über die räumlichen Verhältnisse erstellt (Herrle et al., 2010; Reh, 2012). Ziel ist dabei die Rekonstruktion der Entstehung spezifischer Bedeutungen und Ordnungen im sequenziellen Verlauf und in der Simultanität materiell-körperlicher Konstellationen (Raum, Artefakte und Materialien im Klassenzimmer, Körperbewegungen) (Fritzsche & Wagner-Willi, 2011; Reh, 2012). Drittens wird Videografie im Rahmen von Ethnographischen Studien eingesetzt. Dabei wird häufig eine flexible Handkamera eingesetzt, die auf kleine Ausschnitte des Unterrichtsgeschehens ausgerichtet wird. Im Fokus dieser Untersuchungen stehen jene Aktivitäten und Interaktionen der SuS, die nicht direkt mit dem Lehr-Lern-Prozess zu tun haben (Pausen, Gespräche mit den Sitznachbar*innen, Berührungen) (Reh, 2012).

2.6.2. Unterrichtstranskripte

Die Transkription stellt den Prozess der Verschriftlichung des audiovisuellen Rohmaterials dar und bildet in der videobasierten Unterrichtsforschung häufig die unerlässliche Grundlage für eine detaillierte, theoriegeleitete Analyse (Lenske et al., 2020). Sie fungiert als entscheidender Schritt der Materialisierung, in dem sie das flüchtige und komplexe Geschehen im Unterricht in eine statische, analytisch bearbeitbare Textform überführt, die kodiert, zerschnitten und verschiedenen Prozeduren der Datenanalyse unterworfen werden kann (Breidenstein, 2012; Herrle & Breitenbach, 2016). Die daraus resultierenden Transkripte bieten einige Potenziale für die Analyse und Reflexion pädagogischer Prozesse. Ein wörtliches Transkript ermöglicht die sprachlichen Interaktionen des Unterrichtsgeschehens präzise nachzuvollziehen und zu analysieren (Junker et al., 2020). Dies ist insbesondere bei Verfahren notwendig, bei denen Videodaten primär zur Vervollständigung und Verbesserung der Transkription verbaler Interaktionen eingesetzt werden (Reh, 2012). Zusätzlich ermöglicht die Verschriftlichung eine distanzierte und objektivierte Beobachtungsmöglichkeit. Das Protokoll kann beliebig oft und in beliebiger Geschwindigkeit gelesen werden, was die Reflexion und Analyse erleichtert (Herrle & Breitenbach, 2016). In qualitativen und ethnografischen Studien dient die Transkription als Protokoll des genauen Hinsehens und als essenzieller Schritt zur Rekonstruktion des gefilmten Geschehens (Reh, 2012). Zudem kann die Transkription für die mikroanalytische Untersuchung des Unterrichts als multimodales Interaktionssystem herangezogen werden. Detaillierte Transkripte, die Verbal- und Gesten-/Mimik-Protokolle umfassen, machen die Komplexität und die Simultanität der Abläufe für die nachfolgende Interpretation zugänglich (Herrle et al., 2010; Reh, 2012). Für die Lehrkräftebildung ist die Transkription von Videose-

quenzen hilfreich, da sie in Einzel- oder Gruppenarbeiten genutzt werden kann, um analytische Aktivitäten durchzuführen, ohne das Video erneut betrachten zu müssen. Die Transkripte können außerdem zu Kontrastierungszwecken genutzt werden, da sie sich einfacher parallelisieren lassen als Videosequenzen (Lenske et al., 2020). Obwohl Transkripte ein grundlegendes Werkzeug in der Unterrichtsqualitätsforschung darstellen, sind die Grenzen und Herausforderungen im Umgang mit textbasierten Daten in der Forschung bekannt.

Einer der zentralen methodologischen Einwände ist, dass sich einfache Transkripte auf verbale Äußerungen beschränken und dadurch die Gesamtheit an Interaktionen (nonverbale Verhaltensweisen) im Unterricht nicht vollständig erfasst werden (Göllner et al., 2025). Die nonverbale Kommunikation und der räumliche Kontext sind für das Verständnis des Interaktionszusammenhangs oftmals entscheidend. So kann durch die reine Verschriftlichung des Gesprochenen beispielsweise nicht abgebildet werden, ob es sich bei einem Lob oder einer Ermahnung um Ironie oder Ablehnung handelt (Beck & Scholz, 2012). Ethnografische Notizen durch Beobachter*innen im Unterricht können diese Lücke zwar schließen, eröffnen aber auch neue Probleme. Eine Feldnotiz ist niemals ein neutrales Abbild der Realität, sondern eine „interpretative Neuschaffung“ (Beck & Scholz, 2012, p. 113). Das Beschreiben von Situationen stellt einen Übertragungsprozess des Beobachteten ins Schriftliche dar und erhält implizit bereits Deutungen, die von individuellen Erfahrungen, Alltagstheorien und kulturellen Kontexten geprägt sind (de Boer, 2012). Die Basisdimensionen der Unterrichtsqualität variieren hinsichtlich ihrer Verankerung in der verbalen Interaktion. Die Analyse von Transkripten, die primär linguistische und konversationelle Informationen liefern, ist daher für bestimmte Dimensionen besser geeignet als für andere (Göllner et al., 2025). Aufgrund ihres verbalen und interaktiven Charakters eignet sich die Analyse der Unterrichtsqualität durch Transkripte vermutlich besonders gut für die Dimensionen KA und KU, da beide eng mit den Erklärungen der Lehrkraft, der Förderung fachlicher Diskurse sowie der responsiven emotionalen Unterstützung verknüpft sind (Göllner et al., 2025; Pianta & Hamre, 2009). Die Dimension SK stützt sich hingegen stärker auf nonverbale Verhaltensweisen (z. B. Blickrichtungen, Bewegungen) und visuell-räumliche Informationen, die durch einfache Transkripte nicht erfasst werden können (Göllner et al., 2025; Martikainen, 2020).

In der Lehrkräftebildung konnte festgestellt werden, dass die Analyse von Transkripten zu vergleichbaren Lernzuwächsen wie die Betrachtung von Unterrichtsvideos führt (Kramer et

al., 2020; Schneider et al., 2016). Dennoch stellten Studierende, die direkt mit den Unterrichtsvideos arbeiteten, mehr Zusammenhänge zwischen den Handlungen der Lehrkräfte und dem Lernprozess der Lernenden her (Gold et al., 2016). Außerdem ist die manuelle qualitative Kodierung von umfangreichen schriftlichen Textdaten kostspielig, mühsam und zeitaufwendig (Gencoglu et al., 2023; Schonlau & Couper, 2016). Um Unterrichtstranskripte und Beobachtungsprotokolle effizient nutzen zu können, braucht es skalierbare und kosteneffiziente automatische Analysemethoden (Schlotterbeck et al., 2021). Angesichts der Limitationen ressourcenintensiver, manueller Verfahren zur Erstellung und Analyse umfangreicher transkriptbasierter Datensätze sowie der Schwierigkeit, die Komplexität multimodaler Interaktionen vollständig zu erfassen, rückt der Einsatz von KI-Technologien zunehmend in den Fokus.

2.7. KI in der Unterrichtsforschung

Durch die fortschreitende Digitalisierung des Bildungsbereichs und durch die simultane Entwicklung von KI-Technologien eröffnen sich in der Unterrichtsforschung neue Möglichkeiten zur Erfassung, Auswertung und Interpretation lehr- und lernbezogener Daten. Die Integration von KI in die Bildungsforschung umfasst dabei eine breite Palette von Einsatzmöglichkeiten, die von der automatisierten Analyse umfangreicher Datensätze bis hin zur Generierung von Forschungsinstrumenten reichen. Dabei werden etablierte Zugänge wie Videoerhebungen nicht ersetzt, sondern unterstützt und erweitert (Eberle et al., 2024). Die Relevanz von KI ist dabei vielschichtig und erfordert eine differenzierte Analyse ihrer Anwendungsbereiche und Einsatzmöglichkeiten. Im Kontext der Bildungsforschung lassen sich zwei Einsatzformen von KI unterscheiden: die prädiktive KI und die generative KI (GenKI) (Neumann et al., 2024).

2.7.1. Anwendungen und Potenziale

Prädiktive Verfahren werden in der Unterrichtsforschung primär eingesetzt, um große und heterogene Datensätze automatisiert auszuwerten und aus unterschiedlichen Datentypen quantitative Indikatoren für Lern- und Unterrichtsprozesse abzuleiten. So können aus Unterrichtstranskripten beispielsweise Selbstregulationsprozesse von SuS erschlossen werden (Bannert et al., 2014). Darüber hinaus lässt sich die Semantik von Unterrichtstranskripten mittels KI quantifizieren und mit Merkmalen der Unterrichtsqualität in Beziehung setzen (Göllner et al., 2025). Einen zentralen und aktuellen Bezugspunkt stellt die Studie von Göllner et al. (2025) dar, in der die Eignung eines GPT-4-basierten Ansatzes zur Identifikation von Unterrichtsqualität auf Grundlage von Unterrichtstranskripten untersucht wird. Dabei werden aus den Text-

daten semantische Merkmale extrahiert und zur Vorhersage etablierter Qualitätsdimensionen genutzt, wobei insbesondere sprachlich explizite Facetten der Unterrichtsqualität zuverlässig abgebildet werden können (Göllner et al., 2025). Ergänzend zeigen prädiktive Verfahren auch Potenziale für audio-/videobasierte Analysen, etwa zur Bewertung kollaborativen Arbeitens (Spikol et al., 2018) sowie für prozessnahe Daten aus digitalen Lernumgebungen, wenn Blick- und Logdaten zur Identifikation spezifischer Fehlkonzepte genutzt werden (Becker et al., 2022; Dzsotjan et al., 2021). Schließlich kann auf Grundlage textbasierter SuS-Antworten die Tiefe des domänenspezifischen Verständnisses untersucht werden (Gombert et al., 2023).

GenKI-Systeme basieren auf Deep-Learning-Algorithmen mit neuronaler Netzwerkarchitektur und können Inhalte dadurch nicht nur analysieren, sondern eigenständig erzeugen (Schneider, 2025). Die Veröffentlichung von Transformer-Modellen wie ChatGPT (OpenAI), Copilot (Microsoft) und Gemini (Google) hat das Spektrum an methodischen Einsatzmöglichkeiten für das Forschungsfeld erweitert (Neumann et al., 2024). Zum einen können GenKI-Technologien wie beispielsweise Large Language Models (LLMs) zur Generierung von Forschungsmaterialien und Instrumenten eingesetzt werden. Dies umfasst die Erzeugung von Lernmaterialien, Lernaufgaben, Lernhilfen sowie von Testmaterialien und Kodierschemata (Neumann et al., 2024). So kann GenKI beispielsweise zur automatisierten Kodierung qualitativer Textdaten eingesetzt werden, deren Übereinstimmung mit menschlichen Kodierungen empirisch überprüft wird (Long et al., 2024). Ansätze der natürlichen Sprachverarbeitung ermöglichen außerdem eine automatisierte Bewertung von geschriebenen Texten, Lern- und Arbeits(zwischen)produkten sowie kontinuierliche formative Diagnosen lernrelevanter Prozesse (Scheiter et al., 2025). Arbeiten wie die von Kieser et al. (2023) zeigen in diesem Kontext, dass Modelle wie ChatGPT Antworten auf Aufgaben bewerten können (Neumann et al., 2024). Zusätzlich eröffnet GenKI neue Ansätze zur Aufbereitung und Analyse des Forschungsstandes (Neumann et al., 2024). GenKI kann eingesetzt werden, um große Literaturbasen zu synthetisieren, Literaturrecherchen und Datenanalysen durch Hyperautomationen (Identifizierung, Aufbereitung, vorläufige Auswertung) zu katalysieren (Schneider, 2025), wissenschaftliche Artikel zu verfassen (Neumann et al., 2024) sowie Daten zu bereinigen, zu unterteilen und zu analysieren (Pietrusky, 2025). Außerdem kann GenKI Lehrkräfte bei forschungsrelevanten Reflexionsprozessen unterstützen (Neumann et al., 2024).

Die größten Potenziale von KI in der Unterrichtsforschung liegen demnach in der effektiven und effizienten Analyse und Mustererkennung in großen Datensätzen, in der automatisierten Bewertung und Diagnostik, in der Unterstützung bei der Konzeption von Forschungsdesigns und der Entwicklung geeigneter Instrumente sowie in der wissenschaftlichen Recherche und der Überarbeitung wissenschaftlicher Texte.

2.7.2. Herausforderungen

Trotz der Potenziale ergeben sich aus methodischer, ethischer und theoretischer Sicht erhebliche Herausforderungen im Umgang mit KI in der Unterrichtsforschung. Ein zentrales wissenschaftliches Problem stellt der systematische Bias in KI-Modellen dar, der die Validität und Generalisierbarkeit von Forschungsergebnissen gefährdet (Min, 2023; Scheiter et al., 2025). KI-Systeme lernen anhand von Trainingsdaten und können dadurch systematische Fehler, Vorurteile oder Ungleichheiten, die in den Daten enthalten sind, reproduzieren, was zu nicht generalisierbaren oder diskriminierenden Ergebnissen führen kann (Branda et al., 2025). Besonders problematisch ist es, wenn Trainingsdatensätze unvollständig sind oder bestimmte Personengruppen unterrepräsentiert sind (Min, 2023). Darüber hinaus besteht das Risiko der Halluzination bei GenKI, bei der zwar plausible, aber faktisch falsche oder irreführende Informationen (erfundene Zitate, Daten, Quellen) generiert werden (Perković et al., 2024; Scheiter et al., 2025). Untersuchungen des bibliographischen Outputs von ChatGPT-4 haben gezeigt, dass ein Großteil der generierten Referenzen überzeugend, aber vollständig erfunden war (Branda et al., 2025; Metze et al., 2024). Diese Unzuverlässigkeit generierter Inhalte stellt eine große Bedrohung für die Integrität des Forschungsstandes dar. Um Halluzinationen zu erkennen und zu beseitigen, ist eine kritische Überprüfung durch Forschende unerlässlich (Schneider, 2025). Eine weitere Limitation von KI-Modellen ist das Black-Box-Problem, das auf die mangelnde Transparenz neuronaler Netzwerke verweist und die Reproduzierbarkeit sowie die Überprüfung der generierten Ergebnisse erschwert (Branda et al., 2025). Außerdem ist die Sensitivität gegenüber der Formulierung der Prompts bei Chatbots sehr hoch (Khlaif et al., 2023; Kizilcec, 2023).

Der Europäische Union (EU) AI Act schreibt durch das Human-In-The-Loop-Prinzip vor, dass die letztendliche Entscheidungsverantwortung in automatisierten Prozessen von Menschen getragen wird (Europäische Union, 2024). Deshalb sollte der Fokus auf erklärbare KI (explainable AI) gelegt werden, um den Nutzenden wertvolle Einblicke in den Entstehungs-

prozess von Ergebnissen (Algorithmen, Parameter, Prozessinformationen) liefern zu können und Verantwortungstragende hinreichend zu informieren (Scheiter et al., 2025). Bei aktuellen Modellen von ChatGPT erhalten Nutzende bereits oberflächliche Einblicke in vom System generierte Begründungen und Erläuterungen. Selbst wenn die KI-Modelle erklärbarer werden, stellt ihre Nutzung erhebliche Datenschutzrisiken dar. Öffentlich zugängliche KI-Anwendungen werden häufig auf nicht-europäischen Servern gehostet und Interaktionen mit dem System (Prompts, Bewertungen von Antworten) werden gespeichert, um die Modelle fortlaufend zu trainieren. Diese Informationen können mit Nutzendendaten verknüpft und außerhalb der EU weitergegeben werden, was nicht im Einklang mit der Datenschutz-Grundverordnung (DSGVO) steht, besonders wenn Prompts personenbezogene Daten enthalten (Scheiter et al., 2025). Da in der Unterrichtsforschung mit hochsensiblen, personenbezogenen Daten (Audio-daten, Videodaten, Logdaten) gearbeitet wird, erfordert die Nutzung von KI-Modellen in diesem Bereich eine strikte Regulierung. Die DSGVO legt fest, dass die Verwendung personenbezogener Daten die freiwillige und widerrufbare aktive Einwilligung der Nutzenden erfordert und dass nicht von einer stillschweigenden Zustimmung ausgegangen werden darf (Europäische Union, 2016). Darüber hinaus legt der EU AI Act eine spezifische Klassifizierung der mit dem Einsatz von KI verbundenen Risiken fest, die sich am Ausmaß des potenziellen Schadens für Individuen orientiert. Im Bildungsbereich wird die automatische Emotionserkennung beispielsweise der vierten und damit höchsten Risikostufe (inakzeptabel) zugeordnet (Scheiter et al., 2025).

Die größten Herausforderungen der KI-gestützten Unterrichtsforschung liegen demnach in den Verzerrungen und der mangelnden Transparenz von KI-Modellen, in der eingeschränkten Reproduzierbarkeit der Ergebnisse sowie im verantwortungsvollen Umgang mit sensiblen personenbezogenen Daten.

3. Forschungsfragen

Vor dem theoretischen Hintergrund dieser Arbeit werden die folgenden zwei Forschungsfragen formuliert. Untersucht werden die prinzipielle Eignung und die Übereinstimmungsvalidität einer KI-gestützten, transkriptbasierten Analyse der Unterrichtsqualität im Wirtschaftsunterricht im Vergleich zu videobasierten menschlichen Ratings.

(F1) Für welche Basisdimensionen, Items und Indikatoren des UFB ist eine transkriptbasierte KI-Bewertung grundsätzlich geeignet und wo zeigen sich systematische Grenzen?

(F2) In welchem Maße stimmen KI-gestützte, rein transkriptbasierte Bewertungen der Unterrichtsqualität mit videobasierten Ratings geschulter menschlicher Rater*innen in den drei Basisdimensionen KA, KU und SK überein?

4. Methoden

4.1. Forschungsdesign

Die vorliegende Arbeit ist als methodische Validierungsstudie im Feld der videobasierten Unterrichtsqualitätsforschung angelegt. Untersucht wird, ob eine transkriptbasierte Analyse von Wirtschaftsunterricht durch ein LLM zu vergleichbaren Ergebnissen führt wie eine videobasierte Analyse durch geschulte menschliche Beobachter*innen. Die Studie folgt einem quantitativen, vergleichenden Design. Für die Beobachtungseinheiten liegen menschliche Ratings und KI-Bewertungen zu allen Items vor. Auf dieser Grundlage werden Übereinstimmungen und systematische Abweichungen zwischen beiden Datenquellen analysiert.

Gegenstand des Vergleichs sind Bewertungen auf Grundlage des UFB mit dem zugehörigen Beobachtungsmanual (Fauth et al., 2024). Das Instrument fokussiert zentrale Tiefenstrukturen von Unterricht. Abgebildet werden die Basisdimensionen KA mit vier Items, KU mit vier Items und SK mit drei Items. Für jedes Item formuliert das Manual eine theoretische Grundidee sowie mehrere positiv und negativ formulierte Verhaltensindikatoren. Diese Indikatoren beziehen sich je nach Item auf das Verhalten der Lehrkraft oder der SuS und konkretisieren die abstrakten Qualitätsmerkmale in beobachtbaren Situationen des Unterrichts. Die Bewertung erfolgt itembezogen auf einer vierstufigen Likert-Skala mit den Ausprägungen 1 „trifft nicht zu“, 2 „trifft eher nicht zu“, 3 „trifft eher zu“, 4 „trifft zu“. Die Validität, psychometrische Güte sowie Praxistauglichkeit des Beobachtungsinstruments wurden in umfangreichen Begleitstudien überprüft und bestätigt (Fauth et al., 2024).

Die Untersuchung basiert auf Videoaufzeichnungen einer zwölften Klasse eines Beruflichen Gymnasiums mit wirtschaftswissenschaftlicher Ausrichtung in Baden-Württemberg. Erfasst wurden vier Unterrichtsstunden im Fach Volkswirtschaftslehre mit einer Dauer von jeweils etwa neunzig Minuten. Die Erhebung fand im September und Oktober des Jahres 2022 im regulären Unterrichtsbetrieb statt. Es handelt sich um natürliche Unterrichtssituationen, die keine experimentellen Eingriffe oder besondere Inszenierungen umfassen. Für die Aufzeichnung wurden zwei Kameraperspektiven eingesetzt. Eine Kamera fokussierte nur die Lehrkraft, eine weitere erfasste den Klassenraum. Die Lehrkraft trug ein Ansteckmikrofon, die SuS verfügten über keine individuellen Mikrofone. Daraus ergab sich eine deutlich bessere Audioqualität der Äußerungen der Lehrkraft im Vergleich zu denen der SuS.

Die vier Unterrichtsstunden wurden in 18 Videosegmenten von wissenschaftlichen Hilfskräften des Fachbereichs Wirtschaftspädagogik der Universität Konstanz beurteilt. Die Rater*innen orientierten sich bei der Beurteilung an den Itembeschreibungen und Indikatoren des Beobachtungsmanuals, um ein gemeinsames Verständnis der zugrunde liegenden Unterrichtsqualitätsmerkmale sicherzustellen. Jedes Segment wurde von mehreren unabhängigen Personen bewertet. In die weitere Analyse gehen die aggregierten Mittelwerte der menschlichen Bewertungen pro Block und Item ein.

4.2. Workflow

Der methodische Workflow dieser Studie umfasst die automatisierte (1) Transkripterstellung der Unterrichtssegmente mittels Whisper (OpenAI), die anschließende (2) KI-gestützte Bewertung der Transkripte über die ChatGPT-API (GPT-5.1) anhand des UFB, sowie die (3) programmgesteuerte Auswertung durch ein Python-Skript, das die resultierenden Ratings in standardisierte Ergebnistabellen überführt. Abschließend erfolgt (4) ein systematischer Vergleich der KI-basierten Urteile mit den videobasierten menschlichen Ratings, um die Übereinstimmung der Bewertungen entlang der erfassten Dimensionen zu prüfen.

4.2.1. Transkription

Aus Gründen des Datenschutzes wurden die Videodateien im MP4-Format lokal auf einem Rechner der Universität Konstanz in Audiodateien im MP3-Format umgewandelt. Anschließend wurden sie in insgesamt 18 Segmente von jeweils etwa 20 Minuten Länge unterteilt. Für die Transkription der Audiodaten wurde der kostenpflichtige Dienst der Software TurboScribe (<https://turboscribe.ai/de/>) eingesetzt, die auf dem OpenAI Whisper-Modell basiert. Whisper ist ein sequenziell arbeitendes neuronales Spracherkennungsmodell, das auf einer großen Menge mehrsprachiger und teils multimodaler Audiodaten trainiert wurde. Es konvertiert das Audiosignal in latente Repräsentationen, erkennt Sprachmuster, Prosodie, Akzent und Hintergrundgeräusche und generiert daraus fortlaufend den transkribierten Text (Radford et al., 2022). TurboScribe erstellt auf dieser Basis Transkripte mit Zeitstempeln und weist die Sprecherrollen Lehrkraft und Schüler*in automatisch zu. Aufgrund der beschriebenen Audioeinschränkungen auf Seiten der SuS sowie gelegentlicher Fehler bei der Sprechererkennung war eine geringfügige manuelle Nachbearbeitung notwendig. Über die Oberfläche von TurboScribe wurden alle Transkripte auf grobe Fehler untersucht, Sprecherrollen angepasst, offensichtliche Fehlzuordnungen korrigiert und Lücken gefüllt. Die finalen Transkripte bilden aus-

schließlich die verbalen sprachlichen Interaktionen ab. Es werden keine Regieanweisungen (z. B. „Die Klasse lacht“), keine nonverbalen Verhaltensweisen (z. B. „Der Schüler sucht in seiner Tasche nach dem Arbeitsblatt“), keine räumlichen Positionierungen (z. B. „Die Lehrkraft bewegt sich durch die Sitzreihen“) und keine Informationen zu Mimik und Gestik (z. B. „Die Lehrkraft schaut empört“) dokumentiert. Damit stehen der KI nur sprachliche Äußerungen und Sprecherwechsel (im Kontext der Zeitstempel) für die Analyse zur Verfügung, während die menschlichen Rater*innen auf das vollständige Videomaterial zugreifen konnten.

4.2.2. KI-gestützte Beurteilung

Um die große Menge an Textdaten effizient auszuwerten, wurde für die KI-Analyse eine Schnittstelle zur ChatGPT-Programmierschnittstelle (API) eingerichtet. Grundlage bildeten die 18 Transkripte, die auf jeweils elf Items analysiert wurden. Daraus resultierten 198 Prompt-Durchläufe mit insgesamt ca. 1,4 Millionen Input-Tokens. Für die Auswertung wurde das Modell GPT-5.1 mit mittlerem „reasoning effort“ verwendet. Die Temperatur wurde auf 0,0 gesetzt, um die Varianz der Modellantworten zu minimieren und die Ausgabe möglichst konsistent zu halten (Göllner et al., 2025). Der Prompt folgte für alle Items und Blöcke einer einheitlichen Struktur. Zunächst erhielt das Modell eine kurze Rollenbeschreibung, in der es als Expert*in für Unterrichtsqualitätsforschung adressiert wurde. Es wurde explizit darauf hingewiesen, ausschließlich Informationen aus dem vorliegenden Transkript zu nutzen und keine zusätzlichen Annahmen zu treffen. Anschließend wurden die vollständige Grundidee des zu betrachtenden Items sowie sämtliche positiven und negativen Indikatoren aus dem Beobachtungsmanual in den Prompt integriert. Damit standen dem Modell exakt die gleichen definitorischen Informationen zur Verfügung, die auch die menschlichen Rater*innen als Grundlage ihrer Urteile nutzten. Im letzten Promptabschnitt wurden die Bewertungsanweisungen präzise beschrieben. Das Modell sollte für jeden einzelnen Indikator angeben, ob dieser im Transkript eindeutig sichtbar ist, nicht vorkommt oder auf Basis des Transkripts nicht beurteilt werden kann. Um die Beschränkung der Transkripte auf rein verbale Informationen abzubilden, wurden drei Kategorien eingeführt.

- Wert 0, wenn der Indikator im Transkript eindeutig nicht vorkommt.
- Wert 1, wenn der Indikator im Transkript eindeutig erkennbar ist.
- Wert 99, wenn der Indikator eine nonverbale Beobachtung voraussetzt oder auf Basis des Transkripts nicht zuverlässig beurteilt werden kann.

Danach sollte das Modell eine Gesamteinschätzung des Items auf der vierstufigen Likert-Skala vornehmen und diese Bewertung knapp begründen. Die textlichen Begründungen dienten ausschließlich der Transparenz der automatisierten Bewertungen und wurden stichprobenartig auf Plausibilität geprüft, um offensichtlich willkürliche Ausgaben zu vermeiden. Die Verwendung der Kategorie 99 ist für die Validitätsanalyse zentral, weil sie sichtbar macht, welche Anteile des Instruments in einer transkriptbasierten Perspektive systematisch nicht abbildbar sind.

4.2.3. Durchführung

Die Durchführungsobjektivität der KI-Bewertung wurde durch ein Python-Skript abgesichert. Das Skript übernimmt vier Aufgaben. Erstens werden die Grundidee, alle positiven und negativen Indikatoren sowie die Bewertungsanweisungen für das jeweils betrachtete Item aus einer strukturierten Datei mit den Inhalten des Beobachtungsmanuals automatisiert zu einem Prompt zusammengeführt. Zweitens liest das Skript die zugehörigen Transkripte der 18 Blöcke ein und ergänzt sie im Prompt. Dadurch entsteht für jedes Item und jeden Block ein vollständig strukturierter Prompt, der in gleicher Form an das ChatGPT-Modell gesendet wird. Drittens steuert das Skript die Kommunikation mit der Programmierschnittstelle. Es übergibt den Textprompt an das Modell, empfängt die Antwort und extrahiert aus dieser Antwort sowohl die Indikatorbewertungen als auch die Likert-Gesamteinschätzung und die textliche Begründung. Viertens werden alle Ergebnisse in tabellarischer Form gespeichert. Für jedes Item wird eine Datei mit der Bezeichnung „indikatoren_pro_block_itemXX“ erzeugt. Diese enthält für jeden Block die numerischen Bewertungen (0, 1, 99) aller Indikatoren sowie die jeweilige qualitative Begründung. Eine zweite Datei mit der Bezeichnung „block_summary_itemXX“ enthält für jedes Item die Anzahl der im Transkript vorkommenden positiven und negativen Indikatoren, die daraus resultierende Gesamtbewertung auf der Likert-Skala sowie eine zusammenfassende textliche Begründung.

Für den Vergleich der Bewertungen wurden alle Daten in Tabellenform zusammengeführt. Für jedes Items liegen menschliche und eine KI-basierte Likert-Bewertungen vor. Zusätzlich stehen pro Item die Verteilungen der Indikatorbewertungen 0, 1 und 99 zur Verfügung. Diese Angaben erlauben es, die Nutzung der Kategorie 99 in Abhängigkeit von Iteminhalt und Basisdimension zu untersuchen und so die Grenzen einer transkriptbasierten Erfassung zu bestimmen. Die Likert-Bewertungen werden in numerischer Form gespeichert. Alle weiteren

Schritte der Datenanalyse basieren auf diesen numerischen Ratings sowie den Häufigkeiten der Indikatorbewertungen.

4.2.4. Auswertung

Die Datenanalyse erfolgte in drei aufeinander aufbauenden Schritten. Im ersten Schritt wurde die Eignung der Indikatoren für eine rein transkriptbasierte Auswertung untersucht. Dazu wurden für jeden Indikator die Häufigkeiten der drei KI-Kategorien 0, 1 und 99 über alle Transkriptblöcke hinweg ausgewertet. Auf dieser Basis wurden Indikatoren von der KI als geeignet, bedingt geeignet oder nicht geeignet eingestuft. Zusätzlich wurde pro Item ein Eignungsscore gebildet, indem geeignet mit 1,0, bedingt geeignet mit 0,5 und nicht geeignet mit 0,0 kodiert und über die Indikatoren eines Items aggregiert wurde.

Im zweiten Schritt wurde die Übereinstimmung der globalen Itemratings zwischen KI- und menschlichen Bewertungen auf Ebene der Transkriptblöcke analysiert. Für jedes Item und jeden Block wurde die Differenz zwischen menschlicher und KI-Bewertung auf der vierstufigen Likert-Skala bestimmt. Darauf aufbauend wurde ausgewertet, in wie vielen Fällen eine vollständige Übereinstimmung vorliegt und in wie vielen Fällen Abweichungen auftreten. Zur Quantifizierung der Abweichungsgröße wurde für jedes Item die mittlere absolute Abweichung (MAD) berechnet und die maximale beobachtete Abweichung angegeben. Zusätzlich wurden die Mittelwerte der menschlichen Ratings und der KI-Bewertungen pro Item bestimmt, um zu prüfen, ob die KI tendenziell höhere oder niedrigere Bewertungen vergibt. Soweit in beiden Bewertungsreihen ausreichende Varianz vorlag, wurde außerdem der Pearson-Korrelationskoeffizient (r) zwischen den beiden Bewertungsreihen über die Transkriptblöcke hinweg berechnet, um die Ähnlichkeit der Bewertungsmuster unabhängig vom Niveau zu beschreiben. Die Anzahl der Vergleichspaare konnte dabei itemweise variieren, wenn für einzelne Blöcke keine gültigen Vergleichswerte vorlagen.

Im dritten Schritt wurden die itemweisen Ergebnisse auf Ebene der Basisdimensionen zusammengeführt. Neben der Gesamtzahl der Vergleichspaare und dem Anteil identischer Bewertungen wurde hierfür eine gewichtete MAD berechnet, um die unterschiedliche Paarzahl der Items innerhalb einer Basisdimension zu berücksichtigen.

Ergänzend wurden zwei zusammenhangsanalytische Auswertungen auf Itemebene vorgenommen. Erstens wurde geprüft, ob ein Zusammenhang zwischen dem Eignungsscore eines Items und der Übereinstimmung im Mensch-KI-Vergleich besteht. Diese Überprüfung wurde

über die MAD sowie den Anteil identischer Bewertungen operationalisiert. Zweitens wurde das Verhältnis positiver zu negativer Indikatoren pro Item bestimmt, um zu überprüfen, ob das Verhältnis einen Einfluss auf die Richtung der Abweichung hat. Diese Überprüfung wurde über die Differenz der Mittelwerte zwischen KI und Mensch operationalisiert. Für diese item-bezogenen Zusammenhangsprüfungen wurden rangbasierte Korrelationsmaße verwendet. Die vierstufige Likert-Skala ist theoretisch ordinal. In dieser Arbeit wird sie für die Berechnung von Mittelwerten, MAD und linearen Zusammenhängen als quasi-metrisch behandelt.

5. Ergebnisse

5.1. Transkriptbasierte Indikatoreignung

Für jeden Indikator wurde geprüft, ob er auf Basis der Transkripte von der KI verlässlich bewertbar ist. Dazu wurden die Häufigkeiten der Kategorien 0, 1 und 99 über alle 18 Blöcke ausgewertet. Die Einstufungen geeignet, bedingt geeignet und nicht geeignet wurden von der KI vorgenommen. Grundlage dafür bildeten der Anteil der 99-Bewertungen sowie eine kontextbezogene Einordnung der Indikatoren. Die folgenden Abschnitte stellen die Ergebnisse getrennt nach Basisdimensionen und Items dar. Abb. 2 fasst die Eignungseinstufungen der Indikatoren nach Item und Basisdimension zusammen und dient als orientierende Gesamtübersicht, bevor die Ergebnisse in den folgenden Unterabschnitten detailliert berichtet werden. Die Abbildung zeigt, dass die Indikatoren der KA und auch der KU überwiegend als geeignet eingestuft werden, während sich bei SK, insbesondere bei SK2, deutlich mehr bedingt geeignete und nicht geeignete Indikatoren finden. Die Indikatordefinitionen sowie die Häufigkeitstabellen der Indikatorbewertungen sind in den Ergebnistabellen im Anhang dokumentiert.




Abb. 2: Übersicht der Indikatoreignung nach Item und Basisdimension.

5.1.1. Kognitive Aktivierung

Die Basisdimension KA umfasst vier Items mit insgesamt 40 Indikatoren. Für das Item KA1 „Verständnisorientierung“ wurden alle elf Indikatoren von der KI über alle 18 Transkriptblöcke hinweg ohne Vergabe der Kategorie 99 bewertet. Alle Indikatoren wurden als geeignet eingestuft. Für das Item KA2 „Ermittlung von Denkweisen und Vorstellungen“ wurden acht der neun Indikatoren als geeignet eingestuft. Ein Indikator, der die Berücksichtigung von Vorwissen erfasst, weist in 44,4 Prozent der Fälle eine 99-Bewertung auf und wurde als bedingt geeignet eingestuft. Dieser Indikator setzt Beobachtungen voraus, die in den Transkripten nicht in jedem Block hinreichend abgebildet sind. Für alle zehn Indikatoren des Items KA3 „Herausfordernde Aufgaben und Fragen“ wurde die Kategorie 99 nicht vergeben. Alle Indikatoren wurden als geeignet eingestuft. Beim Item KA4 „Engagement der SuS“ zeigte sich ein gemischtes Bild. Sieben der zehn Indikatoren wurden als geeignet, zwei als bedingt geeignet und ein Indikator als nicht geeignet bewertet. Besonders der Indikator zur aktiven Beteiligung der SuS am Unterrichtsgeschehen durch Meldungen weist einen hohen Anteil an 99-Bewertungen auf. In 61,1 Prozent der Transkriptblöcke konnte der Indikator nicht bewertet werden. Als bedingt geeignet wurden Indikatoren eingestuft, die der Feststellung von Freude und Interesse der SuS dienen. Insgesamt zeigt sich für die Basisdimension KA bei den meisten Indikatoren eine hohe Beurteilbarkeit durch die KI auf Grundlage der Transkripte. Die Anteile der Eignungseinstufungen der Indikatoren innerhalb der Basisdimension KA sind in Abb. 3 zusammengefasst.




Abb. 3: Eignung der Indikatoren der Basisdimension KA für die transkriptbasierte Analyse.

5.1.2. Konstruktive Unterstützung

Die Basisdimension KU umfasst vier Items mit insgesamt 40 Indikatoren. Die elf Indikatoren des Items KU1 „Qualität des Feedbacks“ wurden nahezu vollständig ohne Vergabe der Kategorie 99 bewertet. Zwei Indikatoren zum Umgang mit Fehlern (respektvoller Umgang; didaktische Nutzung von Fehlern zur Erklärung und Vertiefung) wurden jeweils in einem Block mit 99 bewertet. Alle Indikatoren wurden als geeignet eingestuft. Für das Item KU2 „Individuelle Unterstützung im Lernprozess“ wurden acht der neun Indikatoren als geeignet eingestuft. Der Indikator zur Wartezeit auf Antworten der SuS wurde in 83,3 Prozent der Transkriptblöcke mit 99 bewertet und als nicht geeignet eingestuft. Beim Item KU3 „Wertschätzung und Respekt“ wurden sieben Indikatoren als geeignet, ein Indikator als bedingt geeignet und ein Indikator als nicht geeignet eingestuft. Ob die Lehrkraft alle SuS unabhängig von ihren individuellen Hintergründen gleich behandelt, konnte in 16,6 Prozent der Transkriptblöcke nicht bewertet werden. Der Indikator wurde daher als bedingt geeignet eingestuft. Der als nicht geeignet eingestufte Indikator bezieht sich auf Gesten der Verächtlichmachung und wurde in 38,9 Prozent der Fälle mit 99 bewertet. Verbale Äußerungen von Respekt oder respektlosem Verhalten konnten dagegen meist zuverlässig aus den Transkripten entnommen werden. Beim Item KU4 „Klassenklima“ wurden sieben Indikatoren als geeignet und vier Indikatoren als bedingt geeignet eingestuft. Als bedingt geeignet wurden hier insbesondere Indikatoren eingestuft, die auf wechselseitiges Zuhören, Unterstützung und Zusammenhalt der Lerngruppe abzielen und zumindest teilweise auf nonverbale oder längere Interaktionen verweisen. Indikatoren, die sich direkt auf verbale Respektlosigkeit oder Konflikte beziehen, wurden ohne Vergabe der Kategorie 99 als geeignet eingestuft. Für die Basisdimension KU zeigt sich damit insgesamt eine gute Bewertbarkeit der Indikatoren auf Grundlage der Transkripte, mit punktuellen Einschränkungen bei Indikatoren, die stark von Wartezeiten, Gestik oder feinen Abstufungen in der Beziehungsgestaltung abhängen. Eine Übersicht über die Eignungseinstufungen der Indikatoren der Basisdimension KU zeigt Abb. 4.




Abb. 4: Eignung der Indikatoren der Basisdimension KU für die transkriptbasierte Analyse.

5.1.3. Strukturierte Klassenführung

Die Basisdimension SK umfasst drei Items mit insgesamt 28 Indikatoren. Beim Item SK1 „Störungen durch SuS“ wurden fünf der sieben Indikatoren als geeignet und zwei Indikatoren als bedingt geeignet eingestuft. Als bedingt geeignet wurden Indikatoren eingestuft, die eine genaue Einschätzung der Lautstärke erfordern. Häufigkeit und Art von Störungen sowie die Ruhe und Ordnung im Unterrichtsgeschehen konnten dagegen durchgängig bewertet werden. Beim Item SK2 „Monitoring“ zeigt sich eine deutliche Einschränkung der transkriptbasierten Bewertbarkeit. Sieben der zehn Indikatoren wurden als bedingt geeignet und drei Indikatoren als nicht geeignet eingestuft. Obwohl Indikator eins („Die Lehrkraft hat alle SuS im Blick“) in jedem Block bewertet werden konnte, wurde er als bedingt geeignet eingestuft. Dies könnte an der semantischen Unschärfe der Formulierung „im Blick haben“ liegen, da sie entweder allgemein verstanden werden kann (als grundlegendes Wahrnehmen aller SuS) oder enger als kontinuierliches Beobachten und tatsächliches im Blick behalten. Besonders hohe Anteile von 99-Bewertungen fanden sich bei Indikatoren, die sich auf die Präsenz und Position der Lehrkraft im Raum, die Blickrichtung der Lehrkraft und übersehene Meldungen beziehen. Um das Monitoring einer Lehrkraft beurteilen zu können, reichen einfache Unterrichtstranskripte allein demnach nicht aus. Für das Item SK3 „Zeitnutzung“ wurden acht Indikatoren als geeignet, zwei Indikatoren als bedingt geeignet und ein Indikator als nicht geeignet eingestuft. Als nicht geeignet wurde der Indikator zum pünktlichen Beginn und Ende der Stunde eingestuft, da die Transkriptblöcke nur zwanzigminütige Abschnitte und keine vollständigen Unterrichts-

stunden umfassen. Stundenabschlüsse konnten ebenfalls nur in Transkriptblöcken bewertet werden, in denen ein Stundenabschluss enthalten war. Angaben zur Nutzung der Unterrichtszeit für fachliche Inhalte, zu Wartezeiten und zur Unterrichtsplanung konnten dagegen gut auf Grundlage der Transkripte bewertet werden. In der Basisdimension SK waren damit insbesondere Indikatoren mit stark nonverbalem Charakter nur eingeschränkt oder nicht transkriptbasiert beurteilbar. Die Eignungseinstufungen der Indikatoren der Basisdimension SK sind in Abb. 5 dargestellt.




Abb. 5: Eignung der Indikatoren der Basisdimension SK für die transkriptbasierte Analyse.

5.2. Vergleich von menschlichen Bewertungen und KI-Bewertungen

In diesem Schritt wurden die Gesamtbewertungen der KI auf der vierstufigen Likert-Skala mit den gemittelten menschlichen Bewertungen verglichen. Für jedes Item wurden die Anzahl identischer und abweichender Bewertungen, die mittlere absolute Abweichung (MAD), die maximale Abweichung sowie die Mittelwerte der menschlichen Bewertungen und der KI-Bewertungen berechnet. Sofern möglich, wurde der Korrelationskoeffizient zwischen den beiden Bewertungsreihen berechnet. Die Anzahl der Bewertungspaare variiert itemweise, da nicht in allen Transkriptblöcken für jedes Item gültige Bewertungen vorlagen.

5.2.1. Kognitive Aktivierung

Für KA1 „Verständnisorientierung“ liegen 18 Bewertungspaare vor. In elf Transkriptblöcken stimmen die menschlichen Ratings und die KI-Bewertungen überein, in sieben Fällen weichen sie voneinander ab. Die MAD beträgt 0,31 Skalenpunkte bei einer maximalen Abweichung von einem Skalenpunkt. Der Mittelwert der menschlichen Bewertung liegt bei 3,69,

der Mittelwert der KI-Bewertungen liegt bei 4,00. Da in den KI-Bewertungen keine Varianz vorliegt, kann kein Korrelationskoeffizient berechnet werden.

Für KA2 „Ermittlung von Denkweisen und Vorstellungen“ liegen 17 Bewertungspaare vor. Mensch und KI stimmen in sieben der Transkriptblöcke überein und weichen in zehn Transkriptblöcken voneinander ab. Die MAD beträgt 0,5 Skalenpunkte, die maximale Abweichung 1,5 Skalenpunkte. Der Mittelwert der menschlichen Bewertungen liegt bei 3,38, der Mittelwert der KI-Bewertungen bei 3,61. Zwischen den beiden Bewertungsreihen zeigt sich eine mittlere, positive Korrelation ($r = 0,46$).

Für KA3 „Herausfordernde Aufgaben und Fragen“ liegen 16 Bewertungspaare vor. Die Bewertungen von Mensch und KI stimmen in 5 Transkriptblöcken überein, in 11 Blöcken weichen sie voneinander ab. Die MAD beträgt 0,59 Skalenpunkte bei einer maximalen Abweichung von einem Skalenpunkt. Der Mittelwert der menschlichen Bewertungen beträgt 3,16, der Mittelwert der KI-Bewertungen liegt bei 3,29. Zwischen den beiden Bewertungsreihen zeigt sich eine mittlere, positive Korrelation ($r = 0,40$).

Für KA4 „Engagement der SuS“ stehen 17 Bewertungspaare zur Verfügung. In sieben Fällen stimmen die Bewertungen überein, in zehn Fällen weichen sie voneinander ab. Die MAD beträgt 0,56 Skalenpunkte bei einer maximalen Abweichung von einem Skalenpunkt. Der Mittelwert der menschlichen Bewertungen liegt bei 3,91, der Mittelwert der KI-Bewertungen bei 3,35. Zwischen den beiden Bewertungsreihen zeigt sich eine schwache, positive Korrelation ($r = 0,25$). Die zentralen Vergleichskennwerte für die Items der Basisdimension KA sind in Tabelle 1 zusammengefasst.

Tabelle 1: Vergleich menschlicher und KI-basierter Bewertung für die Dimension KA

Item	N	$N_{\text{identisch}}$	$N_{\text{abweichend}}$	MAD	$\max. \Delta$	M_M	M_{KI}	r
KA1	18	11	7	0.31	1.0	3.69	4.00	-
KA2	17	7	10	0.50	1.5	3.38	3.61	0.46
KA3	16	5	11	0.59	1.0	3.16	3.29	0.40
KA4	17	7	10	0.56	1.0	3.91	3.35	0.25

N = Anzahl der bewerteten Blöcke; $N_{\text{identisch}}$ = Anzahl identischer Bewertungen; $N_{\text{abweichend}}$ = Anzahl abweichender Bewertungen; MAD = mittlere absolute Abweichung; $\max. \Delta$ = maximale Abweichung; M_M = Mittelwert der menschlichen Bewertungen; M_{KI} = Mittelwert der KI-Bewertungen; r = Pearson-Korrelationskoeffizient.

In der Basisdimension KA zeigen sich damit durchgängig eher geringe bis mittlere Abweichungen (MAD : 0,31 - 0,59) sowie überwiegend positive Zusammenhänge zwischen mensch-

lichen Bewertungen und KI-Bewertungen. Gleichzeitig variiert die Häufigkeit identischer Bewertungen je Item.

5.2.2. Konstruktive Unterstützung

Für KU1 „Qualität des Feedbacks“ liegen 17 Bewertungspaare vor. In einem Fall stimmt die Bewertung von Mensch und KI überein, in 16 Fällen weichen die Bewertungen voneinander ab. Die MAD beträgt 1,5 Skalenpunkte bei einer maximalen Abweichung von 2,5 Skalenpunkten. Der Mittelwert der menschlichen Bewertungen liegt bei 2,44, der Mittelwert der KI-Bewertungen bei 3,94. Zwischen den beiden Bewertungsreihen zeigt sich eine mittlere, negative Korrelation ($r = -0,34$).

Für KU2 „Individuelle Unterstützung im Lernprozess“ stehen 17 Bewertungspaare zur Verfügung. In sieben Fällen stimmen die Bewertungen überein, in zehn Fällen weichen sie voneinander ab. Die MAD beträgt 0,47 Skalenpunkte bei einer maximalen Abweichung von einem Skalenpunkt. Der Mittelwert der menschlichen Bewertungen liegt bei 2,71, der Mittelwert der KI-Bewertungen bei 3,12. Zwischen den beiden Bewertungsreihen zeigt sich eine mittlere, positive Korrelation ($r = 0,57$).

Für KU3 „Wertschätzung und Respekt“ liegen 17 Bewertungspaare vor. In einem Fall stimmen die Bewertungen überein, in 16 Fällen weichen sie voneinander ab. Die MAD beträgt 0,94 Skalenpunkte bei einer maximalen Abweichung von 1,5 Skalenpunkte. Der Mittelwert der menschlichen Bewertungen liegt bei 2,94, der Mittelwert der KI-Bewertungen bei 3,88. Zwischen den beiden Bewertungsreihen zeigt sich eine mittlere, positive Korrelation ($r = 0,48$).

Für KU4 „Klassenklima“ liegen 18 Bewertungspaare vor. In sechs Fällen stimmen die Bewertungen überein, in zwölf Fällen weichen sie voneinander ab. Die MAD beträgt 0,67 Skalenpunkte bei einer maximalen Abweichung von einem Skalenpunkt. Der Mittelwert der menschlichen Bewertungen liegt bei 4,00, der Mittelwert der KI-Bewertungen bei 3,33. Da in den menschlichen Bewertungen keine Varianz vorliegt, konnte kein Korrelationskoeffizient berechnet werden. Die Vergleichskennwerte für die Items der Basisdimension KU sind in Tabelle 2 dargestellt.

Tabelle 2: Vergleich menschlicher und KI-basierter Bewertungen für die Dimension KU

Item	N	$N_{\text{identisch}}$	$N_{\text{abweichend}}$	MAD	max. Δ	M_M	M_{KI}	r
KU1	17	1	16	1.50	2.5	2.44	3.94	-0.34
KU2	17	7	10	0.47	1.0	2.71	3.12	0.57
KU3	17	1	16	0.94	1.5	2.94	3.88	0.48
KU4	18	6	12	0.67	1.0	4.00	3.33	–

N = Anzahl der bewerteten Blöcke; $N_{\text{identisch}}$ = Anzahl identischer Bewertungen; $N_{\text{abweichend}}$ = Anzahl abweichender Bewertungen; MAD = mittlere absolute Abweichung; max. Δ = maximale Abweichung; M_M = Mittelwert der menschlichen Bewertungen; M_{KI} = Mittelwert der KI-Bewertungen; r = Pearson-Korrelationskoeffizient.

In der Basisdimension KU zeigt sich damit ein heterogenes Bild. Die mittleren Abweichungen reichen von 0,47 bis 1,5 Skalenpunkten bei einer insgesamt geringen Anzahl an identischen Bewertungen. Die Korrelationskoeffizienten variieren stark ($r = -0,34 - 0,57$).

5.2.3. Strukturierte Klassenführung

Für SK1 „Störungen durch SuS“ liegen 18 Bewertungspaare vor. In 17 Fällen stimmen die Bewertungen überein, in einem Fall weichen sie voneinander ab. Die MAD beträgt 0,03 Skalenpunkte bei einer maximalen Abweichung von 0,5 Skalenpunkte. Der Mittelwert der menschlichen Bewertungen liegt bei 3,97, der Mittelwert der KI-Bewertungen liegt bei 4,00. Da in den KI-Bewertungen keine Varianz vorliegt, konnte kein Korrelationskoeffizient berechnet werden.

Für SK2 „Monitoring“ liegen 18 Bewertungspaare vor. In keinem Fall stimmt die KI-Bewertung mit der menschlichen Bewertung überein. Die MAD beträgt 0,97 Skalenpunkte bei einer maximalen Abweichung von einem Skalenpunkt. Der Mittelwert der menschlichen Bewertungen liegt bei 3,97, der Mittelwert der KI-Bewertungen liegt bei 3,00. Da in den KI-Bewertungen keine Varianz vorliegt, konnte kein Korrelationskoeffizient berechnet werden.

Für SK3 „Zeitnutzung“ liegen 17 Bewertungspaare vor. In zwölf Fällen stimmen die Bewertungen überein, in fünf Fällen weichen sie voneinander ab. Die MAD beträgt 0,26 Skalenpunkte bei einer maximalen Abweichung von einem Skalenpunkt. Der Mittelwert der menschlichen Bewertungen liegt bei 3,79, der Mittelwert der KI-Bewertungen bei 3,94. Zwischen den beiden Bewertungsreihen zeigt sich eine geringe, negative Korrelation ($r = -0,13$). Eine Zusammenfassung der Vergleichskennwerte für die Items der Basisdimension SK bietet Tabelle 3.

Tabelle 3: Vergleich menschlicher und KI-basierter Bewertungen für die Dimension SK

Item	N	$N_{identisch}$	$N_{abweichend}$	MAD	max. Δ	M_M	M_{KI}	r
SK1	18	17	1	0.03	0.5	3.97	4.00	–
SK2	18	0	18	0.97	1.0	3.97	3.00	–
SK3	17	12	5	0.26	1.0	3.79	3.94	-0.13

N = Anzahl der bewerteten Blöcke; $N_{identisch}$ = Anzahl identischer Bewertungen; $N_{abweichend}$ = Anzahl abweichender Bewertungen; MAD = mittlere absolute Abweichung; max. Δ = maximale Abweichung; M_M = Mittelwert der menschlichen Bewertungen; M_{KI} = Mittelwert der KI-Bewertungen; r = Pearson-Korrelationskoeffizient.

In der Basisdimension SK zeigt sich insgesamt ein stark heterogenes Bild. Die Anzahl identischer Bewertungen (0 - 18) sowie die MAD (0,03 - 0,97) variieren zwischen den Items deutlich.

5.3. Aggregierter Vergleich auf Ebene der Basisdimensionen

5.3.1. Zusammenhang von Indikatoreignung und Mensch–KI-Übereinstimmung auf Itemebene

Die Eignung der Items für eine transkriptbasierte Analyse wurde über die Eignung ihrer Indikatoren operationalisiert (geeignet = 1; bedingt geeignet = 0,5; nicht geeignet = 0) und zu einem Eignungsscore aggregiert. Die Rangreihe in Tabelle 4 zeigt, dass KA1, KA3 und KU1 mit einem Score von 1,00 die höchste Eignung aufweisen, während SK2 mit 0,35 deutlich abfällt.

Tabelle 4: Zusammenhang zwischen Indikatoreignung und Übereinstimmung

Rang	Item	N_g	N_{bg}	N_{ng}	Eignungsscore	MAD	$N_{identisch} / N$ (in %)
1	KA1	11	0	0	1.00	0.31	61.1
1	KA3	10	0	0	1.00	0.59	31.3
1	KU1	11	0	0	1.00	1.50	5.9
2	KA2	8	1	0	0.94	0.50	41.2
3	KU2	8	0	1	0.89	0.47	41.2
4	SK1	5	2	0	0.86	0.03	94.4
5	KU3	7	1	1	0.83	0.94	5.9
6	KU4	7	4	0	0.82	0.67	33.3
6	SK3	8	2	1	0.82	0.26	70.6
7	KA4	7	2	1	0.80	0.56	41.2
8	SK2	0	7	3	0.35	0.97	0.0

N_g = Anzahl geeigneter Indikatoren; N_{bg} = Anzahl bedingt geeigneter Indikatoren; N_{ng} = Anzahl nicht geeigneter Indikatoren; Eignungsscore = normierter Kennwert zur quantitativen Einschätzung der Transkript-Eignung auf Itemebene; MAD = mittlere absolute Abweichung zwischen KI- und menschlichen Bewertungen; $N_{identisch} / N$ = Anteil identischer Bewertungen in Prozent.

Im Vergleich zwischen menschlichen Ratings und KI-Bewertungen zeigt sich jedoch, dass eine hohe Indikatoreignung nicht zwangsläufig mit hoher Übereinstimmung einhergeht. Besonders deutlich wird dies bei KU1. Trotz maximaler Eignung (1,00) weist das Item die größte mittlere Differenz ($MAD = 1,50$) und die zweitgeringste Übereinstimmungsquote (5,9%) auf. Demgegenüber erzielt SK1 trotz einer nicht optimalen Eignung (0,86) die höchste Übereinstimmung ($MAD = 0,03$; 94,4% identische Bewertungen). Die Ergebnisse zeigen, dass zwischen dem Eignungsscore der Items für eine transkriptbasierte Analyse und der Übereinstimmung zwischen menschlichen und KI-basierten Bewertungen insgesamt kaum ein Zusammenhang besteht (*Spearman- ρ* : Eignung vs. $MAD \approx -0,09$; Eignung vs. Anteil identischer Ratings $\approx +0,09$).

5.3.2. Verhältnis positiver und negativer Indikatoren und Richtung der KI-Abweichung

Zur Prüfung eines möglichen systematischen Effekts der Indikatorpolung wurde für jedes Item die Anzahl positiver und negativer Indikatoren erfasst und in Relation gesetzt (Positivanteil in %). Anschließend wurde geprüft, ob der Positivanteil mit der Richtung der Abweichung zwischen KI- und menschlichen Bewertungen zusammenhängt. Als Maß der Richtung wurde die Differenz der Mittelwerte $\Delta = MW(KI) - MW(Mensch)$ herangezogen. Eine Übersicht der Kennwerte enthält Tabelle 5.

Tabelle 5: Verhältnis der Indikatoren pro Item und Richtung der Abweichung

Item	N_{pos}	N_{neg}	N_{pos} / N (in %)	M_M	M_{KI}	$\Delta (M_{KI} - M_M)$
KA1	7	4	63.6	3.69	4.00	0.31
KA2	6	3	66.7	3.38	3.61	0.23
KA3	7	3	70.0	3.16	3.29	0.13
KA4	5	5	50.0	3.91	3.35	-0.56
KU1	8	3	72.7	2.44	3.94	1.50
KU2	6	3	66.7	2.71	3.12	0.41
KU3	5	4	55.6	2.94	3.88	0.94
KU4	6	5	54.5	4.00	3.33	-0.67
SK1	4	3	57.1	3.97	4.00	0.03
SK2	5	5	50.0	3.97	3.00	-0.97
SK3	6	5	54.5	3.79	3.94	0.15

N_{pos} = Anzahl positiver Indikatoren; N_{neg} = Anzahl negativer Indikatoren; N_{pos}/N (in %) = Anteil positiver Indikatoren in Prozent; M_M = Mittelwert der menschlichen Likert-Bewertungen; M_{KI} = Mittelwert der KI-Likert-Bewertungen; $\Delta (M_{KI} - M_M)$ = Differenz der Mittelwerte (positiv = KI bewertet höher als Mensch; negativ = KI bewertet niedriger).

Auf Itemebene zeigt sich ein positiver Zusammenhang zwischen dem Positivanteil der Indikatoren und der Richtung der Abweichung (Δ). Items mit höherem Positivanteil weisen tendenziell höhere KI-Mittelwerte im Vergleich zu den menschlichen Mittelwerten auf ($Spearman-\rho = 0,6865$; $n = 11$; $p = 0,0196$). Gleichzeitig zeigt sich kein Zusammenhang zwischen Positivanteil und der Größe der Abweichung, wenn diese richtungsunabhängig betrachtet wird ($Spearman-\rho$ (Positivanteil, MAD) = $0,0229$; $p = 0,9468$).

5.3.3. Rangreihe der Basisdimensionen nach Mensch–KI-Passung

Auf aggregierter Ebene der Basisdimensionen zeigt sich ein differenziertes Bild der Übereinstimmung zwischen menschlichen Ratings und KI-Bewertungen. Tabelle 6 zeigt die aggregierten Kennwerte zur Mensch-KI-Übereinstimmung auf Ebene der Basisdimensionen KA, KU und SK als sortierte Rangreihe.

Tabelle 6: Aggregierte Übereinstimmung auf Basisdimensionsebene (absteigend sortiert)

Basisdimension	N_{items}	N_{paare}	$N_{identisch}$	$N_{identisch} / N_{paare}$ (in %)	MAD*	MAD (min–max)
SK	3	53	29	54.7	0.42	0.03–0.97
KA	4	68	30	44.1	0.49	0.31–0.59
KU	4	69	15	21.7	0.89	0.47–1.50

N_{items} = Anzahl der Items je Basisdimension; N_{paare} = Anzahl der verglichenen Bewertungspaare (KI–Mensch) über alle Blöcke und Items der jeweiligen Basisdimension; $N_{identisch}$ = Anzahl identischer Bewertungen; $N_{identisch} / N_{paare}$ (in %) = Anteil identischer Bewertungen in Prozent; MAD* = gewichtete mittlere absolute Abweichung der Likert-Bewertungen zwischen KI und Mensch; MAD (min–max) = Spannweite der itembezogenen MAD-Werte innerhalb der jeweiligen Basisdimension.

Die höchste Passung zwischen menschlichen Bewertungen und KI-Bewertungen ergibt sich für die Basisdimension SK mit einem Anteil identischer Bewertungen von 54,7 Prozent, bei der zugleich niedrigsten gewichteten MAD (MAD = 0,42). KA erreicht eine mittlere Übereinstimmung (44,1% identisch; MAD = 0,49). Die geringste Übereinstimmung weist KU auf (21,7% identisch; MAD = 0,89).

6. Diskussion

6.1. Interpretation der Ergebnisse

6.1.1. Kognitive Aktivierung

In der Basisdimension KA zeigt sich eine moderate Übereinstimmung zwischen den KI-Bewertungen und den menschlichen Ratings. Aggregiert sind 44,1 Prozent der Bewertungen identisch und die gewichtete MAD beträgt 0,49 (Tab. 6). Auf Ebene der Basisdimension KA ergibt sich dadurch eine mittlere Passung bei einer geringen Abweichung. Ein Blick auf die Itemebene verdeutlicht jedoch eine gewisse Spannweite der Übereinstimmung (Tab. 1).

Das Item KA1 „Verständnisorientierung“ erreicht bei einem maximalen Eignungsscore von 1,00 innerhalb der Dimension KA die höchste Passung (Tab. 1; Tab. 4). Auch dimensionsübergreifend gehört KA1 mit 11 von 18 identischen Vergleichspaaren und einer MAD von 0,31 zu den Items mit der höchsten Übereinstimmung (Tab. 1; Tab. 4). Auffällig ist dabei, dass die KI alle Transkriptblöcke mit dem Höchstwert bewertet und damit im Mittelwert über der menschlichen Bewertung liegt (Tab. 1). Im Vergleich zu KA1 fällt die Passung bei den übrigen KA-Items geringer aus. Für KA2 „Ermittlung von Denkweisen und Vorstellungen“ ergibt sich trotz hoher Eignung eine MAD von 0,50 bei 7 von 17 identischen Vergleichspaaren und einer positiven Korrelation von $r = 0,46$ (Tab. 1). KA3 „Herausfordernde Aufgaben und Fragen“ schneidet innerhalb der Dimension KA, trotz maximaler Eignung mit einer MAD von 0,59 bei 5 von 16 Vergleichspaaren und einer positiven Korrelation von $r = 0,40$ am schwächsten ab. Für KA1, KA2 und KA3 liegt der KI-Mittelwert jeweils über dem menschlichen Mittelwert, was auf eine tendenzielle Überbewertung hinweist (Tab. 5). KA4 „Engagement der SuS“ wird demgegenüber im Mittelwert durch die KI um 0,56 Skalenpunkte niedriger bewertet, was auf eine Unterschätzung des beobachteten Engagements hindeutet (Tab. 5). Dabei sind 7 von 17 Vergleichspaare identisch, bei einer MAD von 0,56 und einer schwachen positiven Korrelation von $r = 0,25$ (Tab. 1).

Die überwiegend hohen Ergebnisse in der Eignungsanalyse sind zunächst erwartbar. Zentrale Aspekte der KA werden häufig in sprachlich vermittelten Interaktionsmustern realisiert und sind damit im Transkript grundsätzlich sichtbar (Göllner et al., 2025; Hamre & Pianta, 2010; Klieme, 2020). Entsprechend schneiden die Items der KA in der Indikatoreignung insgesamt hoch ab. KA1 und KA3 weisen einen maximalen Eignungsscore auf, KA2 liegt nur geringfügig darunter (Abb. 3; Tab. 4). KA4 erreicht hingegen einen der niedrigsten Eignungsscores

(Tab. 4). Gleichzeitig verdeutlicht die eignungsbasierte Rangreihe der Items, dass eine hohe Indikatoreignung keine hinreichende Bedingung für hohe Übereinstimmung ist. Dies zeigt sich besonders bei Item KA3, das trotz maximaler Eignung eine vergleichsweise geringe Übereinstimmungsquote und die höchste MAD innerhalb der KA-Dimension aufweist (Tab. 4; Tab. 2).

Die vergleichsweise hohe Übereinstimmung bei KA1 „Verständnisorientierung“ lässt sich theoretisch über die starke sprachliche Verankerung dieses Items einordnen. KA1 fokussiert die Zieltransparenz, Inhaltsfokussierung und Inhaltsverknüpfungen im Sinne von „Konzepten“ (Drollinger-Vetter, 2011). Ob sich die Lehrkraft im Unterrichtsverlauf an diesen Konzepten orientiert, ist im Transkript häufig gut erkennbar und kann daher auch durch die KI vergleichsweise zuverlässig bewertet werden. Die Indikatoren sind so operationalisiert, dass sie anhand sprachlicher Interaktionen (und im Kontext der Zeitstempel) beurteilt werden können, ohne visuelle oder paarverbale Informationen einzubeziehen (Fauth et al., 2024). Vor diesem Hintergrund sind die hohe Eignung, die hohe Passung und die geringe Abweichung plausibel.

KA2 „Ermittlung von Vorstellungen“ ist in konstruktivistischen Lerntheorien verankert, die davon ausgehen, dass Wissen aktiv auf Basis vorhandenen Wissens und Vorstellungen konstruiert werden muss (Kunter & Voss, 2011; Lauterbach et al., 2013). Dafür ist die Exploration des Vorwissens zentral. Die Exploration dieses Vorwissens erfolgt häufig über sprachliche Interaktionen (z. B. Erfragen, Erklärungen einfordern) und ist demnach gut im Transkript sichtbar (Fauth et al., 2024). Gleichzeitig kann die Segmentierung in 20-minütige Blöcke die Beurteilung erschweren. Nicht in jedem Segment ist eindeutig erkennbar, ob die Lehrkraft in ein Thema einsteigt, ohne das Vorwissen der SuS zu aktivieren oder zu berücksichtigen.

Die Abweichungen bei KA3 und KA4 lassen sich theoretisch über das Angebots-Nutzungs-Modell erklären (Fend, 1981; Helmke & Weinert, 1997). Im Transkript wird primär das pädagogische Angebot sichtbar, das in KA3 „Herausfordernde Aufgaben und Fragen“ abgebildet wird. Zentral ist dabei, dass Aufgaben dann herausfordernd sind, wenn sie über das bloße Aneignen von Faktenwissen hinaus gehen, kognitive Konflikte auslösen und durch das Einfordern von Erklärungen Potenzial für KA bieten (Lauterbach et al., 2013). Diese Merkmale werden im Unterrichtsdialog deutlich, wenn Aufgaben beispielsweise vorgelesen werden oder aus dem Unterrichtsgespräch hervorgehen. Trotzdem lässt sich das Potenzial zur KA im Unterrichtsdiskurs nicht aus einzelnen Fragen ableiten, sondern zeigt sich häufig erst in längeren

zusammenhängenden Gesprächssequenzen (Kunter & Voss, 2011). Die Segmentierung der Unterrichtseinheit kann solche Diskurse unterbrechen und damit die Analyse beeinflussen. Außerdem ist das Angebot ohne zusätzliche Kanäle nicht immer vollständig rekonstruierbar. Eine Ergänzung durch Unterrichtsmaterialien (z. B. Aufgabenblätter) könnte die Erfassung des kognitiven Potenzials zusätzlich absichern (Jordan et al., 2008; Kunter & Voss, 2011).

Demgegenüber adressiert KA4 „Engagement der SuS“ stärker die Nutzungsseite, also die tatsächliche kognitive Aktiviertheit der Lernenden. Die mäßige Übereinstimmung und geringe Korrelation bei KA4 deuten darauf hin, dass die KI Schwierigkeiten hat, die hoch inferenten Aspekte der Nutzungsseite zu erfassen. Das ist grundsätzlich plausibel, da kognitive Aktiviertheit interne mentale Prozesse betrifft, die nicht direkt beobachtbar sind (Fauth & Leuders, 2022). Dennoch gibt es beobachtbare Hinweise auf die Aktivität und Beteiligung (Fredricks et al., 2019). Kritische Nachfragen der SuS sind beispielsweise sprachlich markiert und können im Transkript als Indikatoren aktiver Beteiligung sichtbar werden (Fauth et al., 2024). Gleichzeitig liefern nonverbale Signale wie Mimik und Körperspannung sowie paraverbale Merkmale wie Tonfall Hinweise auf die Tiefe der Auseinandersetzung und emotionale Komponenten des Engagements (Fauth & Leuders, 2022; Praetorius & Charalambous, 2018; Praetorius et al., 2024). Menschliche Rater*innen können diese Signale nutzen, um Freude, Off-Task-Verhalten oder Lustlosigkeit besser einzuschätzen. Diese Informationen fehlen der KI. Diese Einschränkung passt zur schwachen Korrelation ($r = 0,25$) und mäßigen Passung bei Item KA4. Während das Transkript also primär das pädagogische Angebot der Lehrkraft (z. B. Aufgabenstellungen, Instruktionen) abbildet, bleibt die tatsächliche Nutzung durch die Lernenden (kognitive Aktiviertheit) im Text in Teilen unsichtbar (Fauth & Leuders, 2022; Kunter & Voss, 2011). Zusätzlich wirkten sich die spezifische Datengrundlage und das Audio-Setup limitierend aus. Da lediglich die Lehrkraft ein Ansteckmikrofon trug, kam es zu einer systematischen Unterrepräsentation von Schüler*innenbeiträgen im Transkript. Leise oder überlappende Äußerungen der Lernenden, die potenziell Rückschlüsse auf deren Denkprozesse erlaubt hätten, wurden somit unzuverlässig erfasst, was die Datenbasis zur Beurteilung der Nutzungsseite einschränkte.

Insgesamt zeigt sich für KA, dass die KI die transkriptbasierte Analyse im Hinblick auf F1 überwiegend als gut geeignet einstuft. Bezogen auf F2 ergibt sich eine moderate Überein-

stimmung mit den menschlichen Ratings bei vergleichsweise geringer MAD und insgesamt relativ homogener Passung.

Die Befunde für KA lassen sich schließlich in Bezug auf den Forschungsstand einordnen. Göllner et al. (2025) argumentieren, dass transkriptbasierte Analysen von „Lesson Semantics“ für die Erfassung von KA grundsätzlich geeignet sein können, da sich diese in sprachlich vermittelten Erklärungen der Lehrkraft und in der Moderation bzw. Facilitation von Unterrichtsdiskursen niederschlägt (Hamre & Pianta, 2010). In ihrer Studie zeigen semantische Komponenten die stärksten Zusammenhänge mit Ratings zu „students’ cognitive engagement“, während „multiple approaches“ als weitere aktivierungsnahe Facette deutlich schwächer vorhergesagt wird (Göllner et al., 2025). In Göllner et al. wird „students’ cognitive engagement“ jedoch primär als lehrkraftseitiges Angebotsmerkmal operationalisiert („opportunities to engage“), während „multiple approaches“ stärker die Lernendenseite adressiert, indem der Fokus auf den von SuS genutzten Vorgehensweisen zur Problemlösung liegt.

6.1.2. Konstruktive Unterstützung

Die Basisdimension der KU weist in der vorliegenden Untersuchung die geringste Übereinstimmung zwischen menschlichen Bewertungen und KI-Bewertungen auf (Tab. 6). Aggregiert betrachtet werden lediglich 21,7 Prozent der Transkriptblöcke identisch bewertet bei einer gewichteten MAD von 0,89, was die aggregierte Schwäche dieser Dimension im Vergleich der beiden Bewertungsansätze verdeutlicht (Tab. 6). Zugleich zeigt sich auf Itemebene ein deutlich heterogenes Profil, das für die Interpretation zentral ist (Tab. 2).

Besonders kritisch fällt der Befund für KU1 „Qualität des Feedbacks“ aus. Hier liegt bei 17 Vergleichspaaren nur eine einzige Übereinstimmung vor, die MAD beträgt 1,50 Skalenpunkte und die Korrelation zwischen den Bewertungsreihen ist negativ (Tab. 2). Während die menschlichen Rater*innen dieses Item im Mittel mit 2,44 einordneten, vergab die KI einen Mittelwert von 3,94 (Tab. 2). Dieser Befund ist bemerkenswert, da das Item KU1 in der Eignungsanalyse zu den am besten geeigneten Items für eine transkriptbasierte Analyse zählt (Tab. 4; Abb. 4). Damit wird ein zentrales Muster der Arbeit deutlich. Ein hohes Bewertungspotenzial von Indikatoren auf Transkriptbasis ist keine hinreichende Bedingung für eine hohe Übereinstimmung im globalen Itemrating (Tab. 4).

Im Gegensatz zu Item KU1 „Qualität des Feedbacks“ zeigt Item KU2 „Individuelle Unterstützung im Lernprozess“ als einziges Item der Basisdimension KU eine moderate Überein-

stimmung. KU2 erreicht mit 7 von 17 identischen Bewertungspaaren und einer positiven Korrelation von $r = 0,57$ eine moderate Passung (Tab. 2). Auch die MAD fällt mit 0,47 deutlich geringer aus als bei den übrigen Items der KU (Tab. 2). Die Items KU3 „Wertschätzung und Respekt“ sowie KU4 „Klassenklima“ bestätigen dagegen erneut die begrenzte Passung. KU3 „Wertschätzung und Respekt“ weist nur eine identische Bewertung auf und die MAD beträgt 0,94 (Tab. 2). Das Item KU4 „Klassenklima“ weist eine MAD von 0,67 bei 6 von 18 identischen Bewertungen auf (Tab. 2). Auffällig ist bei KU4, dass die Abweichungsrichtung im Mittel keine Überbewertung darstellt, sondern die KI bei diesem Item unter dem menschlichen Mittelwert liegt (Tab. 2; Tab. 5). Diese Konstellation spricht dafür, dass die Abweichungen innerhalb der KU nicht durch ein einheitliches Muster erklärt werden können, sondern dass die Subfacetten der Dimension und die jeweilige Beobachtbarkeit der relevanten Merkmale eine wichtige Rolle spielen.

Theoretisch lässt sich die geringe Übereinstimmung innerhalb der Basisdimension KU durch ihre spezifische inhaltliche und konzeptionelle Beschaffenheit einordnen. KU umfasst sowohl eine emotional-motivationale Subfacette, die Beziehung, Wertschätzung und Klima adressiert, als auch eine methodisch-didaktische Subfacette, die Feedback, adaptive Unterstützung und kognitive Gerüstbildung (Scaffolding) im Lernprozess einschließt (Fauth et al., 2024; Klieme, 2020; Sliwka et al., 2022).

Für die emotional-motivationale Unterstützung ist im Beobachtungsmanual explizit vorgesehen, nonverbale Interaktionen in die Bewertung einzubeziehen (Fauth et al., 2024). Arbeiten wie die von Paulmann und Weinstein (2023) zeigen, dass prosodische Merkmale der Lehrkraft wie Tonfall, Lautstärke und Sprechtempo einen starken Einfluss darauf haben, wie unterstützend und motivierend SuS die Interaktion wahrnehmen. Daraus ergibt sich ein struktureller Unterschied zwischen den Bewertungsgrundlagen. Während videobasierte Beobachtungen Tonfall, Mimik, Gestik, Blickkontakt und situatives Timing berücksichtigen können, steht der KI in dieser Untersuchung ausschließlich das sprachliche Transkript zur Verfügung. In der Indikatoranalyse wird dies dadurch sichtbar, dass bei mehreren Indikatoren der Items KU3 „Wertschätzung und Respekt“ sowie KU4 „Klassenklima“ eine erhöhte Nicht-Beurteilbarkeit auftritt, was auf die Relevanz nicht transkriptierter Informationskanäle verweist (Tab. 4; Abb. 4). Damit ist erklärbar, weshalb insbesondere relational und affektiv geprägte Qualitätsmerkmale in der Basisdimension KU im Transkript nur eingeschränkt bewertet werden können.

Für die methodisch-didaktische Subfacette ergibt sich ein differenziertes Bild. Dass KU2 „Individuelle Unterstützung im Lernprozess“ vergleichsweise besser abschneidet, ist theoretisch anschlussfähig. Scaffolding, Aufgabenstrukturierung und sprachlich realisierte Hilfestellungen sind eng an den Dialog zwischen der Lehrkraft und den Lernenden gebunden. Dadurch sind diese Unterstützungsformen im Transkript häufiger direkt nachvollziehbar (Sliwka et al., 2022). Zudem ist das Ergebnis auch deshalb plausibel, weil die Angebotsseite der KA in den Befunden ebenfalls vergleichsweise gut abbildbar ist. Scaffolding wird auch als Brücke zwischen KU und KA beschrieben, da es Lernprozesse so strukturiert, dass anspruchsvolle Auseinandersetzung ermöglicht und angeregt wird (Fauth & Leuders, 2022; Sliwka et al., 2022). Gleichzeitig zeigt das Item KU1 „Qualität des Feedbacks“, dass auch methodisch-didaktische Aspekte stark kontextabhängig sein können. Feedback ist nicht nur eine Frage des propositionalen Gehalts, sondern auch der Passung, des Timings und der kommunikativen Einbettung (Fauth et al., 2024; Hattie & Timperley, 2007). Wenn eine Rückmeldung zwar fachlich korrekt formuliert ist, aber in einem herabsetzenden oder ironischen Tonfall geäußert wird, bleibt diese affektive Komponente im Transkript unsichtbar und kann von der KI folglich nicht berücksichtigt werden.

Ein weiterer zentraler Mechanismus für die beobachteten Diskrepanzen liegt in einem Bias, der aus der Instrumentenstruktur selbst resultiert. Die KI leitet ihre Likert-Bewertung größtenteils aus dem Verhältnis erkannter positiver zu negativer Indikatoren ab. Das Verhältnis von Positiv- zu Negativindikatoren ist in Teilen des Instruments jedoch unausgeglichen (Tab. 5). In der Folge werden die verbalen Positivindikatoren in der KI-Bewertung überproportional stark einbezogen, was den beobachteten positiven Bias (insbesondere bei KU1, KU2 und KU3) plausibel erklärt. KU1 weist den höchsten Anteil positiver Indikatoren (72,7 %) auf und wird von der KI im Mittel deutlich höher bewertet als von den menschlichen Rater*innen (Tab. 5). KU4 hingegen zeigt (ähnlich wie KU3) ein nahezu ausgeglichenes Verhältnis zwischen positiven und negativen Indikatoren (Tab. 5). Allerdings werden bei KU4 vier der sechs Positivindikatoren als bedingt geeignet bewertet (siehe Anhang). Dadurch kann in einzelnen Transkriptblöcken ein relatives Übergewicht der (besser erfassbaren) Negativindikatoren entstehen, was die deutliche Abweichung der KI-Mittelwerte in die entgegengesetzte Richtung erklären könnte.

Insgesamt kann argumentiert werden, dass die Items der KU von paraverbalen und nonverbalen Merkmalen abhängen (Göllner et al., 2025; Lazarides et al., 2025). Das spiegelt sich in geringen Passungen und vergleichsweise hohen mittleren absoluten Abweichungen wider. Eine Ausnahme bildet KU2. Durch die dialogbasierte Struktur und die Nähe zur kognitiven Aktivierung erreicht das Item eine moderate Passung bei vergleichsweise geringer mittlerer absoluter Abweichung.

Insgesamt wird für KU im Hinblick auf F1 eine grundsätzliche Eignung der transkriptbasierten KI-Analyse angenommen. Bezüglich F2 weist KU jedoch die geringste Übereinstimmung mit den menschlichen Ratings auf.

Die Befunde lassen sich zudem in Bezug auf die Erwartung einordnen, dass transkriptbasierte Semantikanalysen Aspekte von Lernunterstützung abbilden können. Göllner et al. (2025) erwarteten, dass transkriptbasierte „Lesson Semantics“ Aspekte des „learning support“ abbilden können, da diese in der Moderation von Unterrichtsdiskursen und der emotionalen Reaktivität sichtbar werden (Hamre & Pianta, 2010). Sie zeigen ebenfalls, dass sich innerhalb der Lernunterstützung vor allem diskursive Facetten gut vorhersagen lassen, während „encouragement and warmth“ schwächer ausfällt, vermutlich weil hier nonverbale Kommunikationssignale bedeutsam sind, die Transkripte nicht erfassen (Göllner et al., 2025; Lazarides et al., 2025). Damit wird die zentrale Grenze transkriptbasierter Analysen von KU empirisch sichtbar und zugleich theoretisch begründbar.

6.1.3. Strukturierte Klassenführung

Die Basisdimension SK erreicht im Vergleich mit KA und KU die höchste Übereinstimmung zwischen den KI-Bewertungen und den menschlichen Bewertungen (Tab. 6). Auf aggregierter Ebene stimmen 54,7 Prozent der Bewertungen überein, bei der zugleich niedrigsten gewichteten MAD von 0,42 Skalenpunkten (Tab. 6). Auf Itemebene zeigt sich innerhalb der Basisdimension SK jedoch ein stark heterogenes Profil, das für die Interpretation zentral ist (Tab. 3).

Für SK1 „Störungen durch SuS“ ergibt sich eine nahezu perfekte Passung zwischen den menschlichen Bewertungen und den KI-Bewertungen. Bei 18 Bewertungspaaren sind 17 Bewertungen identisch, die MAD beträgt 0,03 Skalenpunkte, bei einer maximalen Abweichung von 0,5 Skalenpunkten, was dimensionsübergreifende Bestwerte darstellt (Tab. 3). Für SK3 „Zeitnutzung“ zeigt sich ebenfalls eine vergleichsweise hohe Passung. Bei 17 Bewertungspaaren sind 12 Bewertungen identisch, die MAD beträgt 0,26 Skalenpunkte und die maximale Ab-

weichung liegt bei 1,0 Skaleneinheiten (Tab. 3). SK3 weist nach SK1 die zweithöchste Passung auf (Tab. 3; Tab. 5). Die geringe negative Korrelation (Tab. 3) deutet auf eine gegenläufige Variation der Bewertungsreihen hin, während die geringe Mittelwertdifferenz (Tab. 5) durch eine Kompensation von Über- und Unterbewertungen erklärbar ist. Im Gegensatz zu den guten Ergebnissen von SK1 und SK3, markiert SK2 „Monitoring“ eine zentrale Einschränkung der transkriptbasierten KI-Bewertung. Für dieses Item stimmen bei 18 Bewertungspaaren keine Bewertungen überein und die MAD beträgt 0,97 Skaleneinheiten, bei einer maximalen Abweichung von 1,0 Skaleneinheiten (Tab. 3). Die geringe Passung ist vor dem Hintergrund des sehr niedrigen Eignungsscores von 0,35 erwartbar, da für das Item kein Indikator als geeignet, sieben Indikatoren als bedingt geeignet und drei Indikatoren als nicht geeignet klassifiziert wurden (Tab. 5). Die beobachtete Diskrepanz zwischen den vergleichsweise großen Übereinstimmungen bei SK1 und SK3 und der fehlenden Passung von SK2 lässt sich theoriegeleitet über die Konzeption der Basisdimension SK erklären.

Die SK ist theoretisch vor allem im ökologisch-psychologischen Ansatz nach Kounin (1976) verankert, der wirksame Steuerung weniger als Reaktion auf Störungen, sondern als proaktive und präventive Regulation des Unterrichtsgeschehens konzeptualisiert (Klieme & Rakoczy, 2008; Ophardt & Thiel, 2008). Im Zentrum stehen die Konstrukte Allgegenwärtigkeit und Überlappung. Sie beziehen sich auf die kontinuierliche Wahrnehmung relevanter Ereignisse im Klassenraum sowie auf die Fähigkeit, mehrere Interaktions- und Arbeitsprozesse gleichzeitig zu koordinieren (Kounin, 1976; Kunter & Voss, 2011). SK2 „Monitoring“ adressiert insbesondere die Allgegenwärtigkeit im Sinne Kounins sowie Aspekte der Störungsprävention und Störungsintervention. Im Zentrum stehen dabei die Präsenz der Lehrkraft im Raum, die Blickrichtung, das simultane Wahrnehmen paralleler Prozesse und das rechtzeitige Aufgreifen sich anbahnender Störungen (Fauth et al., 2024). Dieses proaktive und präventive Verhalten ist eng an visuell situative Informationen gekoppelt, die menschliche Beobachter*innen anhand von Videoaufnahmen erfassen können, die im Transkript jedoch nicht abgebildet sind. Entsprechend zeigt die Eignungsanalyse, dass beim Item SK2 sieben Indikatoren als bedingt geeignet und drei Indikatoren als nicht geeignet eingestuft wurden (Abb. 5; Tab. 4). Zudem treten besonders hohe Anteile von 99 Bewertungen bei Indikatoren auf, die Raumpräsenz, Blickrichtung und das Übersehen von Meldungen betreffen. Unter Berücksichtigung der Eignungsanalyse und der Konzeption des Items ist die fehlende Übereinstimmung als strukturelle Modalitätsgrenze einer rein transkriptbasierten Erfassung von Monitoring zu bewerten.

Die sehr hohe Übereinstimmung bei SK1 „Störungen durch SuS“ ist bemerkenswert, sollte aber kritisch eingeordnet werden. In den vorliegenden Unterrichtssequenzen treten kaum explizite verbale oder nonverbale Störungen auf. Das kann die hohen und übereinstimmenden Bewertungen durch die menschlichen Rater*innen sowie durch die KI erklären. Gleichzeitig besteht bei einer transkriptbasierten Analyse von SK1 die Gefahr eines Ruhe-Bias. Die empirische Erfassung von SK gilt generell als herausfordernd, da erfolgreiche SK häufig implizit geschieht (Ophardt & Thiel, 2008) und das Ausbleiben von Störungen oder Unterbrechungen selbst als Indikator für gelingende Klassenführung interpretiert werden kann (Kunter & Voss, 2011). Vor diesem Hintergrund ist es naheliegend, dass die KI aus der Abwesenheit negativer Ereignisse systematisch die höchstmögliche Bewertung ableitet. Zwei Indikatoren des Items SK1 wurden als bedingt geeignet eingestuft, weil zentrale Informationen wie die Lautstärke im Raum oder das Ausmaß von Unruhe im Klassenverband aus den Transkripten nicht zuverlässig erschließbar sind. Hinzu kommt, dass die SuS nicht mit Individualmikrofonen ausgestattet waren. Dadurch konnten leises Gemurmel, kurze Dialoge zwischen Sitznachbar*innen oder andere Geräusche aus den Reihen der Lernenden teilweise nicht erfasst und folglich nicht transkribiert werden. Nonverbale Störungen wie das Werfen von Gegenständen, das Austauschen von Zetteln oder das Schneiden von Grimassen, die im Beobachtungsmanual explizit als Beispiele genannt werden, sind in einfachen Transkripten nicht abgebildet und können daher in der KI-Bewertung nicht als negative Evidenz berücksichtigt werden (Fauth et al., 2024).

Gelungene Klassenführung zeigt sich zudem in der effektiven Nutzung der Unterrichtszeit. Der Unterricht sollte so organisiert und geführt werden, dass ein möglichst großer Anteil der verfügbaren Zeit für Lernaktivitäten und die Auseinandersetzung mit Lerninhalten genutzt wird. Ein hoher Anteil von „Time on Task“ gilt dabei als wichtiger Prädiktor für die Leistungsentwicklung von SuS (Kunter & Voss, 2011). Darüber hinaus kann eine gut strukturierte und störungsarme Unterrichtsorganisation motivationale Effekte auf Seiten der SuS begünstigen (Fauth et al., 2024; Kunter et al., 2007). SK3 „Zeitnutzung“ erfasst genau diese Aspekte der Klassenführung. Die vergleichsweise hohe Übereinstimmung bei SK3 ist anschlussfähig, da sich Indikatoren wie die Fokussierung auf fachliche Inhalte oder ein geplanter und strukturierter Unterricht gut aus den verbalen Interaktionen (im Zusammenhang mit den Zeitstempeln der Transkripte) ableiten lassen. Gleichzeitig ist zu berücksichtigen, dass zwei Indikatoren zum pünktlichen Stundenbeginn und zum runden Stundenabschluss durch die Segmentie-

rung in 20-minütige Blöcke nicht oder nur eingeschränkt beurteilbar waren. Das erklärt den vergleichsweise niedrigen Eignungsscore (Tab. 4).

Insgesamt zeigt die Basisdimension SK im Hinblick auf F1 ein ambivalentes Muster, da Störungsfreiheit und Aspekte der Zeitnutzung die transkriptbasierte KI-Analyse als vergleichsweise gut geeignet erscheinen lassen, während insbesondere SK2 „Monitoring“ als zentraler Bestandteil erfolgreicher Klassenführung als eher ungeeignet eingestuft wird. Bezogen auf F2 bestätigt sich diese Uneinheitlichkeit, da die aggregierte Passung zwar insgesamt hoch ausfällt, die Übereinstimmung jedoch vor allem durch SK1 und SK3 getragen wird und sich dort in einer hohen Übereinstimmung bei geringer MAD zeigt, während Monitoring nicht valide abbildbar ist.

Göllner et al. (2025) argumentieren, dass zentrale Merkmale der Klassenführung stärker an nonverbale Verhaltensweisen wie Blickrichtung und Bewegung gebunden sind und daher in Transkripten nur unvollständig abgebildet werden können (Martikainen, 2020). Vor diesem Hintergrund untersuchen sie Klassenführung in ihrer Studie nicht empirisch, sondern beschränken sich auf Dimensionen, die stärker im verbalen Unterrichtsgeschehen verankert sind.

6.2. Methodologische Limitationen

Die Interpretation der Befunde ist an zentrale methodologische Rahmenbedingungen gebunden, die sowohl die Datengrundlage als auch den Referenzstandard, die analytischen Entscheidungen und den Einsatz eines kommerziellen Large Language Models betreffen. Diese Limitationen beeinflussen die Ergebnisse dimensionsübergreifend.

6.2.1. Transkriptbasierte Limitationen

Eine zentrale Limitation der Untersuchung ergibt sich aus der verwendeten Datengrundlage. Wörtliche Unterrichtstranskripte ermöglichen auch ohne Zugriff auf Videoaufnahmen die Analyse sprachlicher Interaktionen im Unterrichtsgeschehen (Junker et al., 2020). Insbesondere detaillierte Transkripte, die neben verbalen Äußerungen auch Gesten-/Mimik-Protokolle umfassen, können dazu beitragen, die Komplexität und Simultanität des Unterrichtsgeschehens für nachfolgende Interpretationen und Beurteilungen zu erfassen (Herrle et al., 2010; Reh, 2012). Die KI-Bewertungen der vorliegenden Untersuchung basieren jedoch auf einfachen, automatisch generierten Unterrichtstranskripten ohne Regieanweisungen und ohne systematische Erfassung nonverbaler oder paraverbalen Informationen. Damit fehlen der KI zen-

trale Informationskanäle wie Tonfall, Lautstärke, Blickkontakt, Raumpräsenz, Mimik, Gestik und situative Dynamiken, obwohl diese für einzelne Indikatoren und Items des eingesetzten Beobachtungsinstruments (ausdrücklich) relevant sind (Fauth et al., 2024). Auf dieser Grundlage kann beispielsweise nicht beurteilt werden, ob eine positive Äußerung als wertschätzendes Lob oder als ironische Abwertung zu verstehen ist (Beck & Scholz, 2012). Die Reduktion der Modalität ist damit eine zentrale Ursache für die eingeschränkte Beurteilbarkeit einzelner Indikatoren und erklärt, weshalb insbesondere visuell oder paarverbal konzeptualisierte Merkmale im transkriptbasierten Verfahren strukturell benachteiligt sind. Prinzipiell könnten aufwendigere manuell erstellte Transkripte einen Teil dieser Lücken schließen. Dies steht aber durch die kostspielige, mühsame und zeitaufwendige Erstellung im Spannungsfeld zu dem methodischen Ziel, eine effiziente, ressourcenschonende und automatisierte Analysemethode zu entwickeln (Gencoglu et al., 2023; Schlotterbeck et al., 2021; Schonlau & Couper, 2016).

Die Einschränkungen der Transkriptgrundlage werden durch das Audio-Setup weiter verstärkt. Da lediglich die Lehrkraft ein Ansteckmikrofon trug, sind Beiträge der SuS in Teilen unterrepräsentiert. Leise Äußerungen, parallele Gespräche und überlappende Beiträge werden in diesem Setting schlechter erfasst und werden folglich im Transkript nur unvollständig abgebildet. Damit fehlen der KI potenziell relevante Hinweise auf Denkprozesse, Beteiligungsdynamiken, Interaktionsqualität und Störereignisse. Dies betrifft zum einen die Angebotsseite im Sinne des Angebots-Nutzungs-Modells, die für KA, KU und SK konzeptuell bedeutsam ist. Zum anderen betrifft es die Nutzungskomponente, die insbesondere für die KA relevant ist. Darüber hinaus kann es die Sichtbarkeit von Störungen im Transkript reduzieren und damit einen Ruhe-Bias bei der SK begünstigen (Fauth & Leuders, 2022; Fend, 2006; Klieme & Rakoczy, 2008; Kunter & Voss, 2011). Hinzu kommt die Segmentierung der Unterrichtseinheiten in 18 Transkriptblöcke. Die Segmentierung ist für eine standardisierte Analyse notwendig, kann jedoch Kontextbrüche erzeugen. Wenn relevante Vorläufe oder Anschlusssequenzen außerhalb eines Segments liegen, kann dies die Beurteilbarkeit einzelner Indikatoren reduzieren und die KI-Bewertung stärker an punktuelle Signale binden als an prozessuale Entwicklung. Zudem sind Aspekte der Basisdimensionen nicht in allen Phasen des Unterrichts gleich stark ausgeprägt (Fauth et al., 2024). Eine segmentierte Betrachtung einer Unterrichtsstunde kann die phasenabhängige Varianz des Potenzials zur KA zwischen verschiedenen Unterrichtsphasen eingeschränkt abbilden. Das Beobachtungsmanual argumentiert explizit, dass die

beobachteten Verhaltensweisen im Kontext der Phase und Zielsetzung anzuwenden sind (Fauth et al., 2024).

6.2.2. Limitation durch das Beobachtungsinstrument

Zu berücksichtigen ist außerdem, dass das verwendete Beobachtungsinstrument nicht für eine transkriptbasierte oder KI-gestützte Analyse von Unterrichtsqualität entwickelt wurde. Es dient primär der kriteriengeleiteten Unterrichtsvorbereitung, der Selbstreflexion sowie als Grundlage für Feedback und Beratung bei Unterrichtsbesuchen oder Hospitationen (Fauth et al., 2024). Mehrere Indikatoren setzen (explizit) visuelle oder paraverbale Informationen voraus und sind daher im Transkript nur eingeschränkt beurteilbar. Darüber hinaus ist das Verhältnis positiv zu negativ formulierter Indikatoren zwischen den Items weder standardisiert noch ausgeglichen. Für das Item KU1 sind im Beobachtungsinstrument beispielsweise acht positive und drei negative Indikatoren definiert. Für SK3 sind hingegen sechs Indikatoren positiv definiert und fünf Indikatoren negativ formuliert (Fauth et al., 2024). In einer transkriptbasierten KI-Logik kann dies systematische Verzerrungen begünstigen, wenn die Bewertung faktisch aus dem Verhältnis erkannter positiver und negativer Indikatoren abgeleitet wird. Die Ergebnisse zeigen klar, dass Items mit einem höheren Anteil positiver Indikatoren tendenziell höhere KI-Mittelwerte im Vergleich zu den menschlichen Mittelwerten aufweisen (Tab. 5). Da im Beobachtungsmanual keine formalisierte Gewichtungsregel der einzelnen Indikatoren vorgegeben ist, liegt es nahe, dass die KI die globale Bewertung über die beobachtete Indikatorbilanz ableitet. Wenn einzelne Items so konzipiert sind, dass entweder positive oder negative Indikatoren überproportional ungeeignet sind, können zusätzliche Verzerrungen entstehen, selbst wenn das Ausgangsverhältnis der Indikatoren formal ausgeglichen wäre. Damit ist ein Teil der beobachteten Abweichungsmuster nicht nur auf das Modell zurückzuführen, sondern auch auf die eingeschränkte Passung zwischen Instrumentenlogik und Datenmodalität.

Die Validität des Beobachtungsinstruments ist durch umfangreiche Begleitstudien überprüft und bestätigt worden (Fauth et al., 2024). Dennoch muss die Gültigkeit des Instruments im Kontext der Debatte um die fachspezifische Ausdifferenzierung von Unterrichtsqualität verortet werden (Praetorius & Charalambous, 2018; Praetorius et al., 2020b). Eine konzeptionelle Limitation besteht darin, dass die Basisdimensionen zwar als generische Konzepte postuliert werden, ihre Wirksamkeit und konkrete Ausgestaltung jedoch maßgeblich vom Fach und vom jeweiligen Lerngegenstand abhängen. Dies gilt insbesondere für die KA, die in der Fachlitera-

tur zunehmend als inhalts- und gegenstandsabhängig beschrieben wird (Klieme et al., 2006; Praetorius et al., 2018; Praetorius et al., 2014). Da viele empirische Befunde zur KA aus dem Mathematik- und Naturwissenschaftsunterricht stammen, ist die Konzeption der KA entsprechend stark von diesen Fächern geprägt (Klieme, 2006; Praetorius et al., 2020b). Die Übertragung auf sozialwissenschaftliche Lernbereiche und damit auf den Wirtschaftsunterricht erfordert daher konzeptionelle Anpassungen (Helmke & Klieme, 2008; Klieme & Rakoczy, 2008). Im Wirtschaftsunterricht sind insbesondere „Handlungsorientierung“ sowie „Urteilsbildung und Entscheidungsfindung“ eng mit KA verknüpft (Platz et al., 2025). Diese fachspezifischen Besonderheiten der KA werden im Beobachtungsinstrument nicht berücksichtigt.

6.2.3. KI-spezifische Limitationen

Die KI-Analyse basiert auf dem kommerziellen LLM ChatGPT, dessen interne Funktionsweise nicht transparent ist. Das Black-Box-Problem, das die mangelnde Nachvollziehbarkeit komplexer neuronaler Netzwerke beschreibt, begrenzt die Überprüfbarkeit der KI-Bewertungen und erschwert eine reliabilitätsbezogene Einordnung (Branda et al., 2025). Die internen Prozesse der Informationsverarbeitung und Entscheidungsfindung bleiben damit methodisch weitgehend unzugänglich. Damit steigt zugleich das Risiko automatisierter Schlussfolgerungen, bei denen auch scheinbar plausible oder erwartbare Ergebnisse nicht zwingend auf einer theoriegeleiteten, kontextsensitiven Auswertung beruhen, sondern aus statistischen Regularitäten ohne gesicherte Begründungslogik entstehen können (Branda et al., 2025; Wang et al., 2023). Ansätze erklärbarer KI können diese Problematik perspektivisch abschwächen, indem sie Einblicke in relevante Entscheidungskriterien und die Entstehung von Outputs geben, bleiben im Kontext kommerzieller LLMs jedoch nur begrenzt verfügbar (Schneider, 2025).

Hinzu kommt, dass KI-Systeme eine hohe Sensitivität gegenüber der Formulierung von Prompts aufweisen (Khlaif et al., 2023; Kizilcec, 2023). Bereits kleine Nuancen in der Instruktion oder Rollenzuweisung im Prompt können zu unterschiedlichen Analyseergebnissen führen (Khlaif et al., 2023). Da LLMs probabilistische Systeme sind, können selbst bei identischen Inputs unterschiedliche Outputs entstehen (Pietrusky, 2025). In der vorliegenden Untersuchung wurde durch die Anpassung von Parametern wie der Temperatur von null versucht, die Variabilität zu minimieren. Dennoch verbleibt eine stochastische Restunsicherheit, die die Reproduzierbarkeit einschränkt (Göllner et al., 2025; Pietrusky, 2025).

Die Validität und Generalisierbarkeit der Ergebnisse kann zudem durch algorithmische Verzerrung beeinträchtigt werden (Min, 2023; Scheiter et al., 2025). KI-Systeme lernen aus Mustern ihrer Trainingsdaten und können dabei vorhandene gesellschaftliche Vorurteile oder historische Ungleichheiten reproduzieren und verstärken (Branda et al., 2025). Dies kann im Kontext der Unterrichtsbeurteilung zu verzerrten Bewertungen führen, wenn das Modell beispielsweise bestimmte Interaktionsstile einseitig bevorzugt oder benachteiligt (Scheiter et al., 2025).

Ergänzend ist das Risiko von Halluzinationen zu berücksichtigen, bei denen GenKI-Modelle zwar plausible, aber faktisch falsche oder irreführende Begründungen für ihre Bewertungen generieren (Branda et al., 2025; Perković et al., 2024). Ohne eine durchgängige menschliche Validierung im Sinne eines „Human-in-the-Loop-Ansatzes“ besteht die Gefahr, dass fehlerhafte KI-Schlüsse unentdeckt bleiben (Branda et al., 2025). In der vorliegenden Untersuchung wurde diesem Risiko durch klare Instruktionen begegnet, die Bewertung strikt auf das Transkript zu stützen und bei fehlender Evidenz konsequent 99 zu vergeben. Die systematische Nutzung von 99 kann damit auch als Schutzmechanismus verstanden werden, der die Modellantworten an die Grenzen der Datenmodalität bindet und die Gefahr unbegründeter Zuschreibungen reduziert. Gleichwohl lässt sich nicht vollständig ausschließen, dass das Modell implizite Annahmen nutzt oder sprachliche Hinweise überinterpretiert, insbesondere bei hoch inferenten Items.

6.2.4. Limitationen durch den Referenzstandard

Der Referenzstandard besteht in der vorliegenden Untersuchung aus videobasierten menschlichen Ratings. Ein zentrales Potenzial videobasierter Unterrichtsbeobachtungen liegt in der wiederholbaren Betrachtung und Re-Analyse aufgezeichneter Sequenzen (Pauli & Reusser, 2006). Dies ermöglicht es, einen Unterrichtsprozess aus unterschiedlichen Perspektiven und unter verschiedenen Fragestellungen zu analysieren (Gabriel, 2014). Darüber hinaus ermöglichen Videoaufnahmen den Zugang zu einer Pluralität gleichzeitig auftretender Äußerungsmodalitäten und zum simultanen Agieren verschiedener Personen (Herrle & Breitenbach, 2016). In der vorliegenden Untersuchung liegen die menschlichen Bewertungen zudem als aggregierte Mehrfachratings vor. Dies erhöht die Objektivität, da rater-spezifische Varianz reduziert wird und sich die Reliabilität durch den Einsatz mehrerer Rater*innen deutlich verbessern kann (Hill et al., 2012). Gleichzeitig bleiben Unterrichtsbeobachtung, insbesondere auf Tie-

fenstrukturebene, hoch inferent. Auch geschulte Rater*innen müssen komplexe Unterrichtssituationen interpretieren und Evidenz im Kontext normierter Kriterien gewichten, wodurch ein begrenzter Interpretationsspielraum bestehen bleibt (Clausen et al., 2003; Gabriel, 2014). Entsprechend zeigen selbst etablierte Beobachtungssysteme eine gewisse Variabilität in menschlichen Einschätzungen, auch wenn Training und Standardisierung eingesetzt werden (White & Ronfeldt, 2024). Die menschlichen Ratings enthalten in diesem Datensatz Zwischenwerte wie 3,5, weil menschliche Rater*innen bei hoch inferenten Einschätzungen nicht selten um eine Skalenstufe voneinander abweichen. Eine Abweichung der KI um 0,5 - 1,0 Skalenpunkte ist daher nicht automatisch als schwerwiegend zu bewerten. Hinzu kommt, dass die KI-Werte zwangsläufig ganzzahlig sind. Dieser Unterschied reduziert die Anzahl potenziell identischer Paarungen und kann das Übereinstimmungsmaß „Anteil identischer Bewertungen“ systematisch unterschätzen. Abweichungen zwischen KI und Mensch sind daher nicht als eindeutige Fehler der KI zu deuten, sondern als Differenzen zwischen zwei Bewertungsverfahren.

Außerdem umfasst die Stichprobe 18 Segmente und damit eine begrenzte Fallzahl für stabile statistische Schätzungen auf Itemebene. Bei kleinen N können Kennwerte stärker durch einzelne Fälle beeinflusst sein und die Konfidenz der Schätzungen ist begrenzt. Daraus folgt, dass die Ergebnisse als explorative Validierungsbefunde für das untersuchte Material verstanden werden müssen und dass keine starken Generalisierungen abgeleitet werden sollten.

6.3. Ausblick und Implikationen

6.3.1. Multimodale Erweiterung und Instrumentenpassung

Die Befunde legen nahe, dass die nächste Entwicklungsstufe KI-gestützter Unterrichtsanalyse in der Integration zusätzlicher Modalitäten liegt. In der Indikatoranalyse wurden klare Grenzen der Transkriptmodalität sichtbar. Besonders auffällig ist die erhöhte Nichtbeurteilbarkeit bei visuell oder paraverbal konzeptualisierten Indikatoren sowie die damit verbundenen Bias-Muster. Das spricht für multimodale Verfahren, die Audio- und Video-Informationen systematisch einbeziehen. Für KU wären insbesondere paraverbale und prosodische Merkmale wie Betonung, Lautstärke, Sprechtempo und Tonfall relevant, da sie relationalen Gehalt und affektive Nuancen transportieren, die im Transkript nicht erfasst werden (Göllner et al., 2025; Lazarides et al., 2025). Hunkins, Kelly und D’Mello (2022) zeigen in diesem Kontext, dass sich aus Unterrichtsaudio prosodische und paarverbale Merkmale automatisiert extrahieren lassen.

Diese Merkmale können anschließend genutzt werden, um verschiedene Kategorien unterstützender bzw. unterminierender Lehrkraftäußerungen zu klassifizieren.

Für SK sind visuelle Merkmale wie Raumpräsenz, Blickrichtung, Bewegung und simultanes Monitoring der Lehrkraft zentral. Genau diese Informationen fehlen in transkriptbasierten Ratings und zeigen sich in hohen 99-Anteilen und geringerer Übereinstimmung. Ahuja et al. (2021) zeigen in diesem Zusammenhang, dass sich die Blickrichtung der Lehrkraft näherungsweise über Kopfpose aus Unterrichtsvideos schätzen lässt und daraus über eine Stunde hinweg Blickverläufe und Aufmerksamkeitsmuster im Raum rekonstruiert werden können. Ergänzend zeigen Cortina et al. (2015), dass sich das Monitoring der Lehrkraft über mobile Eye-Tracking-Daten operationalisieren lässt, indem die Verteilung von Blickfixationen auf SuS als Indikator für simultanes Klassenmonitoring ausgewertet wird.

Für KA könnte eine multimodale Erweiterung durch Unterrichtsartefakte (z. B. Aufgaben, Klassenarbeiten) die Einschätzung des kognitiven Potenzials zusätzlich absichern (Jordan et al., 2008). Ergänzend können bei KA auch nonverbale Merkmale wie Meldeaktivität, Körperspannung oder Mimik Hinweise auf kognitive Beteiligung geben (Praetorius et al., 2024). Goldberg et al. (2021) zeigten in diesem Kontext beispielsweise, dass sich Unterrichtsvideos mit Machine-Vision automatisiert auswerten lassen, indem Blickrichtung, Kopfpose und Gesichtsausdrücke extrahiert werden und damit manuelle Einschätzungen sichtbarer Engagement-/Aufmerksamkeitsprozesse gut approximiert werden können.

Zukünftige Arbeiten sollten zudem die Robustheit KI-gestützter Ratings systematischer prüfen. Dazu gehört der Vergleich mehrerer Modelle und Promptvarianten sowie die Durchführung von Robustheitschecks, etwa durch wiederholte Durchläufe und die Aggregation mehrerer KI-Urteile pro Segment. Auf diese Weise ließe sich die stochastische Restunsicherheit reduzieren und zugleich prüfen, wie sensitiv die Ergebnisse gegenüber Promptformulierungen, Indikatorreihenfolgen und Instruktionsdetails ausfallen. Darüber hinaus wäre es aufschlussreich, die Interrater-Reliabilität zwischen verschiedenen Modellen sowie innerhalb desselben Modells unter variierenden Prompts zu analysieren und KI-Urteile nicht nur gegen aggregierte, sondern auch gegen einzelne menschliche Ratings einzuordnen, um die Übereinstimmung im Sinne klassischer Gütekriterien differenzierter zu bewerten.

Ebenfalls ergeben sich Implikationen für die Weiterentwicklung von Beobachtungsinstrumenten. Die vorliegende Untersuchung zeigt, dass Instrumente, die für videobasierte Beobachtung

entwickelt wurden, nur begrenzt zu einer transkriptbasierten KI-Analyse passen. Das gilt besonders dann, wenn zentrale Indikatoren nonverbal konzeptualisiert sind oder wenn keine standardisierte Gewichtungslogik vorgesehen ist. Für KI-gestützte Anwendungen sollten Indikatoren daher entweder so formuliert sein, dass sie im Text beobachtbar sind, oder so angelegt werden, dass sie explizit multimodal erfasst werden können. So lässt sich die Passung zwischen Instrumentenlogik, Datenmodalität und algorithmischer Auswertung erhöhen.

6.3.2. Einsatz in Praxis und Lehrkräfte(aus)bildung

Für die schulische Praxis und die Lehrkräfte(aus)bildung lässt sich aus den Befunden ableiten, dass KI-basierte Verfahren vor allem als assistive Unterstützung sinnvoll erscheinen und nicht als Ersatz für professionelle Beobachtung und Beurteilungen. Die Ergebnisse sollten dabei realistisch in den Kontext eingeordnet werden. In dieser Untersuchung wurden Urteile theoriegeleitet und mit validierten Kriterienrastern abgesichert (Fauth et al., 2024). In Aus- und Weiterbildungssettings wird in der Praxis jedoch teils weniger systematisch und stärker heuristisch beurteilt. Strong et al. (2011) zeigen beispielsweise, dass selbst erfahrene Beurteiler*innen effektive Lehrkräfte nur auf Zufallsniveau oder in Teilen darunter identifizieren und von ineffektiven Lehrkräften unterscheiden können. Der Einsatz von transkriptbasierten KI-Bewertungen ist besonders dort plausibel, wo Qualitätsmerkmale eng an sprachliche Signale gekoppelt sind. Dort könnten sie als Screening- oder (Selbst-)Reflexionshilfe dienen. Vor allem zur Reflexion von Zieltransparenz, fachlicher Strukturierung, Diskursgestaltung oder zu sprachlich sichtbaren Aspekten der KA. Dimensionsübergreifende Rückmeldungen an Lehrkräfte auf Basis von KI-Bewertungen sind nur begrenzt sinnvoll. Ohne Audio- und Videoinformation lassen sich zentrale Aspekte der KU und SK nur eingeschränkt valide beurteilen.

Für den Wirtschaftsunterricht ergibt sich ein spezifisches Potenzial transkriptbasierter Analysen dort, wo fachliches Lernen stark sprachlich elaboriert ist. Einige Aspekte der Handlungsorientierung sowie der Urteilsbildung und Entscheidungsfindung lassen sich der Dimension KA zuordnen (Platz et al., 2025). Dadurch ergeben sich für diese Aspekte Potenziale für eine transkriptbasierte KI-Beurteilung. Andere Aspekte sind eng an die Unterstützung der aktiven Beteiligung aller SuS und an die sozio-emotionale Unterstützung des SF geknüpft (Platz et al., 2025; Praetorius & Charalambous, 2018). Durch diese Nähe zur KU kann die Beurteilbarkeit zentraler fachspezifischer Qualitätsmerkmale entsprechend eingeschränkt sein. Zugleich

ist bei der Anwendung im Wirtschaftsunterricht zu berücksichtigen, dass in dieser Untersuchung ein generisches Beobachtungsinstrument eingesetzt wurde. Die fachspezifische Auswahl von Themen im Sinne der Dimension „Aktualität und Lebensweltbezug“ wird im Beobachtungsinstrument nicht abgebildet. Auch fachspezifische Ausdifferenzierungen von Aspekten der KA und der KU, im Sinne der Dimensionen „Handlungsorientierung“ sowie „Urteilsbildung und Entscheidungsfindung“, werden nur begrenzt erfasst. Das Beobachtungsinstrument ist daher für fachbezogene Urteile nur mit entsprechender Vorsicht zu nutzen. Vor diesem Hintergrund bleibt die Entwicklung und Validierung fachspezifischer Beobachtungsinstrumente für sozialwissenschaftliche Unterrichtsfächer wie den Wirtschaftsunterricht ein zentrales Desiderat.

7. Fazit

Die Motivation dieser Arbeit war es, einen weitgehend ressourcenschonenden, automatischen Workflow für die KI-gestützte Beurteilung von Unterrichtsqualität zu entwickeln. Um diesem Anspruch gerecht zu werden, wurde geprüft, inwiefern Unterrichtsqualität auf Basis KI-generierter Unterrichtstranskripte durch das LLM ChatGPT valide bewertet werden kann. Dazu wurden KI-basierte Bewertungen systematisch mit videobasierten menschlichen Ratings verglichen. Beide Beurteilungen stützten sich auf den Beobachtungsbogen Tiefenstrukturen des IBBW, der die Basisdimensionen KA, KU und SK über insgesamt elf Items operationalisiert.

(F1) Für welche Basisdimensionen, Items und Indikatoren des UFB ist eine transkriptbasierte KI-Bewertung grundsätzlich geeignet und wo zeigen sich systematische Grenzen?

Die Analyse der Indikatoreignung zeigt deutliche Unterschiede zwischen den Items. In der KI-basierten Eignungsanalyse erzielten KA1, KA3 sowie KU1 mit einem Eignungsscore von jeweils 1,00 die höchsten Werte. Dies ist plausibel, da ihre Indikatoren vor allem auf verbalen Interaktionsmustern beruhen, die im Unterrichtstranskript direkt sichtbar sind. Am schwächsten fällt SK2 aus. Mit einem Score von 0,35 weist es die geringste Eignung im Instrument auf, weil zentrale Merkmale des Monitorings wie Blickrichtung, Positionierung im Raum und physische Präsenz im Transkript nicht erfasst werden. Damit werden grundlegende Modalitätsgrenzen eines rein textbasierten Verfahrens sichtbar. Auf Ebene der Basisdimensionen erweist sich die KA insgesamt als am besten geeignet. Die KU wurde zwar überwiegend als geeignet eingestuft, bleibt jedoch in relationalen und emotionalen Aspekten begrenzt. Für die SK zeigt sich eine besonders klare Grenze beim Monitoring, obwohl dieser Bestandteil theoretisch zentral ist und transkriptbasiert nur eingeschränkt beurteilbar bleibt.

(F2) In welchem Maße stimmen KI-gestützte, rein transkriptbasierte Bewertungen der Unterrichtsqualität mit videobasierten Ratings geschulter menschlicher Rater*innen in den drei Basisdimensionen KA, KU und SK überein?

Die Übereinstimmung zwischen den transkriptbasierten KI-Bewertungen und den videobasierten menschlichen Ratings variiert deutlich zwischen den Basisdimensionen. Für die SK ergab sich aggregiert die höchste Übereinstimmung mit 54,7 Prozent identischen Bewertungen und einer gewichteten MAD von 0,42. Auf Itemebene zeigt sich jedoch ein heterogenes Muster. Während SK1 und SK3 hohe Übereinstimmungen erzielten, markiert SK2 „Monitoring“ als zentrale Facette der Klassenführung eine klare Grenze des transkriptbasierten Ver-

fahrens. Hier wurde keine Übereinstimmung erreicht. Da präventive Aspekte wie Raumpräsenz und Blickrichtung im Transkript unsichtbar bleiben, sind die geringe Übereinstimmung und die größere Abweichung bei SK2 erwartbar. Perspektivisch könnten räumliche Informationen und Blickrichtungsanalysen die Übereinstimmung in diesem Bereich deutlich erhöhen.

Die KA erreicht mit 44,1 Prozent identischen Ratings und einer MAD von 0,49 die zweitbeste Übereinstimmung. Im Unterschied zur SK zeigt sich hier ein vergleichsweise homogenes Muster ohne extreme Ausreißer. Die geringe Abweichung ist vor dem Hintergrund der überwiegend hohen prognostizierten Eignung plausibel. Perspektivisch könnte die Analyse des pädagogischen Angebots durch Unterrichtsartefakte wie Aufgabenmaterial präzisiert werden. Für die Nutzungsseite dürfte eine Ergänzung um nonverbale Hinweise zur Aktiviertheit sowie um Selbstberichte der SuS besonders gewinnbringend sein.

Die geringste Übereinstimmung zeigt die KU mit 21,7 Prozent identischen Bewertungen und einer MAD von 0,89. Besonders bei den Items zur Feedbackqualität und zur Wertschätzung zeigten sich gravierende Defizite. Das Transkript bildet zwar die verbalen Bestandteile von Rückmeldungen ab, es ist jedoch naheliegend, dass für die Bewertung der Intention und der affektiven Qualität zusätzliche Hinweise aus Mimik, Gestik und prosodischen Merkmalen wie dem Tonfall bedeutsam wären. Da diese Kanäle im Transkript fehlen, ist es plausibel, dass beispielsweise KU1 trotz maximaler theoretischer Eignung nur eine minimale Übereinstimmung erzielt. Perspektivisch könnten automatisierte Prosodieanalysen eingesetzt werden, um verbale Äußerungen differenzierter interpretieren zu können.

Unter Berücksichtigung zentraler methodologischer Limitationen sind die erzielten Übereinstimmungen insgesamt als positiv einzuordnen. Erstens erschwerte die Audioqualität eine lückenlose Transkription, da insbesondere Beiträge der Lernenden aufgrund fehlender Individualmikrofone unterrepräsentiert waren. Zweitens führte die Segmentierung in 20-minütige Blöcke zu Kontextverlusten, weil prozessuale Entwicklungen außerhalb des betrachteten Segments liegen konnten. Drittens begünstigte das Beobachtungsinstrument durch unausgeglichene Verhältnisse von Positiv- und Negativindikatoren sowie fehlende Standardisierungen der Indikatorgewichtung potenzielle Verzerrungen in der algorithmischen Logik. Eine weitere entscheidende Limitation betrifft den Referenzstandard. Die menschlichen Ratings lagen als aggregierte Mittelwerte vor, um die Objektivität zu erhöhen und die individuellen Urteilsfehler zu reduzieren. Die KI wurde hingegen nur in einem einzelnen Durchlauf eingesetzt und

vergab dabei ausschließlich ganzzahlige Werte. Diese Diskrepanz verringerte die Anzahl potenziell identischer Bewertungen bereits im Vorfeld und macht zugleich sichtbar, dass auch menschliche Urteile bei hoch inferenten Beobachtungen häufig um eine Skalenstufe abweichen. Vor diesem Hintergrund ist die geringe Abweichung und die relativ homogene Verteilung in der KA als Hinweis auf ein hohes Validitätspotenzial zu bewerten. Ähnliche Potenziale zeigen sich für einzelne Aspekte der SK, insbesondere SK1 und SK3, sowie für KU2 im Sinne sprachlich fassbarer Scaffolding-Prozesse.

Die Integration multimodaler Zugänge könnte das Potenzial automatisierter Analysen dimensionsübergreifend erhöhen. Blickrichtungsdaten könnten das Monitoring präziser erfassen. Prosodische Merkmale wie Tonfall und Sprechtempo könnten affektive Nuancen der KU zugänglich machen. Unterrichtsartefakte und Selbstberichte könnten die Beurteilung der KA verbessern. Darüber hinaus bleibt die Entwicklung fachspezifischer und auf den KI-Einsatz abgestimmter Beobachtungsinstrumente ein zentrales Desiderat. Gleichzeitig bleiben KI-spezifische Limitationen bestehen. Die Black-Box-Problematik kommerzieller Sprachmodelle erschwert die Transparenz und die Reproduzierbarkeit. Zudem muss das Risiko von Halluzinationen durch Schutzmechanismen wie präzise Instruktionsprompts und menschliche Validierungsprozesse minimiert werden.

Insgesamt zeigt der untersuchte Workflow substanzielle Potenziale für eine valide Beurteilung von Unterrichtsprozessen. Für sprachlich explizite Merkmale liefert das Verfahren bereits belastbare Ergebnisse. Die abschließende professionelle Beurteilung komplexer und nonverbal geprägter Tiefenstrukturen sollte angesichts der Abweichungen jedoch weiterhin in der Verantwortung geschulter menschlicher Beobachter*innen verbleiben.

Literatur

- Ackermann, N., & Kavadarli, B. (2022). Civic argumentation in the economic domain: Examining upper high school students' arguments on socio-economic problems in a performance test by applying a domain-specific analytical framework. *Citizenship Social and Economics Education*, 21, 22-42. <https://doi.org/10.1177/20471734211050283>
- Ahuja, K., Shah, D., Paredy, S., Xhakaj, F., Ogan, A., Agarwal, Y., & Harrison, C. (2021). *Classroom Digital Twins with Instrumentation-Free Gaze Tracking* Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems, Yokohama, Japan. <https://doi.org/10.1145/3411764.3445711>
- Bannert, M., Reimann, P., & Sonnenberg, C. (2014). Process mining techniques for analysing patterns and strategies in students' self-regulated learning. *Metacognition and Learning*, 9(2), 161-185. <https://doi.org/10.1007/s11409-013-9107-6>
- Baumert, J., & Kunter, M. (2006). Stichwort: Professionelle Kompetenz von Lehrkräften. *Zeitschrift für Erziehungswissenschaft*, 9(4), 469-520. <https://doi.org/10.1007/s11618-006-0165-2>
- Baumert, J., Kunter, M., Blum, W., Brunner, M., Voss, T., Jordan, A., Klusmann, U., Krauss, S., Neubrand, M., & Tsai, Y.-M. (2010). Teachers' Mathematical Knowledge, Cognitive Activation in the Classroom, and Student Progress. *American Educational Research Journal*, 47(1), 133-180. <https://doi.org/10.3102/0002831209345157>
- Beck, G., & Scholz, G. (2012). Die Schule als Beobachtungsfeld. In H. de Boer & S. Reh (Eds.), *Beobachtung in der Schule – Beobachten lernen* (pp. 85-114). VS Verlag für Sozialwissenschaften. https://doi.org/10.1007/978-3-531-18938-3_5
- Becker, S., Küchemann, S., Klein, P., Lichtenberger, A., & Kuhn, J. (2022). Gaze patterns enhance response prediction: More than correct or incorrect. *Physical Review Physics Education Research*, 18(2), 020107. <https://doi.org/10.1103/PhysRevPhysEducRes.18.020107>
- Begrich, L., Praetorius, A.-K., Decristan, J., Fauth, B., Göllner, R., Herrmann, C., Kleinknecht, M., Taut, S., & Kunter, M. (2023). Was tun? Perspektiven für eine Unterrichtsqualitätsforschung der Zukunft. *Unterrichtswissenschaft*, 51. <https://doi.org/10.1007/s42010-023-00163-4>
- Birke, F., Buschong, R., Kaiser, & Tim. (2022). Staatliche Hilfen für Wettbewerbsverlierer? *Politik & Gesellschaft*, 2022(3), 53-55. https://doi.org/10.5555/uwp-3-2022_10
- Black, P., & William, D. (1998). Assessment and Classroom Learning. *Assessment in Education: Principles, Policy & Practice*, 5(1), 7-74. <https://doi.org/10.1080/0969595980050102>
- Böhner, M., & Dolzanski, C. (2016). *Fachdidaktik für Lehrende im Bereich Wirtschaft: Schlüssel für erfolgreichen Unterricht*. (Publisher not specified).
- Böhnke, A., Jordan, A., Großmann, L., Haase, S., Helbig, K., Müller, J., Achour, S., Krüger, D., & Thiel, F. (2020). Das FOCUS-Videoportal der Freien Universität Berlin - Videobasierte Lerngelegenheiten für die erste und zweite Phase der Lehrkräftebildung. In R. Junker, V. Zucker, M. Oellers, T. Rauterberg, S. Konjer, N. Meschede, & M. Holodynski (Eds.), *Lehren und Forschen mit Videos in der Lehrkräftebildung* (pp. 37-55). Waxmann.

- Brahm, T., Ring, M., & Rudeloff, M. (2020). Mögliche Ausgestaltung der reflexiven Wirtschaftsdidaktik für die Lehrer*innenbildung an allgemeinbildenden Schulen. *Zeitschrift für Pädagogik*, 66(6), 873-893. <https://doi.org/10.25656/01:25818>
- Branda, F., Ciccozzi, M., & Scarpa, F. (2025). Artificial intelligence in scientific research: Challenges, opportunities and the imperative of a human-centric synergy. *Journal of Informetrics*, 19(4), 101727. <https://doi.org/10.1016/j.joi.2025.101727>
- Breidenstein, G. (2012). Ethnographisches Beobachten. In H. de Boer & S. Reh (Eds.), *Beobachtung in der Schule – Beobachten lernen* (pp. 27-44). VS Verlag für Sozialwissenschaften. https://doi.org/10.1007/978-3-531-18938-3_2
- Brophy, J., & Good, T. L. (1986). Teacher behavior and student achievement. In M. C. Wittrock (Ed.), *Handbook of research and teaching* (pp. 328-375). Macmillan.
- Brühwiler, C., Helmke, A., & Schrader, F.-W. (2025). Determinanten der Schulleistung. In M. K. W. Schweer (Ed.), *Lehrer-Schüler-Interaktion: Inhaltsfelder, Forschungsperspektiven und methodische Zugänge* (pp. 279-308). Springer Fachmedien Wiesbaden. https://doi.org/10.1007/978-3-658-45042-7_12
- Brunner, M., Kunter, M., Krauss, S., Baumert, J., Blum, W., Voss, T., Jordan, A., Klusmann, U., Tsai, Y.-M., & Neubrand, M. (2006). Welche Zusammenhänge bestehen zwischen dem fachspezifischen Professionswissen von Mathematiklehrkräften und ihrer Ausbildung sowie beruflichen Fortbildung? *Zeitschrift für Erziehungswissenschaft*, 9, 521-544. <https://doi.org/10.1007/s11618-006-0166-1>
- Clausen, M. (2002). *Unterrichtsqualität: Eine Frage der Perspektive? Empirische Analysen zur Übereinstimmung, Konstrukt- und Kriteriumsvalidität*. Waxmann.
- Clausen, M., Reusser, K., & Klieme, E. (2003). Unterrichtsqualität auf der Basis hoch-inferenter Unterrichtsbeurteilungen. Ein Vergleich zwischen Deutschland und der deutschsprachigen Schweiz. *Unterrichtswissenschaft*, 31, 122-141.
- Conrad, M., Kablitz, D., & Schumann, S. (2024). Learning effectiveness of immersive virtual reality in education and training: A systematic review of findings. *Computers & Education: X Reality*, 4, 100053. <https://doi.org/10.1016/j.cexr.2024.100053>
- Cortina, K., Miller, K., McKenzie, R., & Epstein, A. (2015). Where Low and High Inference Data Converge: Validation of CLASS Assessment of Mathematics Instruction Using Mobile Eye Tracking with Expert and Novice Teachers. *International Journal of Science and Mathematics Education*, 13. <https://doi.org/10.1007/s10763-014-9610-5>
- Cramer, C. (2020). Meta-Reflexivität in der Lehrerinnen- und Lehrerbildung. In *Handbuch Lehrerinnen- und Lehrerbildung* (pp. 204-214). Klinkhardt utb.
- de Boer, H. (2012). Pädagogische Beobachtung. In H. de Boer & S. Reh (Eds.), *Beobachtung in der Schule – Beobachten lernen* (pp. 65-82). VS Verlag für Sozialwissenschaften. https://doi.org/10.1007/978-3-531-18938-3_4
- Deci, E. L., & Ryan, R. M. (1993). Die Selbstbestimmungstheorie der Motivation und ihre Bedeutung für die Pädagogik. *Zeitschrift für Pädagogik*, 39(2), 223-238. <https://doi.org/10.25656/01:11173>
- Doyle, W. (1986). Classroom organization and management. *Handbook of research on teaching*, 3(1), 392-431.

- Drollinger-Vetter, B. (2011). *Verstehenselemente und strukturelle Klarheit: Fachdidaktische Qualität der Anleitung von mathematischen Verstehensprozessen im Unterricht*. Waxmann.
- Dubs, R. (2018). Von der Anleitung zur Selbststeuerung - vom Verstehen über Analyse und Synthese zur Bewertung wirtschaftlicher Fragen aus ganzheitlicher Sicht. In B. Weber (Ed.), *Wirksamer Wirtschaftsunterricht* (pp. 37-46). Schneider Verlag Hohengehren.
- Dzsotjan, D., Ludwig-Petsch, K., Mukhametov, S., Ishimaru, S., Küchemann, S., & Kuhn, J. (2021). *The Predictive Power of Eye-Tracking Data in an Interactive AR Learning Environment*. <https://doi.org/10.1145/3460418.3479358>
- Eberle, J., Strauß, S., Nachtigall, V., & Rummel, N. (2024). Analyse prozessbezogener Verhaltensdaten mittels Learning Analytics: Aktuelle und zukünftige Bedeutung für die Unterrichtswissenschaft. *Unterrichtswissenschaft*, 52(2), 213-225. <https://doi.org/10.1007/s42010-024-00205-5>
- Eccles, J., & Wigfield, A. (2002). Motivational Beliefs, Values and Goals. *Annual Review of Psychology*, 53, 109-132. <https://doi.org/10.1146/annurev.psych.53.100901.135153>
- Emmer, E., & Stough, L. (2001). Classroom Management: A Critical Part of Educational Psychology, With Implications for Teacher Education. *Educational Psychologist*, 36, 103-112. https://doi.org/10.1207/S15326985EP3602_5
- Europäische Union. (2016). *Verordnung (EU) 2016/679 des Europäischen Parlaments und des Rates vom 27. April 2016 zum Schutz natürlicher Personen bei der Verarbeitung personenbezogener Daten, zum freien Datenverkehr und zur Aufhebung der Richtlinie 95/46/EG (Datenschutz-Grundverordnung, DSGVO)*. Amtsblatt der Europäischen Union Retrieved from <https://eur-lex.europa.eu/eli/reg/2016/679/oj/eng>
- Europäische Union. (2024). *Verordnung (EU) 2024/1689 des Europäischen Parlaments und des Rates vom 13. Juni 2024 zur Festlegung harmonisierter Vorschriften für künstliche Intelligenz (Künstliche-Intelligenz-Verordnung, „AI Act“)*. Amtsblatt der Europäischen Union Retrieved from <https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng>
- Fauth, B., Decristan, J., Rieser, S., Klieme, E., & Büttner, G. (2014). Grundschulunterricht aus Schüler-, Lehrer- und Beobachterperspektive: Zusammenhänge und Vorhersage von Lernerfolg*. *Zeitschrift für Pädagogische Psychologie*, 28(3), 127-137. <https://doi.org/10.1024/1010-0652/a000129>
- Fauth, B., Herbein, E., & Maier, J. L. (2024). *Beobachtungsmanual zum Unterrichtsfeedbackbogen Tiefenstrukturen (IBBW_UFB_Manual)*. <https://ibbw.kultus-bw.de/Lde/Startseite/Empirische-Bildungsforschung/unterrichtsfeedbackbogen>
- Fauth, B., & Leuders, T. (2022). *Kognitive Aktivierung im Unterricht. (2. aktualisierte Auflage)*. Institut für Bildungsanalysen Baden-Württemberg. <https://ibbw.kultus-bw.de/Lde/Startseite/Empirische-Bildungsforschung/Publikationsreihe-Wirksamer-Unterricht>
- Fend, H. (1981). *Theorie der Schule: Systemtheoretische Grundlegung und empirische Analysen* (2 ed.). Urban & Schwarzenberg.

- Fend, H. (2006). *Neue Theorie der Schule: Einführung in das Verstehen von Bildungssystemen*. <https://doi.org/10.1007/978-3-531-90169-5>
- Fredricks, J., Reschly, A., Christenson, S., Larson, S., Sinha, S., Bressler, D., & Shernoff, D. (2019). HANDBOOK OF STUDENT ENGAGEMENT INTERVENTIONS Working with Disengaged Students. In.
- Fritzsche, B., & Wagner-Willi, M. (2011). *Dokumentarische Interpretation von Unterrichtsvideografien* [Manuskript].
- Gabriel, K. (2014). *Videobasierte Erfassung von Unterrichtsqualität im Anfangsunterricht der Grundschule: Klassenführung und Unterrichtsklima in Deutsch und Mathematik* kassel university press]. Kassel. urn:nbn:de:0111-pedocs-306501
- Gencoglu, B., Helms-Lorenz, M., Maulana, R., Jansen, E. P. W. A., & Gencoglu, O. (2023). Machine and expert judgments of student perceptions of teaching behavior in secondary education: Added value of topic modeling with big data. *Computers & Education*, 193, 104682. <https://doi.org/https://doi.org/10.1016/j.compedu.2022.104682>
- Gold, B., Förster, S., & Holodynski, M. (2013). Evaluation eines videobasierten Trainingsseminars zur Förderung der professionellen Wahrnehmung von Klassenführung im Grundschulunterricht*. *Zeitschrift für Pädagogische Psychologie*, 27, 141-155. <https://doi.org/10.1024/1010-0652/a000100>
- Gold, B., Pfirrmann, C., Burgula, K., & Holodynski, M. (2016). Fallbasierte Unterrichtsanalyse - Effekte von video- und textbasierter Fallanalyse auf kognitive Belastung, aufgabenspezifisches Interesse und die professionelle Unterrichtswahrnehmung von Grundschullehramtsstudierenden. *Unterrichtswissenschaft*, 44.
- Goldberg, P., Sümer, Ö., Stürmer, K., Wagner, W., Göllner, R., Gerjets, P., Kasneci, E., & Trautwein, U. (2021). Attentive or Not? Toward a Machine Learning Approach to Assessing Students' Visible Engagement in Classroom Instruction. *Educational Psychology Review*, 33(1), 27-49. <https://doi.org/10.1007/s10648-019-09514-z>
- Goldschmidt, N., Keipke, Y., Lenger, A., & Macha, K. (2018). Reflexive Wirtschaftsdidaktik: Ökonomische Handlungskompetenz, wirtschaftliches Sinn-Verstehen und moralische Urteile. *GWP – Gesellschaft. Wirtschaft. Politik*, 67(1), 143-151. <https://doi.org/10.3224/gwp.v67i1.09>
- Göllner, R., Lazarides, R., & Stark, P. (2025). Revealing teaching quality through lesson semantics: A GPT-assisted analysis of transcripts. *British Journal of Educational Psychology*, 95, S300-S315. <https://doi.org/10.1111/bjep.70001>
- Gombert, S., Di Mitri, D., Karademir, O., Kubsch, M., Kolbe, H., Tautz, S., Grimm, A., Böhm, I., Neumann, K., & Drachsler, H. (2023). Coding energy knowledge in constructed responses with explainable NLP models. *Journal of Computer Assisted Learning*, 39(3), 767-786. <https://doi.org/https://doi.org/10.1111/jcal.12767>
- Gruen Korn, J. K., Eckhard; Preatorius, Anna-Katharina; Schreyer, Patrick (Ed.). (2020). *Mathematikunterricht im internationalen Vergleich. Ergebnisse aus der TALIS-Videostudie Deutschland*. DIPF | Leibniz-Institut für Bildungsforschung und Bildungsinformation. [https://doi.org/URN: urn:nbn:de:0111-pedocs-211569](https://doi.org/URN:urn:nbn:de:0111-pedocs-211569) Doi: 10.25656/01:21156.

- Hamre, B., & Pianta, R. C. (2010). Classroom environments and developmental processes: Conceptualization and measurement. *Handbook of Research on Schools, Schooling and Human Development*, 25-41.
- Hattie, J. (2013). *Lernen sichtbar machen*. Schneider Verlag Hohengehren.
- Hattie, J., & Timperley, H. (2007). The Power of Feedback. *Review of Educational Research*, 77(1), 81-112. <https://doi.org/10.3102/003465430298487>
- Hedtke, R. (2011). *Konzepte ökonomischer Bildung*. Wochenschau Verlag.
- Heid, H. (2006). Werte und Normen in der Berufsbildung. In R. Arnold & A. Lipsmeier (Eds.), *Handbuch der Berufsbildung* (pp. 33-43). VS Verlag für Sozialwissenschaften. https://doi.org/10.1007/978-3-531-90622-5_2
- Helmke, A. (Ed.). (2009). *Unterrichtsqualität und Lehrerprofessionalität. Diagnose, Evaluation und Verbesserung des Unterrichts*. Franz Emanuel Weinert gewidmet. Neubearb., 1. Aufl [Teaching quality and teachers' professionalism. Diagnosis, evaluation and improvement of teaching.]. Kallmeyer u.a.
- Helmke, A., & Klieme, E. (2008). Unterricht und Entwicklung sprachlicher Kompetenzen. In D. Konsortium (Ed.), *Unterricht und Kompetenzerwerb in Deutsch und Englisch. Ergebnisse der DESI-Studie* (pp. 301-312). Beltz. <https://doi.org/10.25656/01:3156>
- Helmke, A., & Weinert, F. E. (1997). Bedingungsfaktoren schulischer Leistungen. In F. E. Weinert (Ed.), *Psychologie des Unterrichts und der Schule* (pp. 71-176). Hogrefe.
- Helsper, W. (2023). Lehrerprofessionalität – der strukturtheoretische Ansatz. In M. Rothland (Ed.), *Beruf Lehrer:in. Ein Studienbuch* (pp. 122-147). Waxmann.
- Herrle, M., & Breitenbach, S. (2016). Planung, Durchführung und Nachbereitung videogestützter Beobachtungen im Unterricht. In (pp. 30-49).
- Herrle, M., Kade, J., & Nolda, S. (2010). Erziehungswissenschaftliche Videographie. In B. Friebertshäuser & A. Prengel (Eds.), *Handbuch Qualitative Forschungsmethoden in der Erziehungswissenschaft* (pp. 599-619). Juventa.
- Hill, H., Charalambous, C., & Kraft, M. (2012). When Rater Reliability Is Not Enough: Teacher Observation Systems and a Case for the Generalizability Study. *Educational Researcher*, 41, 56-64. <https://doi.org/10.3102/0013189X12437203>
- Holodynski, M., & Meschede, N. (2020). Videobasierte Lehre und Forschung in der Lehrkräftebildung – Quo vadis? In R. Junker, V. Zucker, M. Oellers, T. Rauterberg, S. Konjer, N. Meschede, & M. Holodynski (Eds.), *Lehren und Forschen mit Videos in der Lehrkräftebildung* (pp. 197-217). Waxmann.
- Hunkins, N., Kelly, S., & D'Mello, S. (2022). *“Beautiful work, you're rock stars!”: Teacher Analytics to Uncover Discourse that Supports or Undermines Student Motivation, Identity, and Belonging in Classrooms* LAK22: 12th International Learning Analytics and Knowledge Conference, Online, USA. <https://doi.org/10.1145/3506860.3506896>
- Jordan, A., Krauss, S., Löwen, K., Blum, W., Neubrand, M., Brunner, M., Kunter, M., & Baumert, J. (2008). Aufgaben im COACTIV-Projekt: Zeugnisse des kognitiven Aktivierungspotentials im deutschen Mathematikunterricht. *Journal für Mathematik-Didaktik*, 29(2), 83-107. <https://doi.org/10.1007/BF03339055>

- Junker, R., Rauterberg, T., Zucker, V., Meschede, N., & Holodyski, M. (2020). Das Videoportal ProVision: Umgang mit Heterogenität im Unterricht professionell wahrnehmen. In *Lehren und Forschen mit Videos in der Lehrkräftebildung* (pp. 165-180). Waxmann.
- Khlaif, Z. N., Mousa, A., Hattab, M. K., Itmazi, J., Hassan, A. A., Sanmugam, M., & Ayyoub, A. (2023). The Potential and Concerns of Using AI in Scientific Research: ChatGPT Performance Evaluation. *JMIR Med Educ*, 9, e47049. <https://doi.org/10.2196/47049>
- Kieser, F., Wulff, P., Kuhn, J., & Küchemann, S. (2023). Educational data augmentation in physics education research using ChatGPT. *Physical Review Physics Education Research*, 19(2), 020150.
- Kirschner, P., Sweller, J., & Clark, R. (2006). Why Minimal Guidance During Instruction Does Not Work: An Analysis of the Failure of Constructivist, Discovery, Problem-Based, Experiential, and Inquiry-Based Teaching. *Educational Psychologist*, 41. https://doi.org/10.1207/s15326985ep4102_1
- Kizilcec, R. (2023). To Advance AI Use in Education, Focus on Understanding Educators. *International Journal of Artificial Intelligence in Education*, 34. <https://doi.org/10.1007/s40593-023-00351-4>
- Kleickmann, T., Praetorius, A.-K., & Riecke-Baulecke, T. (2019). Beurteilung von Unterrichtsqualität. In F. Zimmermann, J. Möller, & T. Riecke-Baulecke (Eds.), (pp. 223). Kallmeyer'sche Verlags.
- Klieme, E. (2006). Empirische Unterrichtsforschung: aktuelle Entwicklungen, theoretische Grundlagen und fachspezifische Befunde. Einf. *Zeitschrift für Pädagogik*, 52.
- Klieme, E. (2020). Unterrichtsqualität. In *Handbuch Schulpädagogik* (pp. 394-409). Waxmann. <https://doi.org/10.36198/9783838586984-394-409>
- Klieme, E., Jude, N., Rauch, D., Ehlers, H., Helmke, A., Eichler, W., Thomé, G., & Willenberg, H. (2008). Alltagspraxis, Qualität und Wirksamkeit des Deutschunterrichts. *DESI-Konsortium [Hrsg.]: Unterricht und Kompetenzerwerb in Deutsch und Englisch. Ergebnisse der DESI-Studie. Weinheim u.a. : Beltz 2008, S. 319-344.*
- Klieme, E., Lipowsky, F., Rakoczy, K., & Ratzka, N. (2006). Qualitätsdimensionen und Wirksamkeit von Mathematikunterricht. Theoretische Grundlagen und ausgewählte Ergebnisse des Projekts „Pythagoras“. In (pp. 127-146).
- Klieme, E., & Rakoczy, K. (2008). Empirische Unterrichtsforschung und Fachdidaktik. Outcome-orientierte Messung und Prozessqualit. *Zeitschrift für Pädagogik*, 54.
- Klieme, E., Schümer, G., & Knoll, S. (2001). Mathematikunterricht in der Sekundarstufe I: Aufgabenkultur und Unterrichtsgestaltung. *TIMSS - Impulse für Schule und Unterricht*, 43-57.
- Köller, O., Thiel, F., Ackeren-Mindl, I. v., Anders, Y., Becker-Mrotzek, M., Cress, U., Diehl, C., Kleickmann, T., Lütje-Klose, B., Prediger, S., Seeber, S., Ziegler, B., Lewalter, D., Maaz, K., Reintjes, C., & Stanat, P. (2024). *Large Language Models und ihre Potenziale im Bildungssystem. Impulspapier der Ständigen Wissenschaftlichen Kommission der Kultusministerkonferenz. SWK.* <https://doi.org/URN:urn:nbn:de:0111-pedocs-283038> Doi: 10.25656/01:28303
- Kounin, J. S. (1976). *Techniken der Klassenführung: Untersuchungen zum Verhalten von Lehrern und Schülern im Unterricht.* Klett.

- Kramer, C., König, J., & Kaspar, K. (2020). UnterrichtOnline.org - Unterrichtsvideos für den Einsatz in der Forschung und Lehre. In R. Junker, V. Zucker, M. Oellers, T. Rauterberg, S. Konjer, N. Meschede, & M. Holodynski (Eds.), *Lehren und Forschen mit Videos in der Lehrkräftebildung* (pp. 95-112). Waxmann.
- Krammer, K., & Reusser, K. (2005). Unterrichtsvideos als Medium der Aus- und Weiterbildung von Lehrpersonen. *Beiträge zur Lehrerbildung*, 23(1), 35-50. [https://doi.org/URN: urn:nbn:de:0111-pedocs-135612](https://doi.org/URN:urn:nbn:de:0111-pedocs-135612) Doi: 10.25656/01:13561
- Kunter, M., Baumert, J., & Köller, O. (2007). Effective classroom management and the development of subject-related interest. *Learning and Instruction*, 17(5), 494-509. <https://doi.org/https://doi.org/10.1016/j.learninstruc.2007.09.002>
- Kunter, M., & Trautwein, U. (2013). *Psychologie des Unterrichts*. Schöningh.
- Kunter, M., & Voss, T. (2011). Das Modell der Unterrichtsqualität in COACTIV : Eine multikriteriale Analyse. *Professionelle Kompetenz von Lehrkräften : Ergebnisse des Forschungsprogramms COACTIV*, 85-113 (2011).
- Kunter, M., Voss, T., Baumert, J., Blum, W., Brunner, M., Jordan, A., Klusmann, U., Krauss, S., Löwen, K., Neubrand, M., & Tsai, Y.-M. (2006). Mathematikunterricht in den PISA-Klassen 2004: Rahmenbedingungen, Formen und Lehr-Lernprozesse. In (pp. 161–194).
- Lauterbach, C., Gabriel-Busse, K., & Lipowsky, F. (2013). Hoch inferentes Rating: Kognitive Aktivierung im Mathematikunterricht. In (pp. 405-421).
- Lazarides, R., Frenkel, J., Petković, U., Göllner, R., & Hellwich, O. (2025). 'No words'—Machine-learning classified nonverbal immediacy and its role in connecting teacher self-efficacy with perceived teaching and student interest. *British Journal of Educational Psychology*, 95(S1), S15-S31. <https://doi.org/https://doi.org/10.1111/bjep.12732>
- Lenske, G., Bönnte, J., van Bebber, R., & Leutner, D. (2020). Das CLIPSS-Videoportal (Classroom Management in Primary and Secondary Schools): Inszenierte Videovignetten zur Förderung professioneller Kompetenzen. In *Lehren und Forschen mit Videos in der Lehrkräftebildung* (pp. 57-73). Waxmann. <https://doi.org/10.31244/9783830995111>
- Lipowsky, F. (2020). Unterricht. In E. Wild, J. Möller, & Auflage (Eds.), *Pädagogische Psychologie* (pp. 69-118). Springer.
- Lipowsky, F., Rakoczy, K., Pauli, C., Drollinger-Vetter, B., Klieme, E., & Reusser, K. (2009). Quality of geometry instruction and its short-term impact on students' understanding of the Pythagorean Theorem. *Learning and Instruction*, 19(6), 527-537. <https://doi.org/https://doi.org/10.1016/j.learninstruc.2008.11.001>
- Loerwald, D. (2008). Multiperspektivität im Wirtschaftsunterricht. In D. Loerwald, M. Wiesweg, & A. Zoerner (Eds.), *Ökonomik und Gesellschaft: Festschrift für Gerd-Jan Krol* (pp. 232-250). VS Verlag für Sozialwissenschaften. https://doi.org/10.1007/978-3-531-91057-4_15
- Loerwald, D. (2020). Ökonomische Bildung in Deutschland. *List Forum für Wirtschafts- und Finanzpolitik*, 45(3), 239-253. <https://doi.org/10.1007/s41025-020-00187-z>
- Long, Y., Luo, H., & Zhang, Y. (2024). Evaluating large language models in analysing classroom dialogue. *npj Science of Learning*, 9(1), 60. <https://doi.org/10.1038/s41539-024-00273-3>

- Martikainen, J. (2020). How Students Categorize Teachers Based on Visual Cues: Implications of Nonverbal Communication for Classroom Management. *Scandinavian Journal of Educational Research*, 64(4), 569-588. <https://doi.org/10.1080/00313831.2019.1595713>
- Marzano, R. J., & Marzano, J. S. (2003). *Classroom management that works: Research-based strategies for every teacher*. Ascd.
- Mayer, R. (2004). Should There Be a Three-Strikes Rule Against Pure Discovery Learning? *American Psychologist*, 59, 14-19. <https://doi.org/10.1037/0003-066X.59.1.14>
- Metze, K., Morandin-Reis, R. C., Lorand-Metze, I., & Florindo, J. B. (2024). Bibliographic research with large language model ChatGPT-4: instability, hallucinations and sometimes alerts [10.1016/j.clinsp.2024.100409]. *Clinics*, 79. <https://doi.org/10.1016/j.clinsp.2024.100409>
- Min, A. (2023). Artificial Intelligence and Bias: Challenges, Implications, and Remedies. *Journal of Social Research*, 2, 3808-3817. <https://doi.org/10.55324/josr.v2i11.1477>
- Neumann, K., Kuhn, J., & Drachsler, H. (2024). Generative Künstliche Intelligenz in Unterricht und Unterrichtsforschung – Chancen und Herausforderungen. *Unterrichtswissenschaft*, 52(2), 227-237. <https://doi.org/10.1007/s42010-024-00212-6>
- Ophardt, D., Piwowar, V., & Thiel, F. (2017). Kompetenzen des Klassenmanagements (KODEK). In C. Gräsel & K. Trempler (Eds.), *Entwicklung von Professionalität pädagogischen Personals: Interdisziplinäre Betrachtungen, Befunde und Perspektiven* (pp. 133-152). Springer Fachmedien Wiesbaden. https://doi.org/10.1007/978-3-658-07274-2_8
- Ophardt, D., & Thiel, F. (2008). Klassenmanagement als Basisdimension der Unterrichtsqualität. In M. K. W. Schweer (Ed.), *Lehrer-Schüler-Interaktion: Inhaltsfelder, Forschungsperspektiven und methodische Zugänge* (pp. 259-282). VS Verlag für Sozialwissenschaften. https://doi.org/10.1007/978-3-531-91104-5_10
- Oser, F., & Baeriswyl, F. (2002). AERA's Handbook of Research on Teaching, 4th Edition. In (pp. 1031-1065).
- Pauli, C. (2012). Kodierende Beobachtung. In H. d. Boer & S. Reh (Eds.), *Beobachtung in der Schule. Beobachten lernen*. (pp. 45-63). Springer VS. https://doi.org/10.1007/978-3-531-18938-3_3
- Pauli, C., & Reusser, K. (2006). Von international vergleichenden Video Surveys zur videobasierten Unterrichtsforschung und -entwicklung. *Zeitschrift für Pädagogik*, 52(6), 774-798. <https://doi.org/10.1007/s00141-006-0068-1> Doi: 10.25656/01:4488
- Paulmann, S., & Weinstein, N. (2023). Teachers' motivational prosody: A pre-registered experimental test of children's reactions to tone of voice used by teachers. *British Journal of Educational Psychology*, 93(2), 437-452. <https://doi.org/10.1111/bjep.12567>
- Perković, G., Drobnjak, A., & Botički, I. (2024, 20-24 May 2024). Hallucinations in LLMs: Understanding and Addressing Challenges. 2024 47th MIPRO ICT and Electronics Convention (MIPRO),

- Petko, D., Waldis, M., Pauli, C., & Reusser, K. (2003). Methodologische Überlegungen zur videogestützten Forschung in der Mathematikdidaktik. *Zentralblatt für Didaktik der Mathematik*, 35, 265-280. <https://doi.org/10.1007/BF02656691>
- Pianta, R. C., & Hamre, B. K. (2009). Conceptualization, Measurement, and Improvement of Classroom Processes: Standardized Observation Can Leverage Capacity. *Educational Researcher*, 38(2), 109-119. <https://doi.org/10.3102/0013189X09332374>
- Pietrusky, S. (2025). *Schulische Praxis im Wandel. Kann künstliche Intelligenz helfen, Antworten auf die Fragen der Bildungsforschung zu liefern?* [Changing school practice. Can artificial intelligence help provide answers to educational research questions?]. <https://doi.org/URN:urn:nbn:de:0111-pedocs-330632> Doi: 10.25656/01:33063
- Piowar, V., Barth, V. L., Ophardt, D., & Thiel, F. (2018). Evidence-based scripted videos on handling student misbehavior: the development and evaluation of video cases for teacher education. *Professional Development in Education*, 44(3), 369-384. <https://doi.org/10.1080/19415257.2017.1316299>
- Platz, L., Findeisen, S., Köpfer, P., & Frech, V. (2025). Fachspezifische Unterrichtsqualität im Wirtschaftsunterricht – eine fachdidaktische Perspektive. 210-239. <https://doi.org/10.7808/ZFOEB.2025.110>
- Praetorius, A.-K., Charalambous, C., Vieluf, S., Steffensky, M., Göllner, R., & Fauth, B. (2025). Rethinking teaching-quality research: a reflection on the role of core working assumptions and possible pathways for future research. *School Effectiveness and School Improvement*, 36, 314-334. <https://doi.org/10.1080/09243453.2025.2482575>
- Praetorius, A.-K., & Charalambous, C. Y. (2018). Classroom observation frameworks for studying instructional quality: looking back and looking forward. *ZDM*, 50(3), 535-553. <https://doi.org/10.1007/s11858-018-0946-0>
- Praetorius, A.-K., & Gräsel, C. (2021). Noch immer auf der Suche nach dem heiligen Gral: Wie generisch oder fachspezifisch sind Dimensionen der Unterrichtsqualität? Still searching for the holy grail: How generic or subject-specific are dimensions of teaching quality? *Unterrichtswissenschaft*, 49. <https://doi.org/10.1007/s42010-021-00119-6>
- Praetorius, A.-K., Herrmann, C., Gerlach, E., Zülsdorf-Kersting, M., Heinitz, B., & Nehring, A. (2020a). Unterrichtsqualität in den Fachdidaktiken im deutschsprachigen Raum – zwischen Generik und Fachspezifik. *Unterrichtswissenschaft*, 48(3), 409-446. <https://doi.org/10.1007/s42010-020-00082-8>
- Praetorius, A.-K., Klieme, E., Herbert, B., & Pinger, P. (2018). Generic dimensions of teaching quality: the German framework of Three Basic Dimensions. *ZDM - International Journal on Mathematics Education*, 50. <https://doi.org/10.1007/s11858-018-0918-4>
- Praetorius, A.-K., Pauli, C., Reusser, K., Rakoczy, K., & Klieme, E. (2014). One lesson is all you need? Stability of instructional quality across lessons. *Learning and Instruction*, 31, 2-12. <https://doi.org/10.1016/j.learninstruc.2013.12.002>

- Praetorius, A.-K., Rogh, W., & Kleickmann, T. (2020b). Blinde Flecken des Modells der drei Basisdimensionen von Unterrichtsqualität? Das Modell im Spiegel einer internationalen Synthese von Merkmalen der Unterrichtsqualität. *Unterrichtswissenschaft*, 48(3), 303-318. <https://doi.org/10.1007/s42010-020-00072-w>
- Praetorius, A.-K., Vieluf, S., Saß, S., Bernholt, A., & Klieme, E. (2015). The same in German as in English? Investigating the subject-specificity of teaching quality. *Zeitschrift für Erziehungswissenschaft*, 19. <https://doi.org/10.1007/s11618-015-0660-4>
- Praetorius, A.-K., Wemmer-Rogh, W., Schreyer, P., & Brinkmann, M. (2024). Kognitive Aktivierung unter der Lupe: Eine Einführung in den Band. In (pp. 2). <https://doi.org/10.31244/9783830999010>
- Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2022). Robust Speech Recognition via Large-Scale Weak Supervision. *arXiv preprint*. <https://arxiv.org/abs/2212.04356>
- Rakoczy, K., & Pauli, C. (2006). Hoch inferentes Rating: Beurteilung der Qualität unterrichtlicher Prozesse [High-inference rating: Evaluating the quality of teaching processes]. *Videoanalysen [Video analysis]*, 206-233.
- Reh, S. (2012). Mit der Videokamera beobachten. In H. de Boer & S. Reh (Eds.), *Beobachtung in der Schule – Beobachten lernen* (pp. 151-169). VS Verlag für Sozialwissenschaften. https://doi.org/10.1007/978-3-531-18938-3_8
- Renkl, A. (2009). Wissenserwerb. In E. Wild & J. Möller (Eds.), *Pädagogische Psychologie* (pp. 3-26). Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-540-88573-3_1
- Reusser, K., & Pauli, C. (2021). Unterrichtsqualität ist immer generisch und fachspezifisch. Ein Kommentar aus kognitions- und lehr-lerntheoretischer Sicht. *Unterrichtswissenschaft*, 49(2), 189-202. <https://doi.org/10.1007/s42010-021-00117-8>
- Riebenbauer, E., Tafner, G., & Dreisiebner, G. (2025). Lehren und Lernen gestalten. In M. Stock, P. Slepcevic-Zach, G. Tafner, & E. Riebenbauer (Eds.), *Wirtschaftspädagogik* (3 ed., pp. 223-298). Uni-Press Graz.
- Rittle-Johnson, B., Loehr, A. M., & Durkin, K. (2017). Promoting self-explanation to improve mathematics learning: A meta-analysis and instructional design principles. *ZDM*, 49(4), 599-611. <https://doi.org/10.1007/s11858-017-0834-z>
- Rothland, M. (2024). Auf Sand gebaut? Über den Versuch, die Basisdimensionen der Unterrichtsqualität in erziehungswissenschaftlicher „Theorie“ zu verankern. *Zeitschrift für Bildungsforschung*, 14. <https://doi.org/10.1007/s35834-024-00411-2>
- Scheiter, K., Bauer, E., Omarchevska, Y., Schumacher, C., & Sailer, M. (2025). *Künstliche Intelligenz in der Schule - Eine Handreichung zum Stand in Wissenschaft und Praxis*. <https://doi.org/10.13140/RG.2.2.34511.19363>
- Schlotterbeck, D., Uribe, P., Araya, R., Jimenez, A., & Caballero, D. (2021). *What Classroom Audio Tells About Teaching: A Cost-effective Approach for Detection of Teaching Practices Using Spectral Audio Features* LAK21: 11th International Learning Analytics and Knowledge Conference, Irvine, CA, USA. <https://doi.org/10.1145/3448139.3448152>

- Schneider, J., Bohl, T., Kleinknecht, M., Rehm, M., Kuntze, S., & Syring, M. (2016). Unterricht analysieren und reflektieren mit unterschiedlichen Fallmedien: Ist Video wirklich besser als Text? *Unterrichtswissenschaft*, 44, 474-490.
- Schneider, S. (2025). *Künstliche Intelligenz an Hochschulen: Empirische Perspektiven zu generativer KI bei Abschlussarbeiten und in der Lehre*.
- Schonlau, M., & Couper, M. (2016). Semi-automated categorization of open-ended questions. *Survey Research Methods*, 10, 143-152. <https://doi.org/10.18148/srm/2016.v10i2.6213>
- Schramm, M. (2025). Ethische Entscheidungskriterien: Ethikkonzeptionen und wirtschaftsdidaktische Konsequenzen. *Zeitschrift für ökonomische Bildung*, 14, 1-56.
- Seidel, T. (2003). *Lehr-Lernskripts im Unterricht*.
- Seidel, T. (2009). Klassenführung. In E. Wild & J. Möller (Eds.), *Pädagogische Psychologie* (pp. 135-148). Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-540-88573-3_6
- Seidel, T. (2022). Professionelle Unterrichtswahrnehmung als Teil von Expertise im Lehrberuf. Weiterentwicklungsperspektiven für die videobasierte Lehrerforschung. In (pp. 17-36). <https://doi.org/10.31244/9783830995111>
- Seidel, T., Prenzel, M., Rimmele, R., Dalehefte, I. M., Herweg, C., Kobarg, M., & Schwindt, K. (2006). Blicke auf den Physikunterricht. Ergebnisse der IPN Videostudie. *Zeitschrift für Pädagogik*, 52.
- Seidel, T., & Shavelson, R. (2007). Teaching Effectiveness Research in the Past Decade: The Role of Theory and Research Design in Disentangling Meta-Analysis Results. *Review of Educational Research - REV EDUC RES*, 77, 454-499. <https://doi.org/10.3102/0034654307310317>
- Sender, T. (2017). *Wirtschaftsdidaktische Lerndiagnostik und Komplexität*. <https://doi.org/10.1007/978-3-658-18947-1>
- Sliwka, A., Klopsch, B., & Dumont, H. (2022). *Konstruktive Unterstützung im Unterricht* (2. aktualisierte Auflage ed.). Institut für Bildungsanalysen Baden-Württemberg. <https://ibbw.kultus-bw.de/Lde/Startseite/Empirische-Bildungsforschung/Publikationsreihe-Wirksamer-Unterricht>
- Spikol, D., Ruffaldi, E., Dabisias, G., & Cukurova, M. (2018). Supervised machine learning in multimodal learning analytics for estimating success in project-based learning. *Journal of Computer Assisted Learning*, 34. <https://doi.org/10.1111/jcal.12263>
- Steinmann, B. (1997). Das Konzept Qualifizierung für Lebenssituationen im Rahmen der ökonomischen Bildung heute [Aufsatz im Buch, Book section]. *Konzeptionelle Ansätze ökonomischer Bildung : [Tagung der Deutschen Gesellschaft für Ökonomische Bildung in Halle im März 1997]*, 1-22.
- Strong, M., Gargani, J., & Hacifazlioglu, O. (2011). Do We Know a Successful Teacher When We See One? Experiments in the Identification of Effective Teachers. *Journal of Teacher Education*, 62, 367-382. <https://doi.org/10.1177/0022487110390221>
- Trautwein, U., Marsh, H., Nagengast, B., Lüdtke, O., Nagy, G., & Jonkmann, K. (2012). Probing for the Multiplicative Term in Modern Expectancy-Value Theory: A Latent Interaction Modeling Study. *Journal of Educational Psychology*, 104, 763-777. <https://doi.org/10.1037/a0027470>

- Tulodziecki, G., Herzig, B., & Blömeke, S. (2017). *Gestaltung von Unterricht. Eine Einführung in die Didaktik* (3 ed.). Klinkhardt.
- van de Pol, J., Volman, M., Oort, F., & Beishuizen, J. (2015). The effects of scaffolding in the classroom: support contingency and student independent working time in relation to student achievement, task effort and appreciation of support. *Instructional Science*, 43(5), 615-641. <https://doi.org/10.1007/s11251-015-9351-z>
- Wang, H., Fu, T., Du, Y., Gao, W., Huang, K., Liu, Z., Chandak, P., Liu, S., Van Katwyk, P., Deac, A., Anandkumar, A., Bergen, K., Gomes, C. P., Ho, S., Kohli, P., Lasenby, J., Leskovec, J., Liu, T.-Y., Manrai, A., . . . Zitnik, M. (2023). Scientific discovery in the age of artificial intelligence. *Nature*, 620(7972), 47-60. <https://doi.org/10.1038/s41586-023-06221-2>
- Weyland, M., & Gross, A. (2022). Tasks in Economics Education - a Systematic Review / Aufgaben in der ökonomischen Bildung - ein systematischer Literaturüberblick. 42-77. <https://doi.org/10.7808/zfoeb.2021.10004.83>
- White, M., & Ronfeldt, M. (2024). Monitoring Rater Quality in Observational Systems: Issues Due to Unreliable Estimates of Rater Quality. *Educational Assessment*, 29(2), 124-146. <https://doi.org/10.1080/10627197.2024.2354311>
- Zucker, V., Sunder, C., Konjer, S., Rauterberg, T., Junker, R., Meschede, N., Holodyski, M., & Möller, K. (2020). Das Videoportal ViU: Early Science – Lernunterstützung und Klassenführung im naturwissenschaftlichen und technischen Sachunterricht professionell wahrnehmen. In R. Junker, V. Zucker, M. Oellers, T. Rauterberg, S. Konjer, N. Meschede, & M. Holodyski (Eds.), *Lehren und Forschen mit Videos in der Lehrkräftebildung* (pp. 145-164). Waxmann.

Verzeichnisse

Abkürzungsverzeichnis

DSGVO	Datenschutzgrundverordnung
EU	Europäische Union
F1	Forschungsfrage 1
F2	Forschungsfrage 2
IBBW	Institut für Bildungsanalysen Baden-Württemberg
KA	Kognitive Aktivierung
KI	Künstliche Intelligenz
KU	Konstruktive Unterstützung
LLM	Large Language Model
MAD	mittlere absolute Abweichung
SBT	Selbstbestimmungstheorie
SK	Strukturierte Klassenführung
SF	Syntheseframework
SuS	Schülerinnen und Schüler
UFB	Unterrichtsfeedbackbogen Tiefenstrukturen

Abbildungsverzeichnis

<i>Abb. 1:</i> Das MAIN-TEACH-Modell (Praetorius & Gräsel 2021, p. 182).	21
<i>Abb. 2:</i> Übersicht der Indikatoreignung nach Item und Basisdimension.....	43
<i>Abb. 3:</i> Eignung der Indikatoren der Basisdimension KA für die transkriptbasierte Analyse.	44
<i>Abb. 4:</i> Eignung der Indikatoren der Basisdimension KU für die transkriptbasierte Analyse.	46
<i>Abb. 5:</i> Eignung der Indikatoren der Basisdimension SK für die transkriptbasierte Analyse.	47

Tabellenverzeichnis

Tabelle 1: Vergleich menschlicher und KI-basierter Bewertung für die Dimension KA.....	48
Tabelle 2: Vergleich menschlicher und KI-basierter Bewertung für die Dimension KU.....	50
Tabelle 3: Vergleich menschlicher und KI-basierter Bewertung für die Dimension SK	51
Tabelle 4: Zusammenhang zwischen Indikatoreignung und Übereinstimmung	51
Tabelle 5: Verhältnis der Indikatoren pro Item und Richtung der Abweichung	52
Tabelle 6: Aggregierte Übereinstimmung auf Basisdimensionsebene (absteigend sortiert)....	53

Anhang

Indikatoreignung nach Items mit Definitionen aus dem IBBW Beobachtungsmanual

KA1 „Verständnisorientierung“

Indikator_ID	Positiv / Negativ	Beschreibung
1	+	In der Stunde wird deutlich, was die Schülerinnen und Schüler am Ende einer Einheit können, verstanden oder kritisch reflektiert haben sollen.
2	+	Die Lehrkraft fokussiert ihren Unterricht auf die zentralen zu erwerbenden Inhalte.
3	+	Der Unterricht ist so gestaltet, dass er es den Schülerinnen und Schülern ermöglicht, die zentralen Inhalte zu verstehen.
4	+	Der Bezug zu den zentralen Inhalten wird im Verlauf der Stunde immer wieder hergestellt.
5	+	Die Lehrkraft hebt bedeutsame Inhalte hervor.
6	+	Unterrichtsinhalte werden mit Blick auf das Unterrichtsziel zusammengefasst.
7	+	Die zu erwerbenden Inhalte werden klar und verständlich dargestellt.
8	-	Es gibt lange Unterrichtsphasen, die nicht auf das jeweilige Lernziel ausgerichtet sind.
9	-	Es bleibt unklar, was das Ziel der eingesetzten Aufgaben ist.
10	-	Es wird nicht erkennbar, welchen Fortschritt die Lernenden im Verlauf der Stunde oder der Einheit machen sollen.
11	-	In den vermittelten Inhalten stecken offensichtliche fachliche Fehler.

Indikator_ID	0	1	99	99 %	Eignung
1	0	18	0	0,0	geeignet
2	0	18	0	0,0	geeignet
3	0	18	0	0,0	geeignet
4	0	18	0	0,0	geeignet
5	0	18	0	0,0	geeignet
6	0	18	0	0,0	geeignet
7	0	18	0	0,0	geeignet
8	18	0	0	0,0	geeignet
9	18	0	0	0,0	geeignet
10	18	0	0	0,0	geeignet
11	18	0	0	0,0	geeignet

KA2 „Ermittlung von Denkweisen und Vorstellungen“

Indikator_ID	Positiv / Negativ	Beschreibung
1	+	Die Lehrkraft macht sich durch Blicke in Schülerhefte, Kontrolle von Lösungen oder kurze diagnostische Aufgaben ein Bild vom aktuellen Kenntnisstand der Schülerinnen und Schüler.
2	+	Die Lehrkraft sammelt unterschiedliche Schülerbeiträge und hält sich dabei selbst zurück.
3	+	Die Lehrkraft befragt die Schülerinnen und Schüler nach ihren Ideen und Vorstellungen zu einem Thema.
4	+	Die Lehrkraft fragt nach, wie Schülerinnen und Schüler zu ihren Vorstellungen oder Antworten gekommen sind.
5	+	Die Lernenden werden aufgefordert, ihre Antworten zu begründen.
6	+	Die Lehrkraft erfragt, was die Schülerinnen und Schüler verstanden bzw. nicht verstanden haben.
7	-	Die Lehrkraft steigt direkt in das Thema ein, ohne das Vorwissen der Schülerinnen und Schüler zu berücksichtigen.
8	-	Mündliche Interaktionsformen wie Nachfragen oder Aufforderungen zu erklären oder zu begründen werden von der Lehrkraft nicht genutzt, um das Vorwissen und die Präkonzepte der Schülerinnen und Schüler zu ermitteln.
9	-	Schülerbeiträge werden nicht genutzt, um das Verständnisniveau zu explorieren.

Indikator_ID	0	1	99	99 %	Eignung
1	3	15	0	0,0	geeignet
2	7	11	0	0,0	geeignet
3	1	17	0	0,0	geeignet
4	6	12	0	0,0	geeignet
5	3	15	0	0,0	geeignet
6	13	5	0	0,0	geeignet
7	10	0	8	44,4	bedingt geeignet
8	17	1	0	0,0	geeignet
9	17	1	0	0,0	geeignet

KA3 „Herausfordernde Aufgaben und Fragen“

Indikator_ID	Positiv / Negativ	Beschreibung
1	+	Die von der Lehrkraft gestellten Fragen und Aufgaben können nicht nur mit Ja oder Nein beantwortet werden.
2	+	Die von der Lehrkraft gestellten Fragen und Aufgaben gehen über die reine Reproduktion von auswendig gelerntem Wissen oder der Anwendung von Prozeduren hinaus.
3	+	Die Schülerinnen und Schüler werden aufgefordert, eigene Lösungsideen zu entwickeln.
4	+	Unterschiedliche Meinungen, Lösungen oder Fälle werden einander kontrastierend gegenübergestellt.
5	+	Die Lehrkraft konfrontiert die Schülerinnen und Schüler mit widersprüchlichen Sachverhalten.
6	+	Die Schülerinnen und Schüler werden zu Selbsterklärungen angehalten.
7	+	Die Schülerinnen und Schüler übernehmen selbst die Rolle der Lehrkraft und stellen Fragen, fordern Antworten/ Erklärungen ein oder fassen zusammen (vgl. reziprokes Lehren).
8	-	Trotz herausfordernder Fragestellungen versucht die Lehrkraft durch kleinschrittiges Vorgehen bei der Bearbeitung, die Schülerinnen und Schüler zu einer bestimmten Antwort zu bringen.
9	-	Unterschiedliche Lösungen werden einander kontrastierend gegenübergestellt, aber wichtige Zusammenhänge zwischen ihnen werden nicht hergestellt.
10	-	Im Unterrichtsgespräch verfolgt die Lehrkraft eine vorausgeplante Argumentationslinie, weshalb die Interaktion mit den Lernenden zu einer Art „Versuch und-Irrtum-Spiel“ wird und Schülerantworten unberücksichtigt bleiben (vgl. Kunter & Trautwein, 2013).

Indikator-ID	0	1	99	99 %	Eignung
1	0	18	0	0,0	geeignet
2	2	16	0	0,0	geeignet
3	5	13	0	0,0	geeignet
4	2	16	0	0,0	geeignet
5	8	10	0	0,0	geeignet
6	1	17	0	0,0	geeignet
7	18	0	0	0,0	geeignet
8	8	10	0	0,0	geeignet
9	18	0	0	0,0	geeignet
10	15	3	0	0,0	geeignet

KA4 „Engagement der Schülerinnen und Schüler“

Indikator_ID	Positiv / Negativ	Beschreibung
1	+	Der Aufmerksamkeitsfokus der Schülerinnen und Schüler liegt auf dem Unterrichtsgeschehen.
2	+	Die Schülerinnen und Schüler beteiligen sich durch Meldungen aktiv am Unterricht.
3	+	Die Schülerinnen und Schüler beteiligen sich auch mit längeren Beiträgen (nicht nur kurze Antworten auf Fragen der Lehrkraft) aktiv am Unterricht.
4	+	Die Schülerinnen und Schüler stellen der Lehrkraft Fragen, wenn ihnen etwas ungeklärt oder unverständlich erscheint oder erklären, wie sie einen Sachverhalt verstanden haben, um zu erfahren, ob sie die Inhalte richtig nachvollzogen haben.
5	+	Die Lernenden zeigen Interesse und Freude am Unterricht.
6	-	Die Schülerinnen und Schüler sind mit ihrer Aufmerksamkeit nicht beim Unterrichtsgeschehen („passives off-task Verhalten“).
7	-	Die Schülerinnen und Schüler geben kurze, oberflächliche Antworten.
8	-	Die Schülerinnen und Schüler beteiligen sich nur auf explizite Aufforderung der Lehrkraft.
9	-	Schülerinnen und Schüler geben bei schwierigen Aufgaben schnell auf.
10	-	Die Schülerinnen und Schüler wirken desinteressiert und lustlos.

Indikator-ID	0	1	99	99 %	Eignung
1	0	17	1	5,6	geeignet
2	0	7	11	61,1	nicht geeignet
3	0	18	0	0,0	geeignet
4	7	11	0	0,0	geeignet
5	8	7	3	16,7	bedingt geeignet
6	18	0	0	0,0	geeignet
7	5	13	0	0,0	geeignet
8	7	11	0	0,0	geeignet
9	18	0	0	0,0	geeignet
10	17	0	1	5,6	bedingt geeignet

KU1 „Qualität des Feedbacks“

Indikator_ID	Positiv / Negativ	Beschreibung
1	+	Die Rückmeldungen und Kommentare der Lehrkraft helfen den Schülerinnen und Schülern dabei, ihre Fehler zu erkennen und ihr weiteres Vorgehen zu verbessern.
2	+	Es wird erarbeitet, warum eine Antwort oder eine Lösung richtig oder falsch war.
3	+	Die Lehrkraft fokussiert in ihren Rückmeldungen und Kommentaren auf den Prozess der Aufgabenlösung.
4	+	Korrekte Antworten der Schülerinnen und Schüler werden gewürdigt.
5	+	Die Lehrkraft formuliert Rückmeldungen in einem freundlichen, wohlwollenden Ton, auch wenn sie auf Fehler oder Mängel aufmerksam macht.
6	+	Die Lehrkraft stellt Schülerinnen und Schüler bei Fehlern nicht bloß.
7	+	Es wird deutlich, dass Fehler wichtig sind und helfen, zu lernen.
8	+	Die Lehrkraft nutzt Fehler, um auf unzutreffendes Verständnis der Schülerinnen und Schüler einzugehen.
9	-	Die Lehrkraft gibt unsachliche Rückmeldungen und Kommentare, welche sich auf die Person des Lernenden selbst beziehen.
10	-	Das Feedback der Lehrkraft beschränkt sich auf reine Instruktionen, die den Schülerinnen und Schülern den korrekten Lösungsweg aufzeigen.
11	-	Situationen, in denen Feedback notwendig wäre, werden nicht genutzt.

Indikator-ID	0	1	99	99 %	Eignung
1	3	15	0	0,0	geeignet
2	1	17	0	0,0	geeignet
3	1	17	0	0,0	geeignet
4	0	18	0	0,0	geeignet
5	0	18	0	0,0	geeignet
6	0	17	1	5,6	geeignet
7	17	1	0	0,0	geeignet
8	3	14	1	5,6	geeignet
9	15	3	0	0,0	geeignet
10	15	3	0	0,0	geeignet
11	18	0	0	0,0	geeignet

KU2 „Individuelle Unterstützung im Lernprozess“

Indikator_ID	Positiv / Negativ	Beschreibung
1	+	Die Lehrkraft nimmt sich bei Verständnisproblemen gezielt Zeit für einzelne Schülerinnen und Schüler.
2	+	Nach Rückfragen erklärt die Lehrkraft klar und verständlich.
3	+	Unterstützende Maßnahmen und Hilfestellungen der Lehrkraft sind individuell an den Lernstand der Schülerinnen und Schüler angepasst.
4	+	Die Lehrkraft ermöglicht, z. B. durch individualisierte Arbeitsphasen, eine Differenzierung des Anspruchsniveaus, des Lerntempos und/oder der Inhalte.
5	+	Die Lehrkraft gibt den Schülerinnen und Schülern genug Zeit, um überlegt auf Fragen antworten zu können.
6	+	Die Lehrkraft bietet Hilfen bei sprachlichen Barrieren an.
7	-	Den Schülerinnen und Schülern wird durch zu enggeführte Erklärung die Möglichkeit genommen, sich Inhalte selbst zu erschließen.
8	-	Die geforderten Aufgaben stellen für die Schülerinnen und Schüler eine offensichtliche Unter- oder Überforderung dar.
9	-	Die geforderten Aufgaben können von den Schülerinnen und Schülern selbst mit Hilfe nicht bewältigt werden.

Indikator-ID	0	1	99	99 %	Eignung
1	6	12	0	0,0	geeignet
2	6	12	0	0,0	geeignet
3	7	11	0	0,0	geeignet
4	18	0	0	0,0	geeignet
5	1	2	15	83,3	nicht geeignet
6	16	2	0	0,0	geeignet
7	17	1	0	0,0	geeignet
8	17	1	0	0,0	geeignet
9	18	0	0	0,0	geeignet

KU3 „Wertschätzung und Respekt“

Indikator_ID	Positiv / Negativ	Beschreibung
1	+	Die Lehrkraft geht freundlich und respektvoll mit ihren Schülerinnen und Schülern um.
2	+	Die Lehrkraft behandelt alle Schülerinnen und Schüler gleich freundlich, unabhängig von ihren individuellen Hintergründen.
3	+	Die Lehrkraft zeigt Interesse für die Perspektiven und Meinungen der Schülerinnen und Schüler.
4	+	Die Lehrkraft nimmt die Gefühle und außerschulischen/ nicht fachlichen Probleme der Schülerinnen und Schüler ernst.
5	+	Die Lehrkraft geht (in angemessenem Rahmen) auch auf persönliche Berichte oder Probleme von Schülerinnen und Schülern ein.
6	-	Die Lehrkraft ist ablehnend und distanziert gegenüber ihren Schülerinnen und Schülern.
7	-	Schülerinnen und Schüler werden von der Lehrkraft lächerlich gemacht, bloßgestellt oder respektlos behandelt.
8	-	Die Lehrkraft macht sarkastische oder zynische Bemerkungen.
9	-	Die Lehrkraft zeigt Gesten der Verächtlichmachung (z. B. wegwerfende Handbewegungen).

Indikator-ID	0	1	99	99 %	Eignung
1	0	18	0	0,0	geeignet
2	0	15	3	16,7	bedingt geeignet
3	0	18	0	0,0	geeignet
4	17	1	0	0,0	geeignet
5	17	1	0	0,0	geeignet
6	18	0	0	0,0	geeignet
7	18	0	0	0,0	geeignet
8	17	1	0	0,0	geeignet
9	11	0	7	38,9	nicht geeignet

KU4 „Klassenklima“

Indikator_ID	Positiv / Negativ	Beschreibung
1	+	Die Schülerinnen und Schüler hören einander zu und lassen sich gegenseitig ausreden, auch bei länger andauernden Antworten.
2	+	Die Schülerinnen und Schüler helfen und unterstützen sich gegenseitig.
3	+	Die Schülerinnen und Schüler stellen einander bei Fehlern nicht bloß.
4	+	Das Klassenklima ist durch Zusammenhalt und Kameradschaftlichkeit geprägt.
5	+	Die Schülerinnen und Schüler sprechen in einem respektvollen und höflichen Ton mit der Lehrkraft.
6	+	Die Schülerinnen und Schüler hören der Lehrkraft zu und lassen sie ausreden.
7	-	Bei Fehlern reagieren die Schülerinnen und Schüler mit abwertenden Kommentaren.
8	-	Die Schülerinnen und Schüler gehen respektlos miteinander um (z. B. Hänseleien, provozierendes Verhalten, Beschimpfungen, Auslachen).
9	-	Es kommt zu verbalen oder körperlichen Auseinandersetzungen zwischen Schülerinnen und Schülern.
10	-	Die Stimmung in der Klasse ist von einer unangenehmen Anspannung geprägt.
11	-	Die Schülerinnen und Schüler zeigen sich respektlos gegenüber der Lehrkraft (z. B. durch Nachäffen, Grimassen, Witze auf Kosten der Lehrkraft, unhöflicher Tonfall).

Indikator-ID	0	1	99	99 %	Eignung
1	9	2	7	38,9	bedingt geeignet
2	15	1	2	11,1	bedingt geeignet
3	6	8	4	22,2	bedingt geeignet
4	10	1	7	38,9	bedingt geeignet
5	0	18	0	0,0	geeignet
6	0	18	0	0,0	geeignet
7	18	0	0	0,0	geeignet
8	18	0	0	0,0	geeignet
9	18	0	0	0,0	geeignet
10	18	0	0	0,0	geeignet
11	18	0	0	0,0	geeignet

SK1 „Störungen durch Schülerinnen und Schüler“

Indikator_ID	Positiv / Negativ	Beschreibung
1	+	Der Unterricht verläuft ruhig und geordnet.
2	+	Die Lautstärke während der Unterrichtsstunde ist der jeweiligen Unterrichtsphase angemessen.
3	+	Die Schülerinnen und Schüler halten sich an Regeln und bestehende Rituale.
4	+	Es kommt nur selten zu Störungen.
5	-	Es kommt zu intensiven Störungen (Schülerinnen und Schüler schwatzen, werfen Gegenstände umher, tauschen Zettel, machen Faxen hinter dem Rücken der Lehrkraft usw.).
6	-	Die Lautstärke während der Unterrichtsstunde ist zu hoch, um dem Unterrichtsgeschehen noch folgen zu können.
7	-	Trotz Interventionen der Lehrkraft treten immer wieder Störungen auf.

Indikator-ID	0	1	99	99 %	Eignung
1	0	18	0	0,0	geeignet
2	0	11	7	38,9	bedingt geeignet
3	1	15	2	11,1	geeignet
4	0	18	0	0,0	geeignet
5	18	0	0	0,0	geeignet
6	17	0	1	5,6	bedingt geeignet
7	18	0	0	0,0	geeignet

SK2 „Monitoring“

Indikator_ID	Positiv / Negativ	Beschreibung
1	+	Die Lehrkraft hat alle Schülerinnen und Schüler im Blick.
2	+	Die Lehrkraft ist im ganzen Klassenzimmer präsent (z. B. durch Blicke oder Bewegungen), auch während Einzelarbeitsphasen.
3	+	Die Lehrkraft kehrt den Schülerinnen und Schülern nur selten den Rücken zu und richtet ihren Blick meist zur Klasse.
4	+	Die Lehrkraft geht mit Störungen, die den Unterrichtsfluss gefährden, angemessen um.
5	+	Aufkeimende Störungen behebt die Lehrkraft frühzeitig und beiläufig, sodass es erst gar nicht zu Unruhe oder Störungen kommt (z. B. durch nonverbale/verbale Signale wie räumliches Annähern, Blicke oder Gesten).
6	-	Im Gespräch mit einzelnen Schülerinnen und Schülern verliert die Lehrkraft die restliche Klasse aus dem Blick.
7	-	Die Lehrkraft steht häufig mit dem Rücken zur Klasse.
8	-	Die Lehrkraft bemerkt einzelne Schülermeldungen oft nicht oder erst spät.
9	-	Die Lehrkraft verfügt über ein eingeschränktes Verhaltensrepertoire zur Reaktion auf Störungen (z. B. häufiges „Pst“).
10	-	Die Lehrkraft gibt Störungen so viel Raum, dass eine Beschäftigung mit den Unterrichtsinhalten nur noch eingeschränkt möglich ist.

Indikator-ID	0	1	99	99 %	Eignung
1	0	18	0	0,0	bedingt geeignet
2	1	0	17	94,4	nicht geeignet
3	0	0	18	100,0	nicht geeignet
4	5	2	11	61,1	bedingt geeignet
5	4	5	9	50,0	bedingt geeignet
6	11	0	7	38,9	bedingt geeignet
7	0	0	18	100,0	nicht geeignet
8	17	0	1	5,6	bedingt geeignet
9	11	0	7	38,9	bedingt geeignet
10	13	0	5	27,8	bedingt geeignet

SK3 „Zeitnutzung“

Indikator_ID	Positiv / Negativ	Beschreibung
1	+	Die Unterrichtsstunde beginnt und endet pünktlich.
2	+	Die Unterrichtszeit wird für fachliche Themen genutzt, nicht-fachliche Dinge werden auf vor oder nach dem Unterricht verschoben beziehungsweise schnellstmöglich besprochen.
3	+	Zwischen einzelnen Unterrichtsphasen oder Arbeitsaufträgen kommt es nicht zu unnötigen Warte- oder Leerzeiten.
4	+	Die Unterrichtsstunde macht einen geplanten und strukturierten Eindruck, der eine gute Unterrichts- und Zeitplanung zugrunde liegt.
5	+	Die Lehrkraft plant genügend Zeit für die Bearbeitung von Aufgaben ein, sodass einzelne Unterrichtsphasen nicht stark verkürzt oder abgebrochen werden müssen.
6	+	Die Lehrkraft gerät nicht unter Zeitdruck.
7	-	Durch die Art der Unterrichtsorganisation wird unnötig Zeit verschwendet.
8	-	Zu Beginn neuer Arbeitsphasen dauert es lange, bis die Schülerinnen und Schüler zur Ruhe kommen und mit der Arbeit beginnen.
9	-	Die Lehrkraft scheint unvorbereitet zu sein (hat z. B. Materialien nicht griffbereit, ist unsicher im Ablauf der Unterrichtsstunde).
10	-	Die Lehrkraft gerät zum Stundenende unter Zeitdruck und wird hektisch.
11	-	Die Lehrkraft plant zu viel Zeit für die Bearbeitung von Aufgaben ein, sodass Leerlauf für die Schülerinnen und Schüler entsteht.

Indikator-ID	0	1	99	99 %	Eignung
1	0	0	18	100,0	nicht geeignet
2	0	18	0	0,0	geeignet
3	0	18	0	0,0	geeignet
4	0	18	0	0,0	geeignet
5	0	16	2	11,1	bedingt geeignet
6	0	18	0	0,0	geeignet
7	17	1	0	0,0	geeignet
8	18	0	0	0,0	geeignet
9	18	0	0	0,0	geeignet
10	9	0	9	50,0	bedingt geeignet
11	18	0	0	0,0	geeignet

Erweiterter Anhang

Über den QR-Code (oder manuell über den Weblink) kann auf eine Website zur Masterarbeit zugegriffen werden. Dort stehen eine Zusammenfassung der Arbeit und weitere Anhänge zum Download bereit.



Weblink: <https://masterarbeit-u247.onrender.com/>